3. Elemente de bază în modelarea sistemelor cu şiruri de aşteptare

3.1. Definiţia unui sistem cu şir de aşteptare

A. Un sistem în cadrul căruia se execută un anumit serviciu se numeşte **sistem de servire.**

B. Obiectivul asupra căruia se execută serviciul respectiv poartă denumirea de **clienţi .** Un client emite o cerere de servire.

C. **Staţia de servire** este o instalaţie (într-un sens foarte larg) care poate servi un singur client la un moment dat. Dacă serviciul se execută în etape de către mai multe staţii, atunci succesiunea acestora formează o **linie de servire**. Mai multe staţii sau linii de servire care por servi mai mulţi clienţi simultan formează un canal de servire.

D. Presupunem că o secvenţă de clienţi soseşte la o linie de servire. Dacă clientul care a sosit găseşte staţia de servire ocupată, va fi pus în situaţia să aştepte. Unităţile care aşteaptă să fie servite formează un **şir de aşteptare**. Criteriul prin care este stabilită ordinea servirii unităţilor aflate în sistem se numeşte **disciplina şirului de aşteptare**.

E. Când staţia se eliberează, un client este selectat din şirul de aşteptare conform disciplinei de servire. Cererea de servire prezentată de client este în continuare executată şi după completarea serviciului clientul părăseşte sistemul de servire.

Un sistem de servire are următoarea reprezentare:

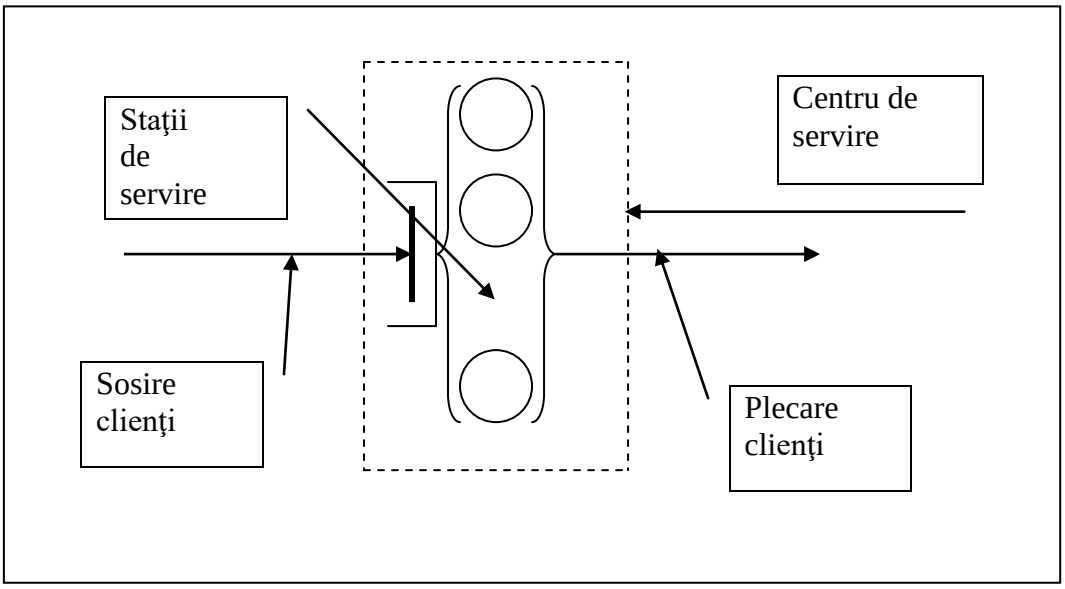

Teoria aşteptării pune la dispoziţie un aparat matematic care dă posibilitatea descrierii stării prezente a unui sistem cu şiruri de aşteptare şi de a formula concluzii cu caracter probabilistic asupra comportării sale viitoare.

3.2. Indici de performanţă pentru un sistem cu şir de aşteptare

Indicii de performanţă definesc parametrii ce caracterizează funcţionarea de ansamblu a sistemului studiat. Pentru înţelegerea acestora definirea se va face plecând de la un exemplu.

Considerăm că la intrarea unui centru de servire de forma

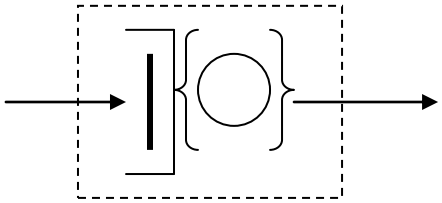

sosesc într-un interval de 10 unităţi de timp un număr de 4 clienţi la momentele specificate în graficul de mai jos. Pentru fiecare client se specifică şi timpul de servire solicitat a fi efectuat în staţia de servire.

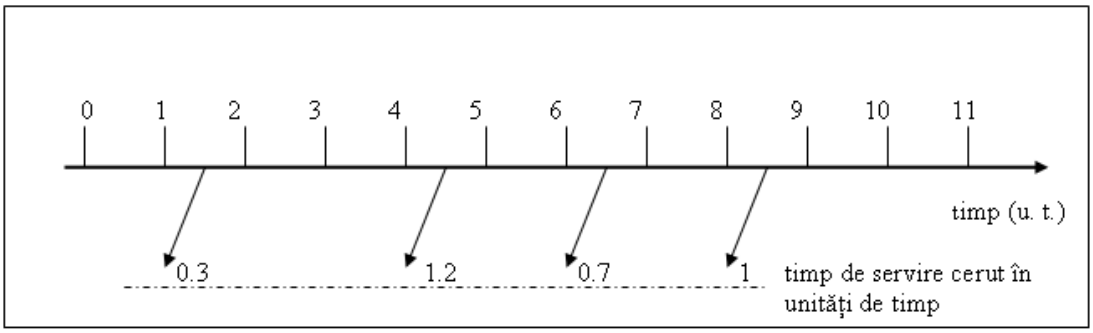

Mărimile care caracterizează procesul de sosire/servire sunt următoarele:

(a) ***frecvenţa de sosire***

Defineşte numărul de clienţi care sosesc la intrarea centrului în unitatea de timp. Parametrul se notează cu λ. Pentru exemplul dat avem:

$$\lambda = \frac{4}{10} = 0.4 \text{ cereri/u.t.}$$

(b) timpul mediu de servire

Defineşte cât solicită în medie o cerere pentru a fi servită. În acelaşi timp parametrul reprezintă şi timpul mediu de execuţie a staţiei centrului de servire. Mărimea se notează cu $\bar{s}$.

Pentru exemplul dat avem:

$$\bar{s} = \frac{0.3 + 1.2 + 0.7 + 1}{4} = \frac{3.2}{4} = 0.8 \text{ u.t.}$$

(c) frecvenţa de servire

Reprezintă numărul de cereri care pot fi servite de staţia centrului în unitatea de timp. Mărimea se notează cu μ.

Este egală cu:

$$\mu = \frac{1}{\bar{s}} \qquad \mu = \frac{1 \text{ unitate de timp}}{\text{timp mediu de servire/cerere}}$$

Pentru exemplul dat avem $\mu = \frac{1}{0.8}$ = 1.25 cereri/u.t.

(d) gradul de utilizare

Reprezintă din timpul total de funcţionare în care centrul de servire (staţia sau staţiile) sunt ocupate. Parametrul se notează cu ρ. Pentru exemplul dat avem:

$\rho = \frac{0.3 + 1.2 + 0.7 + 1}{10} = 0.32$ cu interpretarea: din timpul de funcţionare 32% staţia este ocupată.

Se pot face următoarele observaţii:

- ρ se mai poate scrie sub forma: $\rho = \frac{3.2}{10} = \frac{\frac{3.2}{4}}{\frac{10}{4}} = \frac{\bar{s}}{\frac{1}{\lambda}} = \frac{\lambda}{\mu}$

Prin urmare $\rho = \frac{\lambda}{\mu}$

- gradul de utilizare $\rho \le 1$. Pentru $\rho = 1$ clienţii sosesc mai repede decât pot fi serviţi.

- pentru un sistem de servire cu m staţii

$$\rho = \min\left\{\frac{\lambda}{m\mu}, 1\right\}$$

(e) capacitatea de trecere

Parametrul defineşte numărul mediu de clienţi serviţi în unitatea de timp. Se notează cu τ şi este echivalentă cu frecvenţa sosirilor dacă λ este mai mică decât maximul frecvenţei de servire μ, în caz contrar capacitatea de trecere se saturează la valoarea μ. Pentru un centru de servire cu m staţii capacitatea de trecere este

$\tau = \min\{\lambda, m\mu\}$

(f) timpul de aşteptare şi timpul de răspuns

Reprezintă timpul pe care îl petrece un client în şirul de aşteptare până în momentul în care poate fi servit. Parametrul se notează cu w_j. Timpul de răspuns

este definit ca fiind timpul total petrecut de un client în sistem. Se notează cu T_j şi este egal cu $T_j = w_j + s_j$

(g) lungimea şirului de aşteptare, numărul total de clienţi din sistem.

Se notează cu Q(t) şi reprezintă numărul de clienţi care se găsesc în şir la momentul t. Numărul total de clienţi care se găsesc în centrul de servire la momentul t se notează cu N(t). Pentru un centru cu m staţii de servire

$$Q(t) = \max\{0, N(t)-m\}$$

3.3. Distribuţia numărului de clienţi care apar la intrarea unui centru de servire

Să considerăm un sistem la intrarea căruia cererile sosesc întâmplător. Ne propunem să determinăm distribuţia de probabilitatea variabilei aleatoare

număr de clienţi care sosesc într-un interval de timp de lungime T.

Notăm cu $P(n(t_0, T) = k)$ probabilitatea să înregistrăm k sosiri în sistem în intervalul de timp (t_0, t_0+T), $(t_0 \geq 0)$.

Pentru a calcula această distribuţie împărţim intervalul T în m subintervale, fiecare din acestea având lungimea $h = \frac{T}{m}$

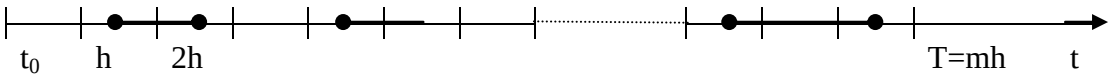

Vom presupune că:

(a) $P(n(t_0, T) = k)$ nu depinde de t_0 (ci numai de k şi de lungimea T a intervalului de timp) şi nici de numărul intrărilor înregistrate în intervalele anterioare momentului t_0. În acest caz vom putea scrie

$$P(n(t_0, T) = k) = P(n(T) = k)$$

Proprietatea ne asigură că sosirile sunt statistic independente (sosirea unui client nu este condiţionată de sosirea altuia).

(b) Probabilitatea ca să sosească două sau mai multe unităţi într-un interval de timp foarte mic este neglijabilă faţă de lungimea intervalului, sau altfel spus este practic imposibil să înregistrăm două sau mai multe sosiri simultane. Notăm cu P (n (h) > 1) = o (h) unde prin o (h) am notat o funcţie de h cu proprietatea

$$\lim_{h \to 0} \frac{o(h)}{h} = 0$$

(c) Dacă notăm cu λ frecvenţa medie a unei sosiri a clienţilor (nr. de clienţi în unitatea de timp) atunci probabilitatea înregistrării unei singure sosiri în intervalul t, t+h este

$$P(n(h) = 1) = \lambda h$$

<u>Obs.</u>

$$\text{probabilitatea} = \frac{\text{nr. de cereri aparute}}{\text{nr. total posibil de cereri care pot apare}}$$

$$P(n(h) = 1) = \frac{\lambda}{\frac{1}{h}} = \lambda h$$

numeric $\frac{1}{h}$ apare din considerentul

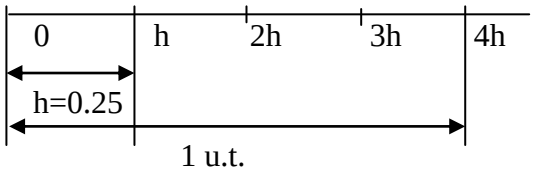

Pot apare $\frac{1}{h} = \frac{1}{0.25} = 4$ cereri

Proprietatea ne spune că pentru intervale foarte mici de timp probabilitatea este proporţională cu lungimea intervalului.

(d) Ca urmare probabilitatea de a avea cel puţin o sosire a unui client într-un interval de lungime h este

$P(n(h) \geq 1) = P(n(h) = 1) + P(n(h) > 1) = \lambda h + o(h)$

iar probabilitatea de a nu avea nici o sosire într-un interval de lungime h este

$P(n(h) = 0) = 1 - P(n(h) = 1) = 1 - (\lambda h + o(h))$

Teoremă

În condiţiile a, b, c pentru orice $t \geq 0$ distribuţia variabilei aleatore n (T) – număr de sosiri în intervalul T – este o distribuţie Poisson de parametru λT

$$P(n(T) = k) = \frac{(\lambda T)^k}{k!} e^{-\lambda T}$$

Demonstraţie

Se poate considera sosirea unei cereri ca un "succes al unui experiment Bernoulli, iar modul în care sosesc cererile pe perioada $T = m \cdot h$ ca o secvenţă de m experimente Bernoulli.

Cu aceste considerente probabilitatea ca să apară exact k clienţi în k subintervale şi să nu apară în m - k subintervale poate fi definită ca fiind o distribuţie binomială

$$P(n(T) = k) = C_m^k (\lambda h + o(h))^k (1 - \lambda h - o(h))^{m-k}$$

Pentru a vedea cum se ajunge la aceasta relaţie vom proceda in următorii paşi succesivi:

1. Şansa ca să avem o sosire in intervalul *h* este λh
2. Şansa ca să avem *k* sosiri in *k* subintervale este
   λh si λh si …… λh de *k* ori deci avem $(\lambda h)^k$
3. Şansa ca să nu avem sosiri intr-un interval *h* este $1 - \lambda h$
4. Şansa ca să nu avem sosiri in restul de *m-k* subintervale este
   $(1 - \lambda h)$ *si* $(1 - \lambda h)$ *si* $(1 - \lambda h)$ *si* …….$(1 - \lambda h)$ *si* deci avem $(1 - \lambda h)^{m-k}$
5. Şansa ca să avem sosiri in *k* subintervale si in restul de *m-k* să nu avem sosiri va fi data de $(\lambda h)^k$ si $(1 - \lambda h)^{m-k}$ si deci vom avea $(\lambda h)^k (1 - \lambda h)^{m-k}$
6. Deoarece cele *k* sosiri se pot distribui in C_m^k moduri in cele *m* subintervale vom avea:

$(\lambda h+o(h))^k(1-\lambda h-o(h))^{m-k}$ sau $(\lambda h+o(h))^k(1-\lambda h-o(h))^{m-k}$ sau

$(\lambda h+o(h))^k(1-\lambda h-o(h))^{m-k}$ de C_m^k deci in final vom obţine:

7. $P(n(T)=k)=C_m^k(\lambda h+o(h))^k(1-\lambda h-o(h))^{m-k}$
8. Deoarece şansa de a avea doua sau mai multe sosiri in intervalul h este foarte mica *o(h)=0* si ca rezultat vom obţinem relaţia finala:
9. $P(n(T)=k)=C_m^k(\lambda h)^k(1-\lambda h)^{m-k}$

Pentru a găsi probabilitatea ca n(T) clienţi să sosească în intervalul T vom trece la limită pentru h → 0 şi m → ∞ menţinându-l însă pe T = h · m constant

$$P(n(T)=k)=\lim_{\substack{h\to 0\\ m\to\infty}} C_m^k(\lambda h)^k(1-\lambda h)^{m-k}=\lim_{\substack{h\to 0\\ m\to\infty}}\frac{m!}{k!(m-k)!}\cdot\frac{(\lambda h)^k(1-\lambda h)^m}{(1-\lambda h)^k}$$

$$\lim_{\substack{h\to 0\\ m\to\infty}}(1-\lambda h)^m=\lim_{\substack{h\to 0\\ m\to\infty}}(1-\lambda h)^{\frac{T}{h}\cdot\frac{\lambda}{\lambda}}=\lim_{h\to 0}(1-\lambda h)^{\frac{1}{\lambda h}\cdot\lambda T}=e^{-\lambda T}$$

$$P(n(T)=k)=\frac{e^{-\lambda T}}{k!}\lim_{\substack{m\to 0\\ h\to\infty}}\frac{m!}{(m-k)!}\cdot\frac{(\lambda h)^k}{(1-\lambda h)^k}$$

$$P(n(T)=k)=\frac{e^{-\lambda T}}{k!}\lim_{m\to\infty} m(m-1)(m-2)...(m-k+1)\frac{\left(\frac{\lambda T}{m}\right)^k}{\left(1-\frac{\lambda T}{m}\right)^k}$$

$$P(n(T)=k)=\frac{e^{-\lambda T}(\lambda T)^k}{k!}\lim_{m\to\infty}\frac{m^k+...}{m^k+...}$$

$$P(n(T)=k)=\frac{e^{-\lambda T}(\lambda T)^k}{k!}$$

Observaţii

(1) Variabila aleatoare n (T) are o distribuţie Poisson cu media şi varianta egale cu λT

(2) Observaţia (1) implică faptul că variabila aleatoare $X = \frac{n(T)}{T}$ are valoarea medie $E\left\{\frac{n(T)}{T}\right\} = \lambda$ iar

varianta $Var\left\{\frac{n(T)}{T}\right\} = \frac{1}{T^2} Var\{n(T)\} = \frac{\lambda T}{T^2} = \frac{\lambda}{T}$

Pentru $T \to \infty$ media tinde către λ iar varianta către 0 ceea ce justifică numele de frecvenţă de sosire pentru parametrul λ.

3.4. Distribuţia intervalului de timp între două sosiri

Dacă sosirile constituie un proces Poisson cu parametrul λT, atunci intervalele de timp între două intrări consecutive sunt variabile aleatoare independente care urmează o lege exponenţială cu parametrul λ..

Notăm cu X intervalul de la o origine de timp arbitrar aleasă până la prima sosire. Dacă ne raportăm la desenul anterior putem avea

Ne propunem să găsim distribuţia de probabilitate a variabilei aleatoare interval de timp până la prima sosire.

Dacă notăm cu P (n (x) = 0) probabilitatea ca nici un client să nu sosească în intervalul (t_0, t_0+x), n(x) reprezentând numărul de clienţi sosiţi într-un interval de timp de lungime x atunci

$P(X \geq x) = P(n(x) = 0)$

dar din P (n (T) = k) $\Rightarrow$ $P(n(x) = 0) = e^{-\lambda x}$

Prin urmare funcţia de distribuţie a variabilei aleatoare X dată de P (X < x) = F (x) = 1 – P (X ≥ x) = 1 – $e^{-\lambda x}$ pentru x ≥ 0

ca urmare densitatea de probabilitate

$$f(x) = F'(x) = \lambda\, e^{-\lambda x}$$

Astfel pentru un proces de sosire Poisson intervalul X între o origine arbitrar aleasă şi momentul primei sosiri este exponenţial distribuit cu media $\frac{1}{\lambda}$. Dacă se va alege ca origine momentul sosirii unui alt client, atunci X va reprezenta intervalul între două sosiri.

În concluzie un proces Poisson are intervalele între două sosiri succesive exponenţial distribuite cu media $\frac{1}{\lambda}$.

3.5. Lipsa de memorie a unui proces Poisson

Un proces Poisson este lipsit de memorie deoarece în calculul probabilităţii timpului rămas înainte de următoarea sosire, nu se ia în considerare când a avut loc ultima sosire.

Notăm cu t_i momentul în care a sosit clientul numărul I şi presupunem că au trecut Y unităţi de timp înaintea momentului t_{i+1} la care urmează să sosească clientul i+1. Grafic avem

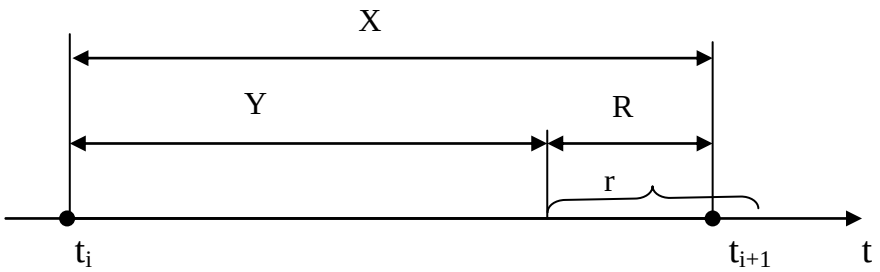

Ne propunem să calculăm probabilitatea ca clientul i+1 să sosească într-un interval r unităţi de timp.

Deci se cere calculul probabilităţii

P (R ≤ r | X ≥ Y) unde R = X – Y reprezintă timpul rămas până la următoarea sosire.

Ştim că $P(A \cap B) = P(A) \cdot P(B \mid A)$ de unde $P(B \mid A) = \dfrac{P(A \cap B}{P(A)}$

deci

$$P(R \le r \mid X \ge Y) = \frac{P(X \ge Y \cap R \le r)}{P(X \ge Y)} = \frac{P(Y \le X \le Y + r}{P(X \ge Y)} =$$

$$= \frac{P(X \le Y + r) - P(X < Y)}{1 - P(X < Y)} = \frac{1 - e^{\lambda(Y+r)} - 1 + e^{-\lambda Y}}{1 - (1 - e^{-\lambda Y})} =$$

$$= \frac{e^{-\lambda Y} - e^{-\lambda(Y+r)}}{e^{-\lambda Y}} = 1 - e^{-\lambda r}.$$

În concluzie timpul rămas până la proxima sosire nu depinde de timpul scurs până în momentul prezent, de la ultima sosire.

3.6 Simularea sistemelor reprezentabile prin șiruri de așteptare

Pentru a putea realiza operația de simulare aunui sistem reprezentabil prin activitățile care se desfășoară la nivelul acestuia sunt necesare două componente.

Prima componentă se referă la reprezentarea sistemului printr-un graf de activități interconectate în timp. Fiecare activitate este descrisă printr-un set de atribute prin intermediul cărora aceasta este particularizată în contextul sistemului în care este prezentă.

A doua componentă se referă la definirea clienților (cererilor) care solicită efectuarea activităților prezente în sistem , activități care sunt descrise de graful activităților care au loc în acesta. Dacă graful activităților reprezintă elementul static al modelului, cererile definesc un element mobil care trece dintr-o activitate în alta. De exemplu în contextul unui sistem care reprezintă procesul de servire la un bancomat activitățile sunt sosire clienți, așteptare, operare bancomat și plecare, în timp ce elementul mobil este definic de persoana care solicită efectuarea unei operații bancare la bancomatul în cauză. Ca și în cazul primei componente clientul

(cererea) este particularizată de un set de atribute care o definesc și o particularizează îcontextul multitudinii de cerei care fac apel la sistemul în cauză.

O imagine a celor două componente prezente în modelul de simulare a sistemul servire a unei cerei la un bancomt este prezentată în figura următoare.

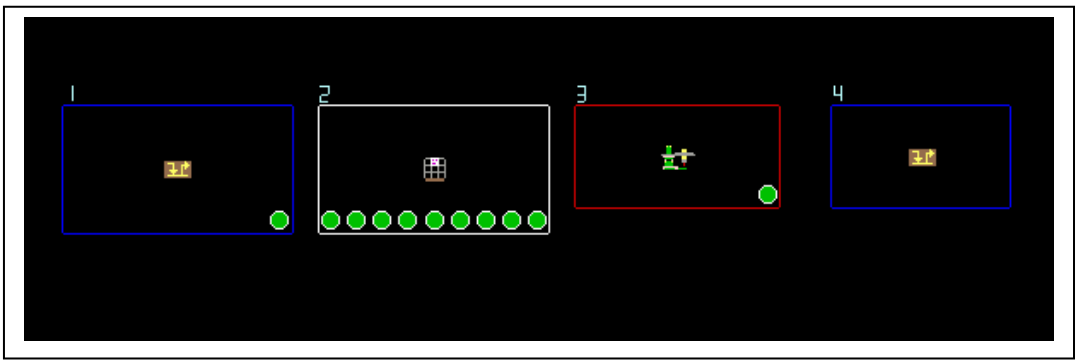

In figurăs e observă prezența celor 4 activități sosire clienți (blocul 1) așteptare (blocul 2) , operare la bancomat (blocul 3) plecare (blocul 4). Peste structura de activități reprezentată de cele 4 blocuri ale grafului activităților se suprapune fluxul de cereri de accesare a unei operații bancare, flux reprezentat grafic de elemntul mobil care se deplasează în graf reprezentat prin cercuri.