4. Concepte fundamentale de statistică în modelare şi simulare

Statistica este un domeniu al matematicii care se ocupa cu modul în care se colectează datele și cu analiza acestora.

4.1.Populaţie. Eşantion.

Acurateţea unui model depinde în mare măsură de culegerea, respectiv definirea datelor care urmează a fi utilizate pentru a caracteriza atributele entităţilor ce caracterizează sistemul modelat.

In ambele cazuri se face apel la o cantitate mare de date, aspect care ridică probleme legate de prelucrarea lor datorită resurselor de calcul limitate. Din aceste considerente se operează asupra unui set de date (restrâns) extras din cele primare disponibile. Ca urmare a acestei modalităţi de lucru se ridică doua probleme:

1. Cum se extrage setul de date care se va utiliza în cazul tehnicilor de modelare respectiv simulare
2. In ce măsura acesta este reprezentativ pentru datele primare din care a provenit.

Se defineşte :

- *Populaţia statistică* ca fiind mulţimea completă a tuturor datelor posibile ce caracterizează un fenomen sau proces.
- *Eşantion* dintr-o populaţie statistică reprezintă mulţimea datelor la care are acces utilizatorul. Un eşantion se spune că este reprezentativ, dacă dă o idee suficient de completă despre populaţia în cauză. Dacă nu există nici o informaţie apriorică despre

populaţie, singurul mod de a asigura reprezentativitatea este de a efectua o eşantionare aleatoare. Aceasta se realizează printr-un procedeu de randomizare. Presupunem că dorim să extragem 100 date dintr-o populaţie de 10000. Primul pas constă în a număra datele de la 0 la 9999. Utilizând o tabelă de numere aleatoare uniform repartizate de la 0 la 9999 vom putea selecta cele 100 date care ne interesează în mod aleatoriu.

Datorită caracterului aleatoriu al eşantionului, rezultă că orice informaţie care se face asupra unei populaţii pe baza analizei unui eşantion are, de asemenea, un caracter aleatoriu (statistic).

- Fiecare element din cadrul eşantionului (și deci din cadrul populaţiei din care a provenit acesta) este caracterizat de un set de atribute (un element din eşantionul ce provine din setul de informaţii dintr-o centrala de telefonie mobilă va avea ca atribute : durata convorbirii, ora de început / sfârşit convorbire, data convorbirii etc.). Valorile atributelor au un caracter aleatoriu indiferent de natura acestora (numerice, alfanumerice, booleene etc.) aspect care ne permite să discutăm în general despre aceste ca reprezentând *variabile aleatoare*.
- O *variabila aleatoare* este o mărime care în cadrul unui experiment (in cazul nostru un atribut a unui element din eşantion) ia valori diferite.

  Notăm cu **X** variabila aleatoare (de exemplu durata convorbire telefonica) și cu $\mathbf{x_1, x_2, \ldots, x_n}$ valorile pe care le poate lua această variabila aleatoare. Valorile luate de X pot fi :

  - *discrete* daca iau valori distincte, de exemplu [2, 9, 4, 11]

- *continue* daca iau valori intr-un interval, de exemplu [1, 20]

Aceste tipuri de valori au un caracter aleatoriu, deoarece nu pot fi prevăzute cu certitudine. Ca urmare avem doua tipuri de variabile:

Variabile aleatoare discrete – dacă se ia numai o valoare distinctă

Variabile aleatoare continue – dacă se ia o valoare într-un interval

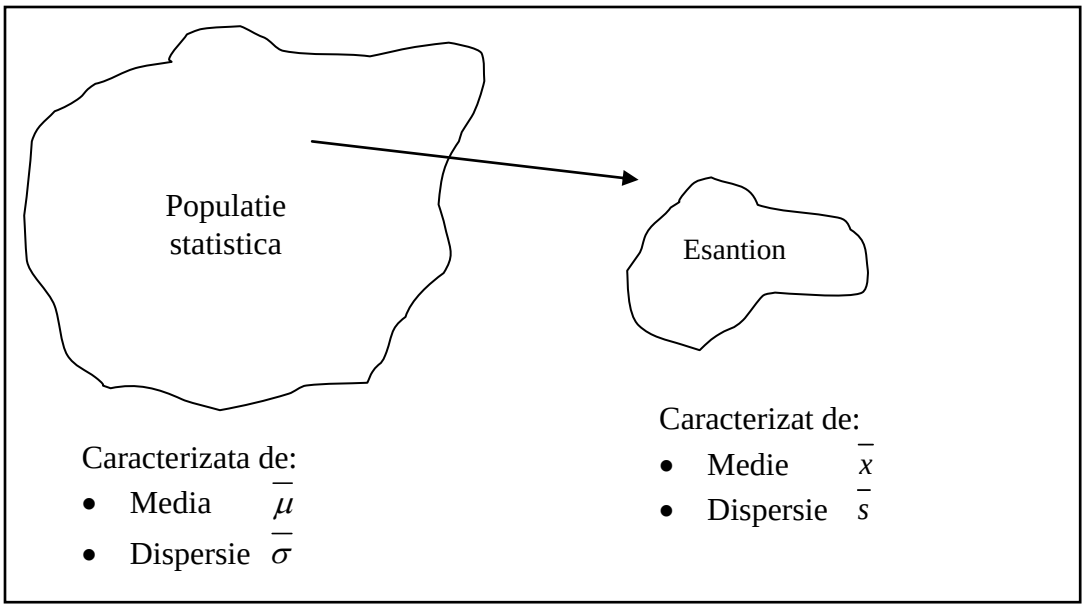

Important

Din punct de vedere statistic caracterizarea informaţiilor se poate face astfel:

1. **Static,** de o valoare medie și o dispersie a valorilor în jurul valorii medii. Astfel *populaţia* este definită de medie, notată cu μ și de dispersie notată cu σ, iar eşantionul este definit de medie notată cu $\bar{x}$ barat și de *dispersie* notată cu $\bar{s}$ barat. Atât $\bar{x}$ cât și $\bar{s}$ aproximează valoare medie și dispersia populaţiei.

2. **Dinamic** se specifică cum se modifica valorile datelor din populaţie și eşantion astfel încât să fie obţinute valorile medii și dispersia calculată. Modul în care se modifica valorile este definit de ceea ce poartă numele de *funcţie de distribuţie*.
3. Cele specificate mai sus se aplica valorilor atributelor ce caracterizează o dată, atât din eşantion cât și evident din populaţia statistică.

4.2. Reprezentarea statistică a datelor

Discuţia care urmează se referă la datele prezente în cadrul unui eşantion (de fapt singurele informaţii la care avem în mod real accesul). Pentru a ilustra conceptele pe care le vom discuta vom pleca de la un exemplu. Astfel în 1798 Henry Cavendish a estimat densitatea pământului utilizând o balanţă de torsiune pentru care a obţinut următoarele valori definite în tabelul de mai jos:

5.5	5.29	5.75
5.57	5.34	5.29
5.42	5.26	5.1
5.61	5.44	5.86
5.53	5.46	5.58
5.47	5.55	5.27
5.88	5.34	5.85
5.62	5.3	5.65
5.63	5.36	5.39
4.07	5.79	Notă Apa =1g/c^3 Granit =2.7 g/ c^3

Esantion

Aceste date reprezintă un eşantion din mulţimea datelor care se pot obţine printr-un număr oricât de mare de măsurători. Putem afirma ca densitatea pământului este o mărime care se modifică de la un experiment la altul și în consecință reprezintă o variabila aleatoare pe care o notăm cu ***X***. În contextul acestor măsurători, în număr de n=29 , o valoare o vom nota cu x_i (i = 1, 29).

4.2.1 Frecvenţa Relativă

Frecvenţa

Pentru a ajunge la conceptul de *frecvenţa relativă* vom introduce iniţial noţiunea de *frecvenţa*. Aceasta reprezintă numărul de valori care se găsesc intr-un interval dat. Pentru a calcula frecvenţa de apariţie în cadrul unui interval se procedează la sortarea datelor în ordine crescătoare a parametrului aflat în discuţie. Pentru cazul nostru vom obţine următorul tabel:

Densitatea în ordine crescătoare

1	4.07	8	5.3	15	5.46	22	5.61
2	4.88	9	5.34	16	5.47	23	5.62
3	5.10	10	5.34	17	5.5	24	5.63
4	5.26	11	5.36	18	5.53	25	5.65
5	5.27	12	5.39	19	5.55	26	5.75
6	5.29	13	5.42	20	5.57	27	5.79
7	5.29	14	5.44	21	5.58	28	5.85
						29	5.86

Valoarea acceptată a densităţii pământului este 5.50 g/c^3

Fier: 7.85 g/ c^3

Nichel:8.90 g/ c^3

Vom considera un interval de 0.25 și vom considera un număr de 9 intervale care plecă de la valoare minima (4.07) din tabelul de mai sus și vom număra câte valori sunt prezente în fiecare interval. Găsim următoarea situaţie

Histograma

Densitate	Frecvenţa
< 4	0
4 - 4.2	1
4.2 - 4.5	0
4.5 - 5	1
5 - 5.25	1
5.25 - 5.5	14
5.5 - 5.75	9
5.75 - 6	3
> 6	0
Total	29

Frecvența = 14 pentru densitatea pământului valori între 5.25 și 5.5

Trasând histograma pentru datele din tabelul anterior se va obţine:

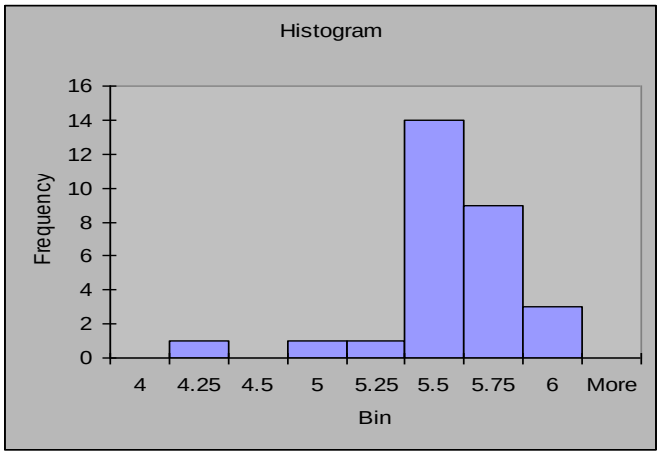

Frecvenţa relativă

Frecvenţa obţinută depinde de numărul total de observaţii. Se poate elimina aceasta dependenţă. Pentru aceasta se procedează la împărţirea numărului de valori aflate în fiecare interval la numărul total de valori.

Astfel n_x / n

defineşte frecvenţa valorilor eşantionului aflate în cadrul unui interval dat, frecvenţă care poartă numele de frecvenţă relativă. Pentru exemplul dat vom obţine:

Densitate	Frecvenţa	Frecvenţa Relativă
< 4	0	0
4 - 4.2	1	0.034483
4.2 - 4.5	0	0
4.5 - 5	1	0.034483
5 - 5.25	1	0.034483
5.25 - 5.5	14	0.482759
5.5 - 5.75	9	0.310345
5.75 - 6	3	0.103448
> 6	0	0
Total	29	1

Revenind la un concept fundamental din statistica matematica care spune ca:

Dacă un experiment este repetat de *n* ori (n foarte mare) și evenimentul A este observat de *b* ori *Probabilitatea* de apariţie a evenimentului A este

$$P(A)=b/n$$

Se observă imediat că Probabilitatea= frecvenţa relativă

Trasând histograma acestui tip de frecvenţă se obţine:

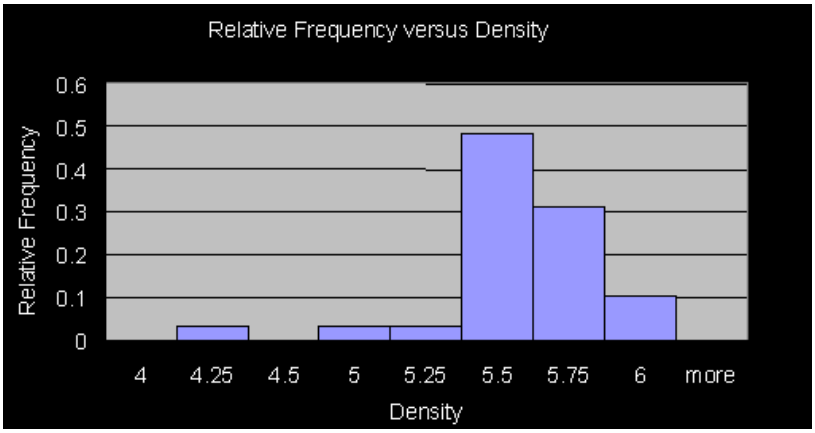

În această etapă se face următoarea observaţie:

Este mai importantă aria dreptunghiurilor decât înălţimea acestora (mai ales dacă clasele sunt diferite), deoarece ochiul uman reacţionează la arii şi nu la dimensiuni.

Se intenţionează ca aria dreptunghiurilor să definească frecvenţa relativă. În acest context, se procedează la împărţirea frecventei relative la lăţimea clasei, obţinând astfel ca aria să reprezinte frecvenţa relativă. Pentru exemplul dat vom avea:

Densitate	Frecvenţa	Frecvenţa Relativa = Probabilitate	Frecvenţa Relativa/Lăţimea clasei	Aria care defineşte frecvenţa relativă
< 4	0	0	0	0
4 - 4.2	1	0.03448	0.137931	0.03448275
4.2 - 4.5	0	0	0	0
4.5 - 5	1	0.03448	0.137931	0.03448275
5 - 5.25	1	0.03448	0.137931	0.03448275
5.25 - 5.5	14	0.48275	1.931034	0.482
5.5 - 5.75	9	0.31034	1.241379	0.31034475
5.75 - 6	3	0.10344	0.413793	0.02586
> 6	0	0	0	0
Total	29	1	4	

Pentru densitatea pământului valori între 5.25 și 5.5 avem :

- Frecvenţa Relativă / Lăţimea clasei =1.93
- Aria care definește frecvența relativă=1.93x0.25 = 0.482

Pentru acest caz, histograma care se obţine este de forma

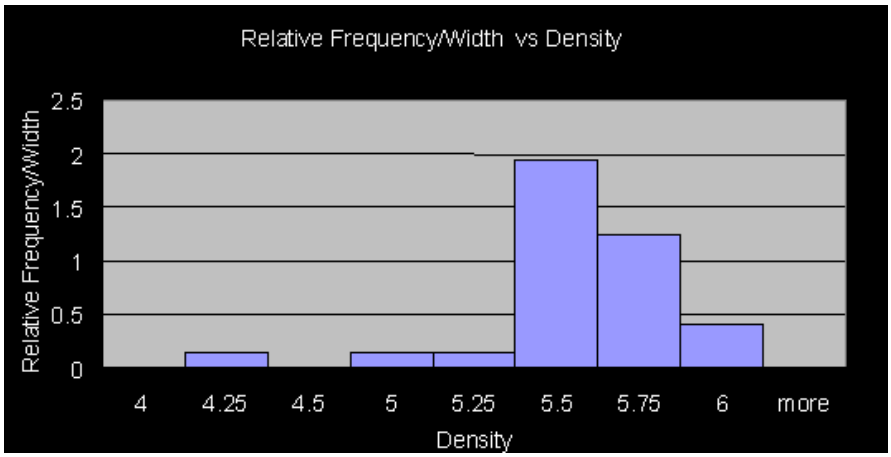

4.2.2 Funcţia de distribuţie

Aşa cum am specificat este important să caracterizăm și modul în care se modifică valorile eşantionului. Cu alte cuvinte, ne interesează dinamica acestora, modul în care aceste valori apar în succesiune una după alta. Pentru a obţine această dinamică se parcurg următorii paşi, primul fiind construirea a ceea ce poartă denumirea de frecvenţe cumulate.

- ***Frecvenţe cumulate***

Acestea se construiesc adunând frecventele relative care sunt mai mici decât limita superioara a clasei, cu alte cuvinte vom calcula

$$\sum n_k \leq \text{limita superioară a clasei k}$$

unde:

- ***k*** reprezintă clasa
- n_k definește frecvența relativă a clasei ***k*** (aria)

Pentru exemplul studiat vom obţine:

Clasa k	Densitate	Frecvenţa	Frecvenţa Relativa	Frecvenţa Relativa/ Lăţimea clasei	Aria care defineşte frecvenţa relativă n_k	Frecvente relative Cumulate
1	4	0	0	0	0	0
2	4.25	1	0.03448	0.13793	0.03448275	0.03448
3	4.5	0	0	0	0	0.03448
4	5	1	0.03448	0.13793	0.03448275	0.06896
5	5.25	1	0.03448	0.13793	0.03448275	0.10344
6	5.5	14	0.48275	1.93103	0.482	0.58620
7	5.75	9	0.31034	1.24137	0.31034475	0.89655
8	6	3	0.10344	0.41379	0.02586	1
	Mai mari	0	0	0	0	1
	Total	29	1	4		

Histograma care se obţine în acest caz, în care s-a reprezentat prin interpolare frecvențele cumulate, este de forma:

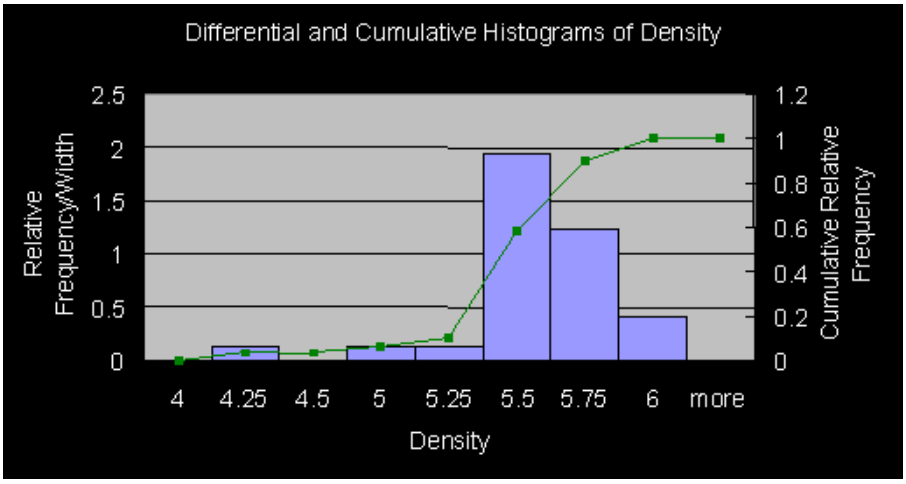

Din histograma se observa două proprietăţi remarcabile și anume:

- Pe ordonată avem probabilităţi astfel încât pentru o valoare a densităţii pământului mai mică decât o anumită valoare putem afla şansa de a fi posibilă. Astfel

$$f(X < x) = \text{Probabilitatea (densitatea} < 5.5) = 0.677$$

Motiv, pentru care funcţia obţinută mai sus poartă numele de *densitate de probabilitate* în cazul variabilelor continue și *distribuţie de probabilitate* in cazul variabilelor discrete.

- Un alt aspect care este remarcabil se refera la faptul că putem determina probabilitatea ca o valoare a densităţii pământului să se afle între anumite limite, însumând ariile prezente intre aceste limite. De exemplu:

$F(x_1 < X < x_2)$ = Probabilitatea (5.2 < densitatea < 5.5) = 0.05 + 0.91 = 0.916

- ***Funcţia de distribuţie . Densitate de probabilitate.***

Se observă că atunci când valorile eşantionului sunt foarte mari, la limită identice cu valorile populaţiei din care provine, se obţine funcția care reprezintă modul în care se modifică dinamic valorile populaţiei. Cu alte cuvinte, obţinem funcția care descrie modul în care variază valorile în cauza. Pentru aceasta, facem următoarele observaţii și procedăm după cum urmează:

- Aria fiecărui dreptunghi este egala cu frecvenţa relativa
- Se utilizează un număr mare de observaţii
- Reducem lăţimea dreptunghiului pana la o valoare foarte mica pe care o notăm cu *dx*
- și consideram ca înălţimea dreptunghiului reprezintă o valoare a unei funcții pe care o notăm cu *f(x)*
- Atunci aria dreptunghiului este *f(x)dx*

Histograma distribuţiei de probabilitate (variabila discretă)

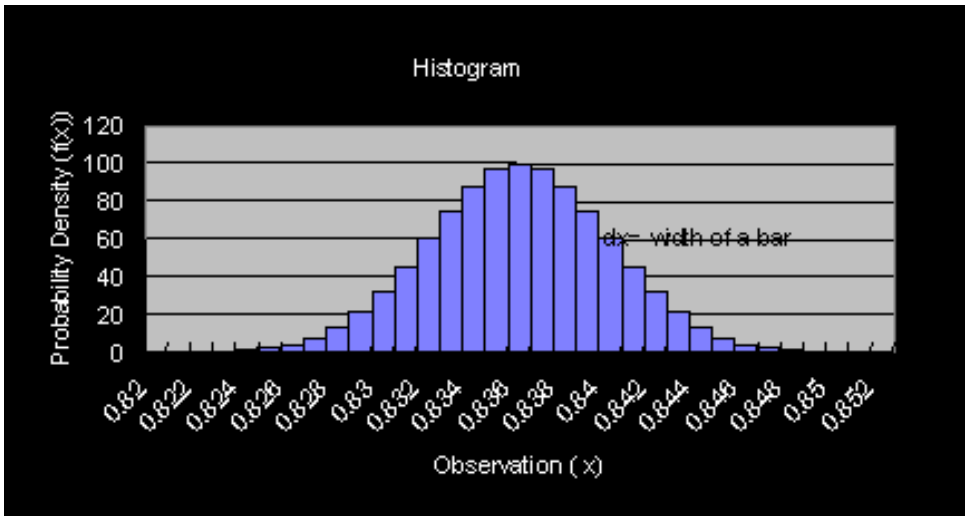

Funcţia densităţii de probabilitate (variabilă continuă)

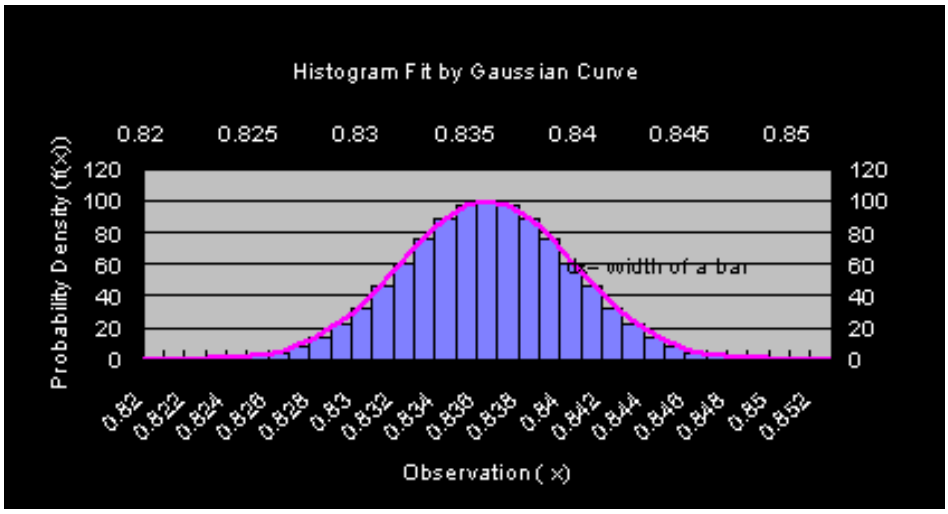

S-a calculat teoretic și s-a verificat experimental că distribuţia valorilor unei variabile aleatoare ce reprezintă o dată numerica dintr-o populaţie, indiferent dacă aceasta defineşte un atribut a unei date cât și data în sine, urmează o lege de distribuţie de forma specificată în figura de mai sus. Funcţia poartă numele de *distribuţie Gaussiană* și se exprimă prin relaţia

$$f(x) = \frac{1}{\sqrt{2\pi\sigma}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2} \right)$$

În care *f(x)* este probabilitatea de a observa o valoare a lui *x*, intru-un interval dat. Grafic această funcţie prezintă următorul aspect

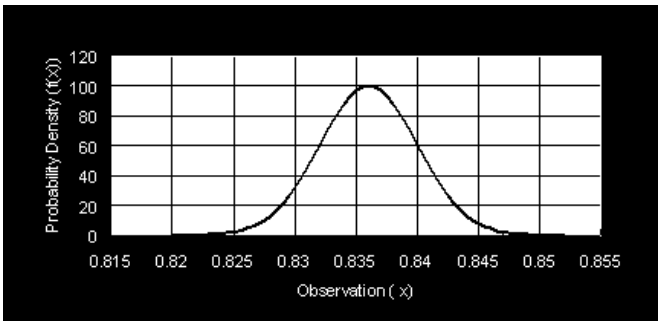

Există câteva observaţii care pot fi făcute referitoare la axa x și anume:

Aria de la μ- σ la μ+ σ este 0.6826
Aria de la μ- 2σ la μ+ 2σ este 0.9544
Aria de la μ-3 σ la μ+ 3σ este 0.9974
Aria totala de sub curbă este =1.0000

4.2.3 Media și Dispersia datelor

Aşa cum am specificat există un set de indici care caracterizează global datele din populaţie / eşantion. Acestea sunt:

- Valoarea medie a datelor
- Mediana
- Dispersia datelor

Valoarea Medie

Exprimă nivelul atins de o variabilă numerică când ea este uniform repartizată pe unităţile care compun o populaţie determinată. De obicei (se utilizează o distanță Euclidiană, dar se poate utiliza de exemplu și o distanță Manhattan), valoarea medie se referă la media aritmetică definită de relaţia :

$$\bar{x} = \frac{1}{n} \sum_{i=1}^{n} x_i$$

Media eşantionului reprezintă o aproximaţie a mediei μ a populaţiei din care provine

Mediana

Este valoarea situată la mijlocul eşantionului care are valori aranjate în ordine de mărime crescătoare sau descrescătoare. Ca urmare, mediana împarte eşantionul în două grupe egale ca număr. în jur de 50% din valorile ordonate ale densităţii sunt prezente sub mediana

Cazuri :

1) Pentru un eşantion cu un număr impar de valori (2k+1), mediana este valoarea de rangul k+1.

Ex : mediana seriei : 4 7 12 26 32 38 59

|

2) Pentru un eşantion cu un număr par de valori (2k), mediana se găseşte între valorile de rangul k și k+1, și în general se convine să fie reprezentată de media aritmetică a celor două valori.

Ex : mediana seriei : 4 7 12 26 32 38

└─┴─┘

|

(12+26) / 2

Dispersia datelor

Caracterizează variaţia ce predomină în eşantionul a cărui medie este cunoscută. Pentru o serie de valori individuale abaterea (dispersia datelor) este definită de expresia

$$s^2 = \frac{1}{n}\sum_{i=1}^{n}\left(x_i - \bar{x}\right)^2$$

Se procedează la ridicarea la pătrat, datorită faptului ca o serie de valori pot fi negative, respectiv mai mici decât valoarea medie, ceea ce face

ca diferenţa dintre o valoare particulară și medie să fie negativa, aspect care fără ridicarea la pătrat influențează valoarea adevărată a abaterii. Din acest considerent se recurge la calculul pătratului acestei abateri. Parametrul care se obţine poartă numele de *varianță*.

Pentru a obţine valoarea corectă a abaterii se extrage radicalul fiind astfel obţinută *dispersia*, altfel numită *deviaţia standard*. Aceasta este definită de expresia

$$\bar{s} = \frac{1}{n}\sqrt{\sum_{i=1}^{n}\left(x_i - \bar{x}\right)^2}$$

Pentru a ilustra conceptul de abatere și modul în care acesta se calculează se prezintă următorul exemplu:

Numărul valorii i	Valori variabilă aleatoare X	$x_i - \bar{x}$	$(x_i - \bar{x})^2$
1	35	-18.67	348.44
2	47	-6.67	44.44
3	48	-5.67	32.11
4	50	-3.67	13.44
5	51	-2.67	7.11
6	53	-0.67	0.44
7	54	0.33	0.11
8	70	16.33	266.78
9	75	21.33	455.11
Media variabilei aleatoare X notată cu $\bar{x}$ este	67	0	1168.00
Deviaţia standard notată cu $\bar{\sigma}$ este			12.08

Parametrii globali care caracterizează variabila aleatoare

Densitatea pământului (X)

Media	$\bar{x}$ =5.42	Deviaţia standard	$\bar{\sigma}$ =0.3388
Minimum	4.07	Maximum	5.86
Mediana	5.46	Lege de distribuție normală a valorilor	

Exemplu

Presupunem că dintr-o populaţie uniform distribuită în (0,100) extragem un număr de 4 eşantioane pentru care calculăm valoarea medie.

Nr. Eşantion	Eșantion Variabila aleatoare măsurată este X	Val. medie $\bar{x}$	Mediana
1	X_1 { 22, 92, 35, 63 }	53	49
2	X_2 { 97, 13, 34, 3, 77 }	45	34
3	X_3 { 45, 55, 37, 76, 83 }	59	55
4	X_4 { 15, 57, 44, 68 }	46	51

Întrebarea care se pune este următoarea:

Care este valoarea mediei care caracterizează populația din care provin cele 4 eșantioane , deoarece fiecare eșantion a furnizat o altă valoare medie. Pentru a avea o imagine cât mai corectă asupra valorii medii a populației se procedează astfel:

- Se extrag mai multe eșantioane. Operația este valabilă atât în cazul în care se efectuează măsurători pe un sistem real sau când se efectuează experimente de simulare cu un model. În această ultimă situație întotdeauna se vor efectua mai multe experimente de simulare.

- Se calculează valoare medie a mediilor variabilei aleatoare care definește un parametru al modelului. Se calculează de asemenea dispersia mediilor astfel obținute.
- Deoarece valorile obținute din măsurători au o distribuție normală, putem determina un interval în care se află valoarea adevărată a parametrului analizat cu un grad de certitudine dat.

  Pentru exemplul dat vom avea:

  - pentru valoarea medie

  $$\bar{x} = \frac{1}{n}\sum_{i=1}^{n} x_i \qquad \bar{x} = \frac{53+45+59+46}{4} = 50.75$$

  - pentru dispersie

  $$\bar{s} = \frac{1}{n-1}\sqrt{\sum_{i=1}^{n}\left(x_i - \bar{x}\right)^2}$$

  $$\bar{s} = \frac{1}{3}\sqrt{(53-50.75)^2 + (45-50.75)^2 + (59-50.75)^2 + (46-50.75)^2}$$

  $$\bar{s} = \frac{1}{3}\sqrt{(-2.25)^2 + (-5.75)^2 + (8.25)^2 + (4.75)^2}$$

  $$\bar{s} = \frac{1}{3}\sqrt{128.3375}$$

  $$\bar{s} = \frac{11.3283}{3} = 3.77$$

  Deoarece cunoaștem că legea de distribuție a valorilor medii obținute din măsurători pentru un același parametru este normal distribuită putem afirma că valoarea medie a parametrului care aparține populației este:

  $$\mu \in \left[\bar{x} \pm \bar{s}\right]$$
  $$\mu \in \left[50.75 - 3.77, 50.75 + 3.77\right]$$

Valoare medie a parametrului care aparține populației este calculată astfel

- Aria de la μ- σ la μ+ σ este 0.6826 deci

  $$\bar{\mu} \in \left[\bar{x}-\bar{s}, \bar{x}+\bar{s}\right] = \left[50.75-3.77, \quad 50.75+3.77\right] = \left[46.98, \quad 53.52\right]$$

  cu o probabilitate de 0.68
- Aria de la μ- 2σ la μ+ 2σ este 0.9544

  $$\bar{\mu} \in \left[\bar{x}-\bar{s}, \bar{x}+\bar{s}\right] = \left[50.75-7.54, \quad 50.75+7.54\right] = \left[43.21 \quad 58.29\right]$$

  Cu o probabilitate de 0.95

Concluzii

1) Întotdeauna se operează pe un eşantion de date, deoarece cantitatea primară de date este mult prea vastă pentru a putea fi prelucrată.
2) Eşantionul este caracterizat de un set de parametrii globali și de o lege de variaţie a datelor. Ambii se raportează la întreaga populaţie, fiind utilizaţi pentru caracterizarea acesteia.
3) Funcţia densităţii de probabilitate și distribuţia de probabilitate sunt ambele ilustrate de histograme.