5. Modele Markov.

5.1 Principii.

Vom pleca de la un exemplu simplu pentru a specifica ce este un model Markov. Acesta reprezintă sisteme, în care starea viitoare în care se poate afla sistemul este determinată de starea curentă a acestuia. Aceste sisteme au fost studiate pentru prima dată de matematicianul rus Andrei Markov și din acest considerent denumirea procesului care descrie dinamica sistemului în timp poartă numele de **proces Markov** iar modelul care poate descrie o astfel de evoluție, **lanț Markov** sau **model Markov**.

Exemplu 1. Pieton aleator.

Considerăm un "*pieton aleator*" într-un oraș mic, care are numai 4 străzi și 4 colțuri de stradă v_1, v_2, v_3, v_4 aranjate ca în figura următoare:

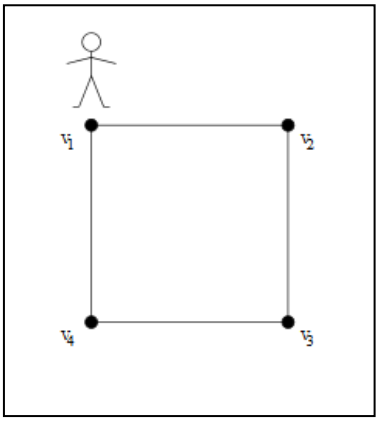

La momentul 0 , pietonul stă în colțul de stradă v_1,. La momentul 0 aruncă o monedă în aer și după cum cade, cap sau stemă se deplasează la v_2 sau v_4. Alegerea de deplasare la următorul colț de stradă este *în sens orar dacă este cap* și *trigonometric dacă este stemă*. Această procedură este utilizată pentru toate momentele de timp $n = 0, 1, 2, 3, \ldots$.

Notăm cu X_n o variabilă care să definească colțul de stradă unde este prezent pietonul la momentul de timp n. În acest context mulțimea (X_0, X_1, X_2, …..) va defini un proces aleator care ia valori din mulțimea {1, 2, 3, 4}.

Deoarece pietonul începe să se deplaseze la momentul de timp 0 fiind prezent în v_1, vom avea

$$P(X_0 = 1) = 1 \tag{1}$$

La următorul moment de timp pietonul se va putea deplasa la v_2 sau v_4 cu probabilitatea ½ fiecare astfel că

$$P(X_0 = 2) = \frac{1}{2} \text{ și } P(X_0 = 4) = \frac{1}{2} \tag{2}$$

Să luăm în considerare un alt aspect. Presupunem că la momentul de timp n , pietonul este la v_2.

Putem scrie că

$$P(X_{n+1} = v_1 \mid X_n = v_2) = \frac{1}{2} \tag{3}$$

$$P(X_{n+1} = v_3 \mid X_n = v_2) = \frac{1}{2} \tag{4}$$

Datorită mecanismului de alegere a sensului de deplasare pe care pietonul l-a adoptat, se poate lua în considerare întregul istoric al deplasării în oraș de forma

$$P(X_{n+1} = v_1 \mid X_0 = i_0, X_1 = i_1, ..., X_{n-1} = i_{n-1}, X_n = v_2) = \frac{1}{2} \tag{5}$$

și

$$P(X_{n+1} = v_3 \mid X_0 = i_0, X_1 = i_1, ..., X_{n-1} = i_{n-1}, X_n = v_2) = \frac{1}{2} \tag{6}$$

pentru orice alegere din i_0, i_1, ……i_{n-1}.

Această afirmație este corectă, deoarece o aruncare a monedei în pasul $n+1$ este independentă de toate cele n aruncări anterioare X_0, X_1, X_2, ….., , X_n. Acest fenomen este cunoscut sub denumirea de *lipsă de memorie* sau *proprietate Markov* iar sistemul în care apare acest fenomen este cunoscut sub denumirea de *sistem cu proprietate Markov*.

- Acesta proprietate spune că distribuția de valori pentru X_{n+1} dată de istoricul valorilor din stările trecute $X_0, X_1, X_2, \ldots, , X_n$ depinde numai de valoarea obținută în starea X_n . Cu alte cuvinte pentru a fi posibil de **prevăzut** ce se va întâmpla "*mâine*" (timpul *n+1*) este necesar să cunoaștem ce se întâmplă "*azi*" (timpul *n*) iar "*trecutul – istoricul*" (timpul *0, 1, ..., n-1*) nu ne furnizează nici o informație utilă.
- Altă proprietate interesantă a unui proces aleatoriu este aceea că distribuția de valori pentru X_{n+1} depinde numai de valorile din starea precedentă X_n fiind aceeași pentru toate momentele de timp *n* , (aceasta deoarece mecanismul prin care pietonul ia decizii în fiecare moment de timp *n* este același). Această proprietate este cunoscută ca omogenitate a unui proces Markov sau pe scurt *omogenitate*.

Definiție

Fie P o matrice de dimensiune (k x k) cu elemente $\{P_{i,j} : i, j = 1, \ldots, k\}$. *Un proces aleator* $(X_0, X_1, \ldots)$ *cu stări finite din spațiul* $S=\{s_1, s_2, \ldots s_k\}$ *se spune că este un* ***lanț Markov omogen cu matricea de tranziție*** *P, dacă pentru toți n, toți* $i,j \in \{1, 2, \ldots, k\}$ *si toți* $i_0, \ldots, i_{n-1} \in \{1,2,..k\}$ *avem*

$$\begin{aligned} &P\left(X_{n+1} = s_j \mid X_0 = s_0, X_1 = s_1, \ldots, X_{n-1} = s_{n-1}, X_n = s_n\right) \\ &= P\left(X_{n+1} = s_j \mid X_n = s_i\right) \\ &= P_{i,j}. \end{aligned} \tag{7}$$

Elementele matricei de tranziție poartă numele de ***probabilități de tranziție***. Probabilitatea de tranziție P_{ij} este probabilitatea ca să fim în starea s_j "*mâine*" atunci când suntem în starea s_i "*azi*".

Termenul omogen se referă la faptul că indiferent de starea în care se găsește sistemul se utilizează aceeași procedură trecere dintr-o stare în alta. Atunci când se vorbește despre *lanț Markov* proprietatea de *omogen* este implicită și se omite.

De exemplu pentru un "*pieton aleator*" acesta poate fi definit de un lanț Markov unde spațiul stărilor este {1, . . .,4} și matricea de tranziție

$$\begin{bmatrix} 0 & 0.5 & 0 & 0.5 \\ 0.5 & 0 & 0.5 & 0 \\ 0 & 0.5 & 0 & 0.5 \\ 0.5 & 0 & 0.5 & 0 \end{bmatrix} \tag{8}$$

O modalitate curentă de reprezentare a unui lanț Markov este grafică prin intermediul unui **graf de tranziție**. Un graf de tranziție (matricea probabilităților de tranziție) constă din noduri care definesc stările unui lanț Markov, iar arcele dintre noduri vor reprezenta probabilitățile de tranziție. Pentru exemplul dat definit prin matricea (8) vom avea următoarea reprezentare

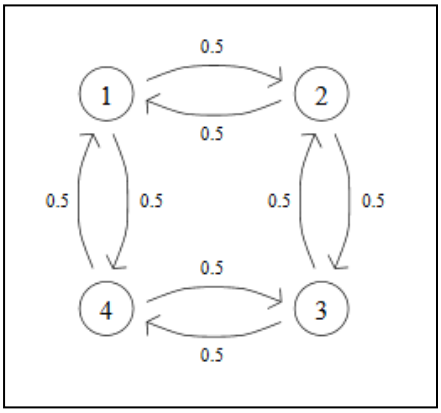

Fiecare matrice de tranziție satisface următoarele condiții

$$P_{i,j} \geq 0 \text{ pentru toți } i, j \in \{1,\ldots.k\}, \tag{9}$$

$$\sum_{j=1}^{k} P_{i,j} = 1 \text{ pentru toți } i \in \{1,\ldots.k\} \tag{10}$$

Proprietatea (9) specifică faptul că toate probabilitățile de tranziție sunt pozitive ia proprietatea (10) că suma lor este întotdeauna 1.

Să luăm în considerarea o altă caracteristică importantă a unui lanț Markov care poartă denumirea de **distribuție inițială.** Aceasta specifică starea inițială a unui lanț Markov, fiind reprezentată de un vector $\mu^{(0)}$ dat de

$$\mu^{(0)} = \left(\mu_1^{(0)}, \mu_2^{(0)}, ..., \mu_k^{(0)}\right)$$
$$= \left(P\left(X_0 = s_1\right), P\left(X_0 = s_2\right), ...P\left(X_0 = s_k\right)\right)$$

Deoarece $\mu^{(0)}$ reprezintă o distribuție de probabilitate vom avea

$$\mu^{(n)} = \mu^{(0)} \times P^n \tag{11}$$

Pentru exemplul dat al "*pieton aleator*" vom avea

$$\mu^{(0)} = (1, 0, 0, 0) \tag{12}$$

Similar vectorul linie $\mu_1^{(n)}, \mu_2^{(n)}, ..., \mu_k^{(n)}$ va defini distribuția unui lanț Markov la momentele de timp 1,2,…,n astfel încât

$$\mu^{(n)} = \left(\mu_1^{(n)}, \mu_2^{(n)}, ..., \mu_k^{(n)}\right)$$
$$= \left(P\left(X_n = s_1\right), P\left(X_n = s_2\right), ...P\left(X_n = s_k\right)\right)$$

Pentru "*pieton aleator" din exemplul ,* ecuațiile (3) și (4) specifică faptul că

$$\mu^{(1)} = (0, 0.5, 0, 0.5)$$

Revenind la exemplul dat se observă că cunoscând distribuția inițială $\mu^{(0)}$ și matricea de tranziție P se pot calcula toate distribuțiile $\mu^{(1)}, \mu^{(2)}, ...$ a unui lanț Markov. Această observație face ca calculul distribuției să se reducă la o simplă multiplicare de matrice. Convenim să scriem P^n pentru a specifica putere a *n* a acestei matrice

Teoremă 1

Pentru un lanț Markov $(X_0, X_1, ...)$ cu spațiul de stări $\{s_1, ..., s_k)$, distribuția inițială $\mu^{(0)}$ și matricea de tranziție P, vom avea pentru orice *n* distribuția $\mu^{(n)}$ la momentul de timp n care satisface relația

$$\mu^{(n)} = \mu^{(0)} \times P^n \tag{13}$$

Demonstrație

Considerăm primul caz în care n-1. Vom obține pentru j=1,..,k că

$$\mu_j^{(1)} = \quad P\left(X_1 = s_j\right) = \sum_{i=1}^{k} P\left(X_0 = s_i, X_1 = s_j\right)$$
$$= \sum_{i=1}^{k} P\left(X_0 = s_i\right) P\left(X_1 = s_j \mid X_0 = s_i\right)$$
$$= \sum_{i=1}^{k} \mu_i^{(0)} P_{i,j} = \left(\mu^{(0)} P\right)_j$$

Unde $\left(\mu^{(0)} P\right)_j$ reprezintă cel de al *j* element din vectorul linie $\mu^{(0)} P$.

Deci $\mu^{(1)} = \mu^{(0)} P$

Pentru a demonstra ecuația (13) se va utiliza inducția. Considerăm momentul de timp *n=m*. Pentru momentul de timp ulterior *n=m+1* se va obține

$$\mu_j^{(m+1)} = \quad P\left(X_{m+1} = s_j\right) = \sum_{i=1}^{k} P\left(X_m = s_i, X_{m+1} = s_j\right)$$
$$= \sum_{i=1}^{k} P\left(X_m = s_i\right) P\left(Xm+_1 = s_j \mid X_m = s_i\right)$$
$$= \sum_{i=1}^{k} \mu_i^{(m)} P_{i,j} = \left(\mu^{(m)} P\right)_j$$

Astfel încât $\mu^{(m+1)} = \mu^{(m)} P$. Dar $\mu^{(m)} = \mu^{(0)} P^m$ și prin recurență obținem $\mu^{(m+1)} = \mu^{(m)} P = \mu^{(0)} P^m P = \mu^{(0)} P^{m+1}$

Exemplu 2: Predicție vreme

Se afirmă că cel mai simplu mod de a prevedea vremea de mâine este acela de a ști cum este vremea azi. Să presupunem că această afirmație este corectă aspect care face ca modelul firesc pentru predicția vremii este de tip lanț Markov. Pentru simplificare să presupunem că luăm numai trei tipuri de vreme: Înnorat, Plouă și Soare. În acest caz spațiul avem

- stărilor este *S = { s1 = „Înorat”, s2 = „Plouă” și s3 = „Soare”}*

- Matricea de tranziție
- Care în cazul general este de forma

$$A=\begin{bmatrix} a_{11} & a_{12} & .... & a_{1j} & .... & a_{1N} \\ a_{21} & a_{22} & .... & a_{2j} & ..... & a_{2N} \\ . & . & . & . & . & . \\ a_{i1} & a_{i2} & .... & a_{ij} & .... & a_{iN} \\ . & . & . & . & . & . \\ a_{N1} & a_{N2} & .... & a_{Nj} & .... & a_{NN} \end{bmatrix} \text{ unde } \quad \begin{array}{ll} a_{ij}=P\left(q_t=j\,|\,q_{t-1}=i\right) & 1\le i,j\le N \\ \text{cu: } \quad a_{ij}>0 & \forall i,j \\ \sum_{j=1}^{N} a_{ij}=1 & \forall i \end{array}$$

Pentru cazul particular din exemplu avem

$$[A]=\begin{array}{c} \begin{array}{ccc} \text{Înnorat} & \text{Plouă} & \text{Soare} \end{array} \\ \begin{bmatrix} 0.4 & 0.3 & 0.3 \\ 0.2 & 0.6 & 0.2 \\ 0.1 & 0.1 & 0.8 \end{bmatrix} \end{array} \begin{array}{l} \text{Înorat} \\ \text{Plouă} \\ \text{Soare} \end{array} \quad \text{unde} \quad \begin{array}{l} a_{13}=P\left(q_t=\text{Soare}\,|\,q_{t-1}=\text{Înnorat}\right)=0.3 \\ a_{32}=P\left(q_t=\text{Plouă}\,|\,q_{t-1}=\text{Soare}\right)=0.1 \end{array}$$

Se cere

Calculați care este probabilitatea de a avea *SSSPPSÎS* dacă astăzi este *S*.

Starea inițială este dată de $\pi = P(S) = 1$

Rezolvare

Probabilitatea de a avea evenimentul A care sa succeadă după evenimentul B este

$$P(A,B)=P(A\,|\,B)P(B)$$

Modelul Markov care surprinde aceasta succesiune in care cu $q_{k,k=\overline{1,n}}$ s-a notat probabilitatea de a avea un eveniment de tip *{Î,P,S}* la momentele de timp 1,2,….n. Cu

$$\begin{aligned} &P\left(q_{1,}q_{2,}.....q_n\right) \\ &\quad = P\left(q_{n,}\,|\,q_{1,}q_{2,}.....q_{n-1,}\right)P\left(q_{1,}q_{2,}.....q_{n-1,}\right) \\ &\quad = P\left(q_n\,|\,q_{n-1}\right)P\left(q_{1,}q_{2,}.....q_{n-1}\right) \\ &\quad = P\left(q_n\,|\,q_{n-1}\right)P\left(q_{n-1}\,|\,q_{n-2}\right)P\left(q_{1,}q_{2,}.....q_{n-2}\right) \\ &\quad = P\left(q_n\,|\,q_{n-1}\right)P\left(q_{n-1}\,|\,q_{n-2,}\right).....P\left(q_2\,|\,q_1\right)P\left(q_1\right) \end{aligned}$$

Pentru secvența O = (SSSPPSÎS)

$$
\begin{aligned}
&P(O \mid \text{model}) \\
&\quad = P(S,S,S,P,P,S,\hat{I},S \mid \text{model}) \\
&\quad = P(S)P(S \mid S)P(S \mid S)P(P \mid S)P(P \mid P)P(S \mid P)P(\hat{I} \mid S)P(S \mid \hat{I}) \\
&\quad = \pi a_{33} a_{33} a_{31} a_{11} a_{13} a_{32} a_{23} \\
&\quad = (1)(0.8)(0.8)(0.1)(0.4)(0.3)(0.1)(0.2) = 1.536 \times 10^{-4}
\end{aligned}
$$