9. Tehnici de modelare Monte - Carlo

Bazele teoretice ale metodei au fost puse în anul 1949 de Metropolis şi Ulam[1], dar ideea acestor metode a apărut încă din 1777 când Buffon a formulat celebra problemă a calculului probabilităţii de intersecţie a unui ac aruncat la întâmplare, pe o suprafaţă plană pe care sunt trasate drepte paralele echidistante. Aceasta idee în 1860 ia permis lui Barbier sa calculeze numărul π prin aruncări succesive ale unui ac de lungime $\boldsymbol{l}$, pe o suprafaţă plană cu drepte paralele la echidistanta $\boldsymbol{2l}$. Fermi, Metropolis şi Ulam au folosit *metoda experimentărilor statistice*, la studiul difuziei neutronilor în materialele fisionabile. In acest scop au utilizat listele de numere întâmplătoare (rezultate in jocul de ruleta) care se publicau la Monte - Carlo. De aici a rezultat cea mai răspândită denumire a metodei. În SUA, metoda a mai fost cunoscută şi sub denumirea de "*metoda Las Vegas*". În literatura de specialitate se întâlnesc următoarele denumiri echivalente: *metoda încercărilor echivalente*; *metoda experimentărilor statistice; simularea numerică; metoda simulării indirecte; metoda numerelor aleatoare.*

Termenul de "*Metoda Monte - Carlo*" se utilizează pentru a desemna două tehnici diferite.

1. Prima tehnică constă în evaluarea integralelor definite prin utilizarea variabilelor aleatoare.
2. Al doilea sens al "*metodei Monte - Carlo*" presupune înlocuirea unui fenomen real cu un experiment statistic.

1. Nicholas Metropolis; S. Ulam, *The Monte Carlo Method*, Journal of the American Statistical Association, Vol. 44, No. 247. (Sep., 1949), pp. 335-341.

9.1 Evaluarea integralelor definite prin tehnica Monte Carlo.

Principiul metodei de calcul Monte Carlo (MC)

Principiul metodei Monte Carlo de calcul este ilustrat de calculul valorii numărului π din figura următoare și constă în următoarele

$$\text{aria patratului} = (2r)^2$$

$$\text{aria cercului} = \pi r^2$$

$$\frac{\text{aria patratului}}{\text{aria cercului}} = \frac{4r^2}{\pi r^2} = \frac{4}{\pi}$$

$$\pi = 4 \times \frac{\text{aria cercului}}{\text{aria patratului}} \quad \text{unde}$$

$$\frac{\text{aria cercului}}{\text{aria patratului}} = \frac{\text{numar de puncte in interiorul cercului}}{\text{numarul total de puncte}}$$

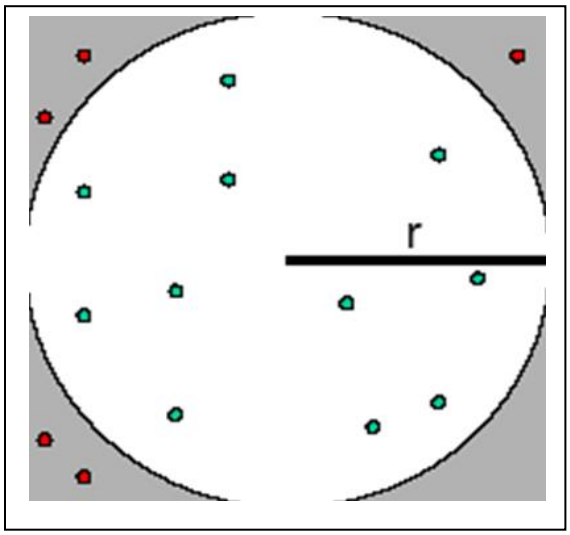

Ca urmare

- Se generează puncte uniform repartizate *(x_i, y_i)* în spațiul definit de pătratul de dimensiune ***2r x 2r***. Notăm cu ***N*** numărul de puncte generate. Generarea de puncte de coordonate *(x_i, y_i)* presupune generarea de coordonate x_i respectiv y_i în intervalul [0, 2r] urmând o lege de distribuție uniform repartizată.

- Notăm cu ***S*** numărul de puncte care cad în interiorul suprafeței delimitate de cerc. Acest contor se incrementează cu 1 dacă punctul de coordonate *(x_i, y_i)* generat îndeplinește condiția $x_i^2 + y_i^2 \le r^2$.
- După generarea unui număr de ***N*** puncte valoarea constantei π va fi dată de relația

$$\pi = 4 * \frac{S}{N}$$

Prin creșterea numărului de puncte în spațiul definit de pătrat vom obține următoarele valori estimative

N	PI
1000	3.13200000
2000	3.14200000
3000	3.10800000
4000	3.11800000
5000	3.13040000
6000	3.12266667
7000	3.15142857
8000	3.12450000
9000	3.15333333
10000	3.15600000
Valoarea exactă	3.14159265

Estimarea poate fi îmbunătățită prin efectuarea unui număr de experimente independente (independența fiind realizată prin utilizarea de diferite secvențe de numere aleatoare uniform distribuite) și calculul valorii medii. De exemplu efectuând un număr de 1000 măsurători independente s-a obținut

N = 10000 m = 1000 PI = 3.14140240

I. Calculul valorii unei integrale prin tehnica Monte Carlo.

Metoda hit-or-miss.

Obiectivul metodei este acela de a calcula

$$y = \int_a^b f(x)dx \quad \text{unde} \quad a, b \in R$$

În așa numita metodă "hit-or-miss" de integrare Monte Carlo, integrala este estimată prin desenarea unei dreptunghi care delimitează funcția $f(x)$ în intervalul [a, b]. Dreptunghiul se extinde de la a b și de la 0 la f_{max}, unde $f_{\max} > f(x)$ în intervalul dat. Se generează N puncte aleatoriu în cadrul dreptunghiului. Estimarea integralei poate fi obținută raportând numărul total de puncte N_0 care apar sub curba $f(x)$ la N.

$$I_{est} = \frac{N_0}{N} A$$

unde $A = (b-a) f_{\max}$ este aria dreptunghiului.

Fiecare din cele N puncte aleatoare se obține prin generarea a generarea a două valori numerice s_1 și s_2 uniform distribuite și calcularea a două coordonate x, respectiv y de forma

$$x = a + s_1 * (b-a)$$
$$y = s_2 * f_{\max}$$

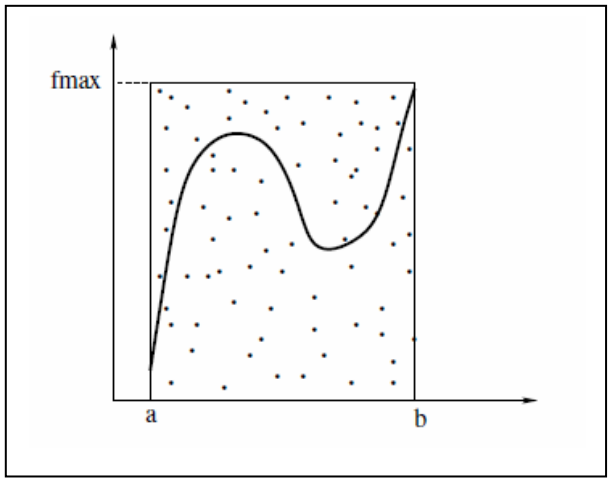

Figura 1. Hit-or-miss MC. Punctele sunt generate aleator în spațiul definit de aria dreptunghiulară care delimitează funcția $f(x)$ în intervalul [a, b] . Numărul de puncte de sub curbă este utilizat pentru calculul integralei.

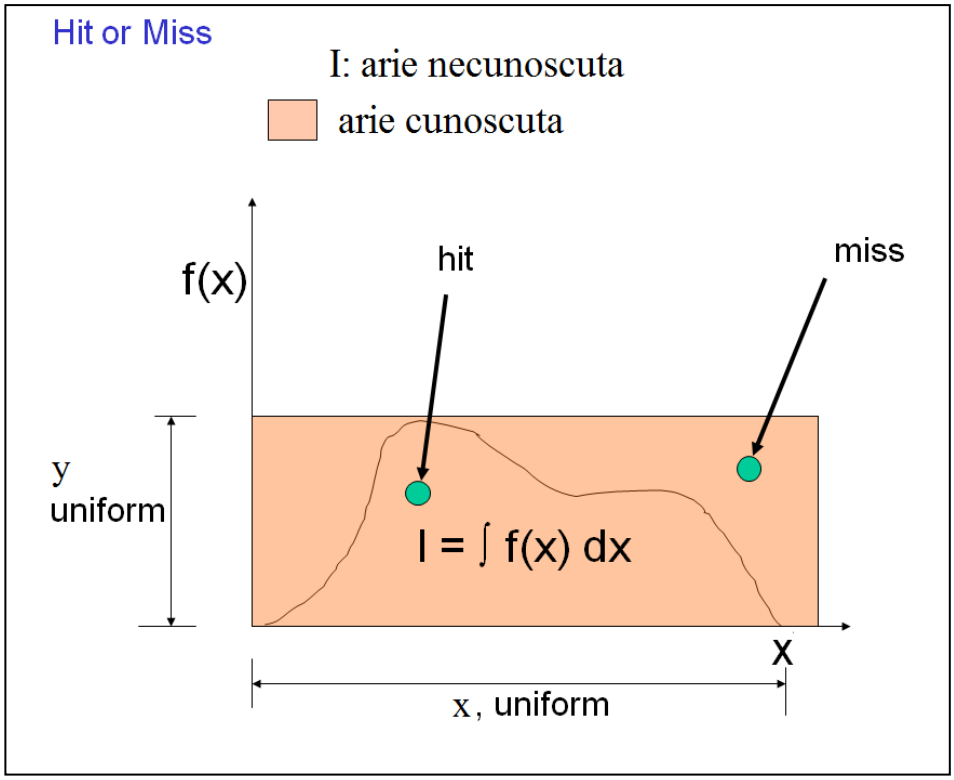

Estimarea valorii integralei va crește în precizie dacă $N \to \infty$ și va converge spre un răspuns corect. Trebuie specificat că calitatea răspunsului obținut depinde de calitatea generatorului de numere aleatoare care se utilizează.

Etapele care se parcurg pentru calculul integralei prin această metodă sunt

- Se generează puncte uniform repartizate (x_i, y_i) în spațiul definit de dreptunghi de dimensiune *b-a* * *ymax* - *ymin*. Notăm cu ***N*** numărul de puncte generate. Generarea de puncte de coordonate (x_i, y_i) presupune generarea de coordonate x_i în intervalul [a, b], respectiv y_i în intervalul [ymin, ymax] urmând o lege de distribuție uniform repartizată.

- Notăm cu ***S*** numărul de puncte care cad în interiorul suprafeței delimitate de f(x). Acest contor se incrementează cu 1 dacă punctul de coordonate *(x_i, y_i)* generat îndeplinește condiția $y_i \le f(x_i)$.
- După generarea unui număr de ***N*** puncte valoarea constantei integralei va fi dată de va fi dată de relația

$$I = (y_{\max} - y_{\min}) * (b - a) * \frac{S}{N}$$

- Dacă o parte a funcției este sub axa x ca în figura următoare vom avea

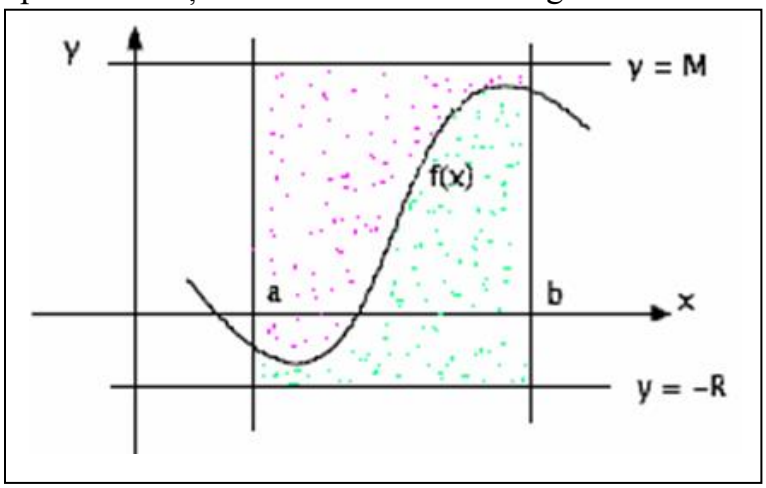

$$\frac{S}{N} = \frac{\text{aria de sub curba f(x)}}{\text{aria totala}} = \frac{\int_a^b f(x)\,dx}{(M+R)(b-a)}$$

$$\int_a^b f(x)\,dx = (M+R)(b-a)\frac{S}{N}$$

Această relație va trebui corectată deoarece linia y=-R s-a utilizat ca linie de bază pentru calculul suprafeței în loc de linia y=0 ca în cazul anterior. Pentru aceasta se va scădea aria R(b-a) din valoarea obținută. Se va obține în final

$$\int_a^b f(x)\,dx = (M+R)(b-a)\frac{S}{N} - R(b-a)$$

Metoda ***Monte Carlo hit-or-miss***, poate fi extinsă pentru calculul unei integrale multiple. De exemplu dacă considerăm o integrală de forma

$$I = \int_{a_1}^{a_2}\int_{b_1}^{b_2}\int_{c_1}^{c2} f(x,y,z)dxdydz$$

Care definește un volum într-un spațiu cu 3 dimensiuni o valoare estimativă se va putea calcula de forma

$$\begin{aligned} I &= \int_{a_1}^{a_2}\int_{b_1}^{ab}\int_{c_1}^{c2} f(x,y,z)dxdydz \\ &= \int_{a_1}^{a_2}\left[\int_{b_1}^{b_2}\left(\int_{c_1}^{c_2} f(x,y,z)\,dx\right)dy\right]dz \\ &\approx (a_2-a_1)(b_2-b_1)(c_2-c_1)\frac{N_0}{N} \end{aligned}$$

unde (x_i, y_i, z_i) este un punct aleator în spațiul tri dimensional definit de paralelipipedul $(a_2-a_1)\times(b_2-b_1)\times(c_2-c_1)$. În total vom avea nevoie de ***3N*** numere aleatoare pentru a genera ***N*** puncte aleatoare. N_0 se obține incrementând cu 1 acest contor dacă condiția $f(x_i, y_i, z_i) < 0$ este îndeplinită

Metoda sample-mean.

O altă tehnică simplă de calcul MC este dată de "**sample-mean**". Aceasta presupune obținerea unui eșantion ***N*** de valori *x* uniform distribuite din intervalul [a, b]. Aceste valori sunt utilizate pentru obținerea unei valori estimative pentru integrală de forma

$$I_{est} = (b-a)\frac{1}{N}\sum_{i=1}^{n} f(x_i)$$

În acest mod vom aproxima integrala prin media unui număr de N valori de forma $f(x_1), f(x_2), f(x_3), \ldots\ldots, f(x_N)$. Și în acest caz estimarea este cu atât mai bună cu cât

eșantionul de numere aleatoare x_i este mai mare. Această estimare va converge la rezultatul corect atunci când $N \to \infty$.

Metoda MC "sample-mean", poate fi extinsă pentru calculul unei integrale multiple. De exemplu dacă considerăm o integrală de forma

$$I = \int_{a_1}^{a_2} \int_{b_1}^{b_2} \int_{c_1}^{c2} f(x, y, z) dxdydz$$

Care definește un volum într-un spațiu cu 3 dimensiuni o valoare estimativă se va putea calcula de forma

$$\begin{aligned} I &= \int_{a_1}^{a_2} \int_{b_1}^{b_2} \int_{c_1}^{c2} f(x, y, z) dxdydz \\ &= \int_{a_1}^{a_2} \left[\int_{b_1}^{b_2} \left(\int_{c_1}^{c_2} f(x, y, z) dx \right) dy \right] dz \\ &\approx (a_2 - a_1)(b_2 - b_1)(c_2 - c_1) \frac{1}{N} \sum_{i=1}^{N} f(x_i, y_i, z_i) \end{aligned}$$

unde (x_i, y_i, z_i) este un punct aleator în spațiul tri dimensional definit de paralelipipedul $(a_2 - a_1) \times (b_2 - b_1) \times (c_2 - c_1)$. În total vom avea nevoie de 3N numere aleatoare pentru a genera N puncte aleatoare.

Calculul volumelor.

Tehnica MC dă posibilitatea calculului unor regiuni complicate dintr-un spațiu tri dimensional. Pentru a ilustra tehnica MC considerăm volumul unei regiuni a cărei puncte satisfac condiția

$$\begin{cases} 0 \le x \le 1 \quad 0 \le y \le 1 \quad 0 \le z \le 1 \\ x^2 + \sin y \le z \\ x - z + e^y \le 1 \end{cases}$$

Prima linie definește un cub de volum 1. Cele două inegalități definesc un volum care este un subset al cubului. În acest caz se poate aplica metoda "hit-or-miss" prin generarea

de ***N*** puncte în interiorul cubului și determinarea punctelor care definesc cele două inegalități (***N₀***). În acest caz estimarea volumului cerut este dată de $\frac{N_0}{N}$. În Figura 2 se prezintă valoarea acestui volum în 20 de calcule, în care s-au utilizat valori diferite pentru ***N***.

9.2 Înlocuirea unui fenomen real cu un experiment statistic

Principiul de Simulare ***Monte Carlo (MCS)*** este ilustrat in figura 3. În contextul acestei metode intrările sunt aleatoriu generate din distribuții de probabilitate. Datele generate din simulare vor fi reprezentate de distribuții de probabilitate sau histograme

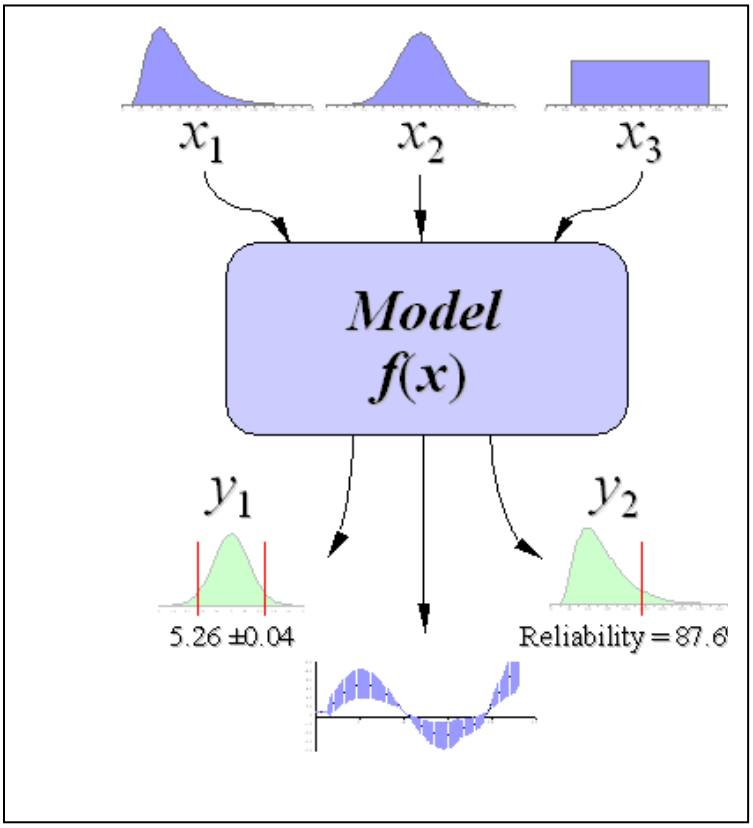

Figura 3. Principiul de Simulare Monte Carlo (MCS)

- **În cadrul acestei tehnici analiza fenomenului real se înlocuieşte cu analiza unui fenomen artificial, descris de un model parametric.** Prin rezolvarea acestuia se generează pentru variabile, valori aleatoare.

- Modelul parametric este de forma $y = f\left(x_1, x_2, x_3, ..., x_q\right)$

- În vederea obţinerii unei imagini corecte a evoluţiei fenomenului sau procesului studiat trebuie ca variabilele aleatoare să fie estimate cu abatere cât mai mică în raport cu cele ce apar în realitate şi experimentul să fie repetat de un număr convenabil de mare de ori, pentru a se pune în evidenţă principalele trăsături ale fenomenului modelat.

- Metoda asociază problemei reale un model aleator şi prin generarea unor variabile aleatoare legate funcţional de soluţie, se realizează experienţe pe model şi se furnizează informaţii asupra soluţiei problemei deterministe.
-

Pașii care se parcurg sunt

Pas 1: Se creează un model parametric, $y = f(x_1, x_2, ..., x_q)$.

Pas 2: Se generează un set de intrări, $x_{i1}, x_{i2}, ..., x_{iq}$.

Pas 3: Se evaluează modelul și se memorează valorile pentru y_i.

Pas 4: Repetă pașii 2 și 3 pentru $i = 1$ to n.

Pas 5: Se analizează rezultatele utilizând histograme, statistici, interval de încredere, etc.

Pentru a ilustra modul în care se utilizează această tehnică vom considera următoarele exemple.

Exemplul 1

Tabelul 9.1 prezintă vânzările de calculatoare PC ale unei firme de profil în ultimele 30 de săptămâni. Se cere utilizând tehnica Monte Carlo simularea vânzărilor de calculatoare pentru 10 săptămâni utilizând distribuţia vânzărilor săptămânale de PC din tabelul 9.2

Tabelul 9.1

Număr curent i	Calculatoare vândute pe săptămână x_i	Număr de Săptămâni f_i
1	0	6
2	1	12
3	2	6
4	3	3
5	4	3

Pentru a simula cererea săptămânală de calculatoare se va determina distribuţia de probabilitate a cererii săptămânale utilizând frecvenţa relativă a cererii în cele 30 săptămâni, adică $P(x_i) = \frac{f_i}{30}$.

Tabelul 10.2

Număr curent i	Calculatoare vândute pe săptămână x_i	Probabilitatea cererii $P(x_i)$
1	0	0,20
2	1	0,40
3	2	0,20
4	3	0,10
5	4	0,10

Pasul 1.

În Tabelul 9.3 sunt prezentate valorile funcţiei distribuţiei cumulative $F(x_i)$ pentru vânzările săptămânale de calculatoare PC determinate pe baza distribuţiei discrete din Tabelul 9.2. Aceasta definește **modelul parametric** al fenomenului studiat.

Tabelul 9.3

Calculatoare vândute pe săptămână x_i	Probabilitatea cererii $P(x_i)$	Funcția distribuției cumulative $F(x_i) = P(X \le x_i)$
0	0,20	0,20
1	0,40	0,60
2	0,20	0,80
3	0,10	0,90
4	0,10	1

Media determinată pe baza datelor ***reale*** referitoare la vânzările săptămânale de PC este

valoarea medie $\mu = 0\times0.2+1\times0.4+2\times0.2+3\times0.1+4\times0.1$

$\mu = 1.5$ calculatoare

dispersia $\sigma^2 = 0\times0.2+1\times0.4+2^2\times0.2+3^2\times0.1+4^2\times0.1-1.5^2$

$\sigma^2 = 1.45$ calculatoare

abaterea standard $\sigma = 1.204$ calculatoare

Pasul 2.

Tabelul 9.4 conţine valorile numerice pentru cazul vânzărilor săptămânale de calculatoare PC

MODEL PARAMETRIC

Tabelul 9.4

Valoarea variabilei probabiliste x_i	Probabilitatea $P(X = x_i) = P(x_i)$	Funcţia distribuţiei cumulative $F(x_i)$	Intervale $[F(x_{i-1}), F(x_i))$
$x_1 = 0$	0,2	0,2	[0 0.2)
$x_2 = 1$	0,4	0,6	[0.2 0.6)
$x_3 = 2$	0,2	0,8	[0.6 0.8)
$x_4 = 3$	0,1	0,9	[0.8 0.9)
$x_5 = 4$	0,1	1,0	[0.9 1.0)

Pasul 3

Se generează un număr de 10 numere aleatoare uniform distribuite în intervalul [0, 1] care au drept corespondent cele 10 săptămâni pentru care se dorește obținerea evoluției probabile a vânzărilor. Evoluția este prezentată în Tabelul 9.5

Tabelul 9.5

Nr. aleator	Valoarea x_i a variabilei probabiliste	Număr calculatoare (bucăţi/săptămână)
0,486281	x2	1
0,928927	x5	4
0,205136	x2	1
0,852845	x4	3
0,005645	x1	0
0,651622	x3	2
0,799931	x3	2
0,333693	x2	1
0,416841	x2	1
0,011913	x1	0

Media determinată pe baza selecţiei simulate = 1,5 calculatoare pe săptămână, iar abaterea standard = 1,269 calculatoare.

Exemplul 2

Numărul de produse vândute zilnic în cadrul unui magazin este dat de o variabilă probabilistă discretă uniform repartizată în intervalul [6, 10]. Se cere simularea vânzărilor pentru 10 zile.

În Tabelul 9.6 sunt prezentate probabilităţile $P(x_i)$, $F(x_i) = P(X \le x_i)$ şi intervalele de numere aleatoare asociate fiecărei valori in intervalul [6, 10] (interval [a, b]). Acestea definesc **modelul parametric.**

Tabelul 9.6

Numărul de produse vândute zilnic x_i	Probabilitatea $P(X = x_i) = \frac{1}{5}$	Funcția distribuției cumulative $F(x_i) = P(X \le x_i) = \frac{1}{5}$	Intervale $[F(x_{i-1}), F(x_i))$
6	0.2	0.2	[0 0.2)
7	0.2	0.4	[0.2 0.4)
8	0.2	0.6	[0.4 0.6)
9	0.2	0.8	[0.6 0.8)
10	0.2	1.0	[0.8 1.0)

În Tabelul 9.7 sunt simulate vânzările din 10 zile.

Tabelul 9.7

Ziua	Număr aleator u	Numărul de produse
1	0,709084	9
2	0,149934	6
3	0,294974	7
4	0,200192	7
5	0,189083	6
6	0,900415	10
7	0,940097	10
8	0,291185	7
9	0,002452	6
10	0,469177	8

Observaţie: În cazul variabilelor cu distribuţie uniformă discretă în intervalul [a, b], se poate genera direct o anumită valoare x_i (numar produse)cu ajutorul relaţiei:

$$x_i = \textit{partea întreagă din } [a + (b-a+1)u]$$

De exemplu, dacă s-a generat u = 0,709084, (numar uniform repartizat in intervalul 0-1) atunci pentru variabila probabilistă cu distribuţie uniformă discretă în intervalul [6, 10], numărul de produse vândute într-o zi oarecare este:

$$x_i = \textit{partea întreagă din } [6 + (10-6+1) * 0{,}709084] = 9 \textit{ produse}$$

Exemplul 3 – Determinarea riscului în management prin modelare și simulare Monte Carlo

Definiții

- **Riscul** este un concept care exprimă probabilitatea unor întâmplări negative și impactul acestora (International Organization for Standardization – ISO). Conform definiției, riscul este efectul (pozitiv sau negativ) al incertitudinii asupra obiectivelor.
- Posibilitatea de pierdere, daune, sau alte circumstanțe neprielnice sau negative; o șansă sau situație care implică o astfel de posibilitate (Oxford English Dictionary).

Presupunem că trebuie să conducem un proiect care implică crearea unui produs eLearning. Pentru creearea acestui produs sunt necesare realizarea unui număr de trei taskuri (activități) scrierea conținutului, crearea interfeței grafice și integrarea de elemente multimedia. În baza unei experințe anterioare sau din aprecierea dificultății de realizare se determină durata acestor activități – cel mai bun caz, cel mai probabil caz respectiv cel mai rău scenariu de terminare pentru fiecare din cele trei activități. Acesta definește **modelul parametric** al sistemului.

Tabelul 9.8

Activități	Cea mai bună estimare de terminare	Cea mai probabilă estimare de terminare	Cea mai pesimistă estimare de terminare
scrierea conținutului	4 zile	6 zile	8 zile
crearea interfeței grafice	5 zile	7 zile	9 zile
integrarea de elemente multimedia	2 zile	4 zile	6 zile
Durata realizării produsului	11 zile	17 zile	23 zile

Simularea Monte Carlo presupune generarea aleatorie de valori pentru diferirele taskuri prezente în crearea produsului cu scopul obținerii de posibile durare de derulare a acestuia. Pentru cazul concret dat vom genera variante de durate pentru cele trei taskuri implicate astfel generând valori uniform distribuite de durate de execuție în intervalul [4 zile, 8 zile] pentru taskul 1, [5 zile, 9 zile] pentru taskul 2 și respectiv [2 zile, 6 zile] pentru taskul 3. Efectuăm această generare de variante de posibile durate de execuțir a produsului de 500 ori. În tabelul 9.9 sunt prezentate rezultatele obținute pentru durata proiectului, luând în considerare suma duratelor celor 3 taskuri de realizat.

Tabelul 9.9

Durata totală a proiectului [zile]	De câte ori s-a generat aceast durată	Procentul variantei de durată care apare în cele 500 simulări
11	5	1%
12	20	4%
13	75	15%
14	90	18%
15	125	25%
16	140	28%
17	155	33%
18	275	55%
19	440	88%
20	475	95%
21	490	98%
22	495	99%
23	500	100%

Grafic, informțiile din acest tabel apar în urmîtoarea formă

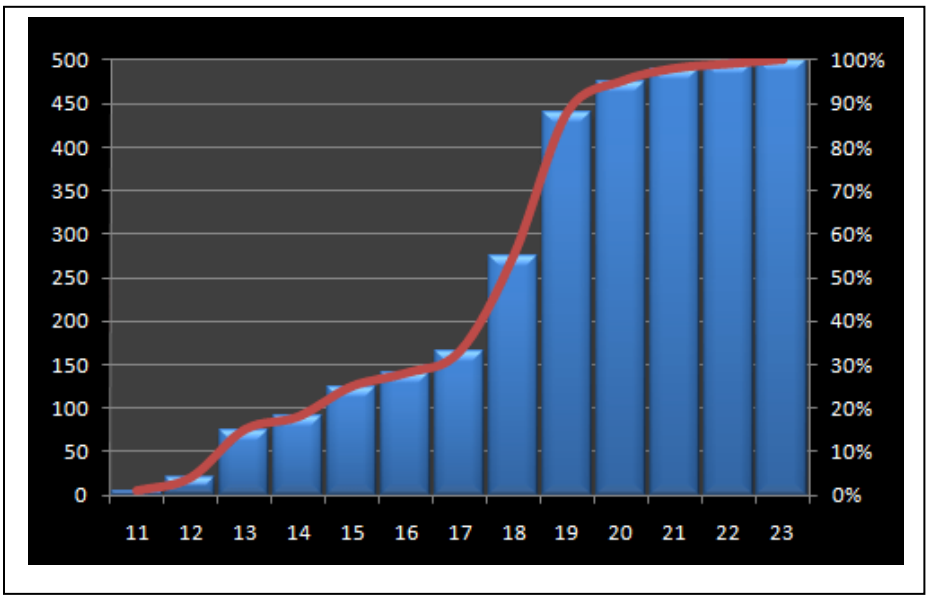

Din grafic se observă că șansa de a termina proiectul în 17 zile este mai mică de 33%. În baza acestei analize proiectul se va termina în 19 – 20 zile.

Analiza Risk Monte Carlo :

Pași

1. Se identifică variabilele de risk ale proiectului
2. Se determină plaja de valori în care apar aceste variabile
3. Se identifică relațiile care apar între aceste variabile
4. Se realizează simularea ținând cont de cele două restricții anterioare (intervale de valori și legaturi între variabile)
5. Se analizează statitstic rezultatele obținute