MODELARE și SIMULARE

Modele corelaționale –
Modele Cauză / Efect

Modele corelaționale

Concepte

În multe situații, sistemul care definește un fenomen din lumea reală (de exemplu fenomene meteo, tehnice – caracteristici funcționale ale unor aparate electronice, medicale, sociale – promovarea unui produs, fenomene de tip imigrationiste etc.) este reprezentat de un set de entități a căror mod de interacțiune între ele și cu lumea înconjurătoare nu este posibil de a fi definit prin ecuații intrare / ieșire, relații între elementele care alcătiesc sistemul și de asemenea nu este posibil să avem o desfășurare clară a succesiunii activităților care au loc sau a stărilor în care acesta este prezent

În aceste cazuri singura posibilitate care rămâne, este aceea ca sistemul asociat fenomenului să fie descris de un set de date (obținute prin măsurători directe care descriu comportarea acestuia la un moment dat), care în foarte multe cazuri are un caracter strict numeric.

Tehnica utilizată în astfel de cazuri poartă denumirea de *Analiză corelațională*. *Modelele care apar prin aplicarea acestei tehnici sunt cunoscute sub denumirea de modele corelaționale (regresionale) sau modele de tip cauză / efect*

Modele corelaționale

Exemplu

Considerăm un set de date de volum ***n***.

✓Acestea vor caracterizează sistemul respectiv și vor corespunde unei situații particulare în care se găsește sistemul în cauză. Practic s-a surprins un instantaneu din funcționarea sistemului.

✓Fiecare element (instanță) din setul de date poate fi caracterizat de un ansamblu de atribute. Aceste atribute sunt: memoria principala, memorie cache, etc. În cele ce urmează convenim să denumim setul de atribute ca reprezentând variabile

	Cycle time (ns)	Main memory (Kb)		Cache	Channels		Performance
	MYCT	MMI	MMA	CACH	CHMIN	CHMAX	PRP
1	125	256	6000	256	16	128	198
2	29	8000	3200	32	8	32	269
...							
208	480	512	8000	32	0	0	67
209	480	1000	4000	0	0	0	45

MMIN: minimum main memory în kilobytes (integer)
MMAX: maximum main memory în kilobytes (integer)
CACH: cache memory în kilobytes (integer)
CHMIN: minimum channels în units (integer)
CHMAX: maximum channels în units (integer)
PRP: published relative performance (integer)

Modele corelaționale

Concepte

Analiza unui set de date cu această structură care să conducă la obținerea unui model, se poate efectua din următoarele puncte de vedere:

1. ***din punctul de vedere a unei singure variabile* a cărei valoare este influențată de restul variabilelor din setul de date. D**e exemplu, aceasta poate fi un atribut de forma: memoria principala ce caracterizează un sistem de calcul a cărei mărime este condiționată de restul atributelor din setul de măsurători.

2. ***fie din punctul de vedere al ansamblului de atribute*** ce caracterizează un sistem, caz în care modelul surprinde relațiile care apar între variabilele ce caracterizează sistemul în ansamblu. De exemplu relații de intercondiționare între memoria principala, memorie cache, etc.,

Modele corelaționale

Concepte

Analiza corelaţionala permite obținerea unor modele analitice ce definesc sistemul care a generat setul de date.

Pentru setul de date prezent modelul care poate fi obţinut este de forma:

$$PRP=-55.9+0.0489MYCT+0.0153\ MMIN+0.0056\ MMAX +$$
$$+0.6410\ CACH-0.2700\ CHMIN+1.480\ CHMAX$$

Pentru construirea modelului se parcurg două etape de analiză :

(A) ***Analiza regresională***, care se ocupă cu descrierea și *cercetarea legăturilor (dependenţei)* care există intre variabilele ce caracterizează elementele setului analizat. Rezultatul este un model matematic al fenomenului în cauză,

(B) ***Calculul coeficientului de corelaţie***, care se ocupă cu *determinarea_ gradului de dependenţă* care există intre variabilele. Acest coeficient va specifica acuratețea modelului construit

Modele corelaționale

Concepte

Dacă notăm

$x_1, x_2, \dots x_m, y$ *setul de variabile ce caracterizează un element al eșantionului în care*

- $\{ x_i \}^n_{i=1}$ *caracterizează fenomenul cauză,*
- y *fenomenul efect,*

modelul dependenţei dintre cauză şi efect, este de forma :

$$y = f (x_1, x_2, \dots , x_m)$$

Sunt prezente două categorii de modele

A) Modele corelaționale liniare

B) Modele corelaționale polinomiale

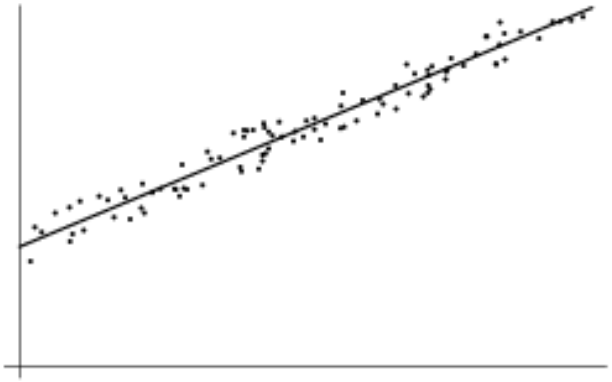

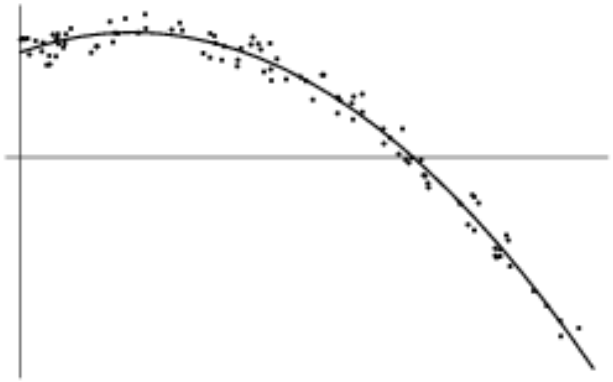

Modele corelaționale

Modele corelaționale liniare

Modul în care se construiește modelul de tip cauze / efect se va exemplifica petru situația în care sistemul a furnizat un eșantion de msurători de dimensiune ***n*** fiecare măsurătoare având un număr de două valori de de forma $(x_i, y_i)_{i=1,n}$

a) Modelul (în care ***x*** este cauza iar ***y*** efectul) care descrie sistemul avut în vedere este de forma

$$y = a_0 + a_1 x$$

b) Modelul (în care ***y*** este cauza iar ***x*** efectul) care descrie sistemul avut în vedere este de forma

$$x = b_0 + b_1 y$$

În primul caz, modelul poartă numele de regresia liniară în ***x*** a lui ***y*** , iar în cel de-al doilea, regresia liniară în ***y*** a lui ***x***.

Modele corelaționale

Modele corelaționale liniare

Caracteristici :

– modelul **$y = f(x_1, x_2, \dots, x_m)$** este reprezentat printr-o linie dreaptă (dreapta de regresie) ;

– corelația (legătura) dintre variabilele cauza și efect este directă dacă odată cu creșterea valorii variabilei cauză creste și mărimea variabilei efect și inversă în caz contrar .

Modele corelaționale

Modele corelaționale liniare

Determinarea coeficienţilor dreptei de regresie

Vom determina aceşti coeficienţi numai pentru un set de date în care un element este caracterizat de doua atribute (***x*** și ***y***), deci modelul (ecuaţia regresională) va fi de forma :

$$y = a_0 + a_1 x$$

Coeficienţii a_0 , a_1 se determină din condiția

a) ca suma abaterilor valorilor reale ale lui ***y*** față de valorile calculate y_x sa fie minimă .

b) ca suma distanțelor de la valorile setului de măsurători la dreapta de regresie să fie minimă

(a)

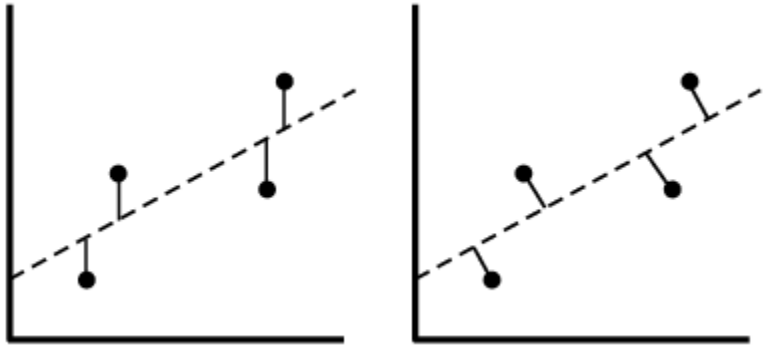

(b)

Modele corelaționale

Modele corelaționale liniare

Vom calcula această distanță în varianta (a).

Dacă notăm cu ***S*** suma a cărei minim se caută, avem

$$S = \sum \left(y_x - \bar{y} \right)^2 = \min$$

sau

$$S = \sum \left(a_0 + a_1 x - \underbrace{\bar{y}}_{y} \right)^2 = \min$$

Unde $\bar{y}$ reprezintă valoare medie a valorilor $\boldsymbol{y_x}$ Pentru a determina minimul lui ***S*** calculăm derivatele parțiale ale acesteia funcţie de $\boldsymbol{a_0}$ și $\boldsymbol{a_1}$

$$\frac{\partial S}{\partial a_0} = 2\sum \left(a_0 + a_1 x - y \right)$$

$$\frac{\partial S}{\partial a_1} = 2\sum \left(a_0 + a_1 x - y \right) x$$

Modele corelaționale

Modele corelaționale liniare

Anulăm derivatele parțiale :

$$\begin{cases} \sum\left(a_0 + a_1 x - y\right) = 0 \\ \sum\left(a_0 x + a_1 x^2 - yx\right) = 0 \end{cases}$$

de unde rezultă sistemul

$$\begin{cases} n a_0 + a_1 \sum x = \sum y \\ a_0 \sum x + a_1 \sum x^2 = \sum yx \end{cases}$$

Modele corelaționale

Modele corelaționale liniare

Model

$y = a_0 + a_1 x$

$$a_0 = \frac{\sum y \sum x^2 - \sum x \sum yx}{n\sum x^2 - \left(\sum x\right)^2}$$

$$a_1 = \frac{n\sum xy - \sum x \sum y}{n\sum x^2 - \left(\sum x\right)^2}$$

$x = b_0 + b_{1y}$

$$b_0 = \frac{\sum x \sum y^2 - \sum y \sum yx}{n\sum y^2 - \left(\sum y\right)^2}$$

$$b_1 = \frac{n\sum xy - \sum x \sum y}{n\sum y^2 - \left(\sum y\right)^2}$$

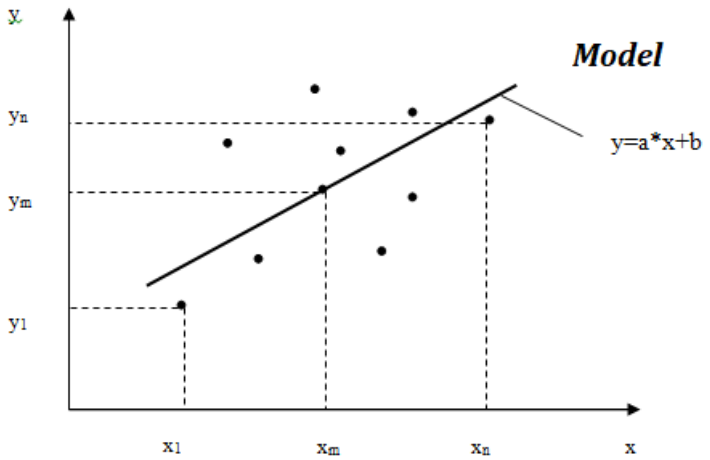

Modele corelaționale

Modele corelaționale liniare

Coeficientul de corelație

Definește calitatea modelului *(cât de bun este acesta). Este definit de un număr care măsoară gradul de legătură (împrăștiere – dispersie) între variabile.*

Se determină astfel :

Erorile standard de estimare pot fi considerate o măsură a gradului de legătură dintre două variabile deoarece :

- **o valoare mare** (indică o împrăștiere mare a punctelor fată de dreapta de regresie) va indica o legătură slabă (asociere) intre cele două variabile ;

- **o valoare mică** (indică o împrăștiere mică a punctelor fată de dreapta de regresie) va indica o legătura mai puternică între cele două variabile.

Dezavantajul constă în faptul că nu pot fi comparate direct între ele, deoarece ele se măsoară în unități ale variabilei ***x*** sau ***y***, care pot fi diferite de la caz la caz. Din acest motiv, se recurge la o măsură relativă raportând eroarea standard de estimare la abaterea medie pătratică.

Modele corelaționale

Modele corelaționale liniare

Raportul astfel obținut $\frac{S_y}{\sigma_y}$ sau $\frac{S_x}{\sigma_x}$

are următoarele avantaje :

- poate fi exprimat în procente, fiind adimensional ;
- dacă legătura dintre cele două variabile este perfectă, $\boldsymbol{S_y}$ sau $\boldsymbol{S_x}$ vor fi egale cu zero și raportul va fi egal cu zero ;
- dacă asocierea este foarte slabă, valoarea erorii standard va crește până când la limită va fi egală cu abaterea medie pătratică, caz în care raportul este egal cu 1

Deoarece raportul are o valoare 0 pentru o legătură perfectă, și 1 pentru absenta oricărei legături, s-a recurs la definirea unei măsuri a cărei valoare să varieze direct proporțional cu gradul de asociere.

Modele corelaționale

Modele corelaționale liniare

Se definește *coeficientul de corelație* ca fiind :

$$r_{yx} = 1 - \frac{S_y^2}{\sigma_y^2} = 1 - \frac{\sum (y - y_c)^2}{\sum (y - \bar{y})^2}$$

$$r_{xy} = 1 - \frac{S_x^2}{\sigma_x^2} = 1 - \frac{\sum (x - x_c)^2}{\sum (x - \bar{x})^2}$$

cei doi coeficienți caracterizează gradul de asociere dintre ***y*** și ***x*** si, respectiv, ***x*** și ***y*** (corectitudinea modelelor corelaţionale $y = a_0 + a_1 x$ și respectiv $x = b_0 + b_1 y$)

Caracteristici :

- ia valori între 0 și 1 ;
- dacă corelația dintre ***x*** și ***y*** este directă, coeficientul de corelație primește semnul '+' și respectiv, semnul '-' dacă corelația dintre x și y este inversă ;
- în practică se consideră semnificative acele modele pentru care coeficientul de corelație are o valoare mai mare de 0.7.

Modele corelaționale

Modele corelaționale liniare - Exemplu

Ne propunem să construim un model pentru un sistem definit de un set de ***n=8*** măsurători de forma $(x_i, y_i)_{i=1,n.}$ Modelul va fi de forma $y = a_0 + a_1 x$

x	y	y_c	$y - y_c$	$(y - y_c)^2$	$y - \bar{y}$	$(y - \bar{y})^2$
1	1	1.18	-0.18	0.324	-4	16
3	2	2.45	-0.45	0.202	-3	9
4	4	3.10	0.90	0.810	-1	1
6	4	4.36	-0.36	0.130	-1	1
8	5	5.63	-0.63	0.397	0	0
9	7	6.27	0.73	0.533	2	4
11	8	7.54	0.46	0.212	3	9
14	9	9.45	-0.45	0.202	4	16

$$\bar{y} = 5$$

$$S_y = 0.6$$

$$\sigma_y = \frac{\sum (y - \bar{y})^2}{N} = \frac{56}{8}$$

$$r_{yx} = 1 - \frac{0.36}{\frac{56}{8}} = 0.99$$

modelul corelaţional este $y = (6/11) + (7/11)x$ având precizia de 0.99

Modele corelaționale

Modele corelaționale

Observații privind analiza corelaţională

Analiza corelaţională reprezintă o tehnică de modelare care ia în considerare măsurători numerice care descriu comportarea globală a sistemului analizat. Tehnica de construiește un model care descrie sistemul luat în considerare indirect prin luarea în considerare a cauzelor care conduc la un efect al funcționării sistemului în cauză

Condițiile care trebuiesc respectate sunt :

- necesară reținerea numai a factorilor cu influenta semnificativă asupra variabilei dependente ;
- se recomandă utilizarea acelor variabile care se exprimă prin unități de măsură relative, deoarece sunt mai puțin supuse deformărilor pe care le incumba unitățile de măsură ;
- numărul de elemente trebuie să fie suficient de mare pentru a se evita obținerea unor modele relaţionale nereprezentative (caracterizate de un coeficient de corelaţie mare, dar incorect).

Modele corelaționale

Modele corelaționale - multiliniare

În cazul în care sistemul este descris de un set ***N*** măsurători unde fiecare măsurătoare este formată din ***M+1*** valori numerice modelul care descrie comportarea sistemului prin luarea în considerare cauzelor ***M*** care conduc la un efect ***y*** este de forma

Cauze — Efect

Date în setul analizat	x_1	x_2	x_3	.....	x_M	Y
1	x_{11}	x_{21}	x_{31}	.....	x_{M1}	Y_1
2	x_{12}	x_{22}	x_{32}	.....	x_{M2}	Y_2
.....	.....	.....	.....	.....	.....	.....
N	x_{1N}	x_{2N}	x_{3N}	.....	x_{MN}	Y_N

MODEL

$$Y = a + b_1 x + b_2 x_2 + \ldots\ldots\ldots\ldots + b_M x_M = \sum_{j=1}^{M} b_j x_j$$

Modele corelaționale

Modele corelaționale - multiliniare

- Pentru modelele multiliniare precizia se defineşte ca fiind coeficientul de corelaţie total. Acesta, definește efectul total al tuturor cauzelor care conduc la obținerea unui cauze Relaţia de definiţie este

$$R_{Y,X_1,X_2,\ldots,X_M} = \frac{\sum_i (Y_i - \overline{Y}) \cdot (\hat{Y}_i - \overline{Y})}{\sqrt{[\sum_i (Y_i - \overline{Y})^2] \cdot [\sum_i (\hat{Y}_i - \overline{Y})^2]}}$$

Unde

$\overline{Y}$ valoarea medie a mărimilor măsurate Y_i

$\hat{Y}_i$ valoarea medie a mărimilor calculate Y_i

- Pentru modelele multiliniare se poat calcula inclusiv importanța unei cauze particulare în producerea efectului total. Legătura dintr cauză și efect poartă denumirea de **indice de corelare parțială**

- Pentru modelele multiliniare se poate calcula cît de puternică este legătura dintre două cauze în contextul modelului construit Legătura dintre două cauze poartă denumirea de **indice de intercorelare**

Întrebări???