10. Particle Swarm Optimization

10.1 Introducere

Tehnica Optimizari roiului de particule (PSO - **P**article **S**warm **O**ptimization) este o metodă de calcul care optimizează o problemă încercând în mod iterativ să îmbunătățească o soluție candidat cu privire la o anumită măsură de calitate. Rezolvă o problemă prin faptul că are o populație de soluții candidate, numite particule pe care le mută în spațiul de căutare, conform relațiilor matematice care specifică modul de modificare a poziției și vitezei particulelor în contextul prezenței unei funcții fitness de evaluare a poziției curente (funcție fitness - Funcții matematice utilizate în optimizare pentru a evalua calitatea soluțiilor în algoritmi evoluționali sau de selecție natural).

Taxonomie

Particle Swarm Optimization se găsește la granița dintre tehnicile de modelare / simulare și domeniul Inteligenței Artificiale

Inspirație

Particle Swarm Optimization este inspirată de comportamentul social a unor animale,cum ar fi comportamentul zborului păsărilor în roi ca și comportamentul bancurilor de pești.

Strategie

Algoritmul operează cu un set de soluții candidat (parțiale). Fiecare soluție candidat este definită ca o particulă într-un spațiu multi-dimensional al tuturor soluțiilor posibile. În acest acest spațiu particula evoluează, aspect care se realizează prin atribuirea unor poziții și viteze aleatorii inițial tuturor particulelor. Algoritmul modifică poziția fiecărei particule în funcție de

- viteza sa,
- poziția globală cea mai cunoscută în spațiul problemei și
- cea mai bună poziție cunoscută unei particule.

Funcția obiectiv (fitness) este activată după fiecare actualizare a poziției. De-a lungul timpului, printr-o combinație de explorare și exploatare, particulele vor converge spre un optim sau mai multe optime.

Particle swarm optimization (PSO) - Tehnica optimizării roiului de particule. A fost propus de Kennedy, J.; Eberhart, R. (1995). "*Particle Swarm Optimization". Proceedings of IEEE International Conference on Neural Networks. IV. pp. 1942–1948. doi:10.1109/ICNN.1995.488968*.

Concepte

- Particle Swarm Optimization, sau „*tehnica optimizării roiului de particule*”, , folosește un model populațional.
- Populația, *roiul*, este formată din *particule*, potențiale soluții. Roiul de particule, se spune că „zboară” în hiperspațiul de dimensiune *n*, unde *n* este dimensiunea unei soluții (nr. de parametri căutați). Acest zbor presupune găsirea unei soluții acceptabile plecând de la o populație de soluții inițială generată aleatoriu, care se îmbunătățește pe parcursul a mai multor iterații.
-

O particulă tinde să orbiteze

- în jurul celei mai bune sale poziții (***pbest***) și
- în jurul celei mai bune poziții (***gbest***) din grupul din care face parte.

- Fiecare particulă își ajustează viteza de deplasare și direcția în acord cu:
  - propria sa experiență de zbor și
  - cea a particulelor din roi.

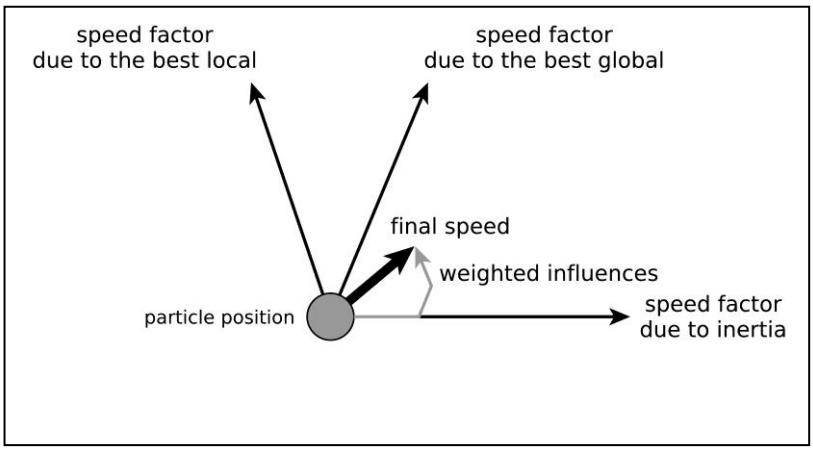

- Algoritmul se poate termina luînd în considerare mai multe criterii, spre exemplu când o soluție satisfăcătoare a fost găsită ori s-au executat un număr predefinit de iterații.
-

  Există două tipuri de PSO:

  - varianta *gbest* și
  - varianta *lbest*.

- în cadrul modelului *gbest*, o particulă schimbă informație cu tot roiul,
- pe când în cadrul modelului *lbest*, informația este schimbată doar cu particulele aflate într-o vecinătate a acesteia.

10.2 Algoritmul original

În cele ce urmează vom prezenta algoritmul original PSO, o variantă *gbest*, așa cum a fost descris de către creatorii săi (Kennedy, J.; Eberhart, R. (1995). "*Particle Swarm Optimization*". Proceedings of IEEE International Conference on Neural Networks. IV. pp. 1942–1948)

În acest model, la un moment oarecare ***t***, fiecare particula ***i***, are următoarele caracteristici:

- x_i – poziția curentă;
- v_i – viteza curentă;
- fiecare particulă are în propria memorie cea mai bună poziție descoperită de-a lungul iterațiilor, notată cu p_i, iar
- întreg roiul are în propria memorie cea mai bună poziție găsită de toate particulele sale, notată cu p_g definită ca:

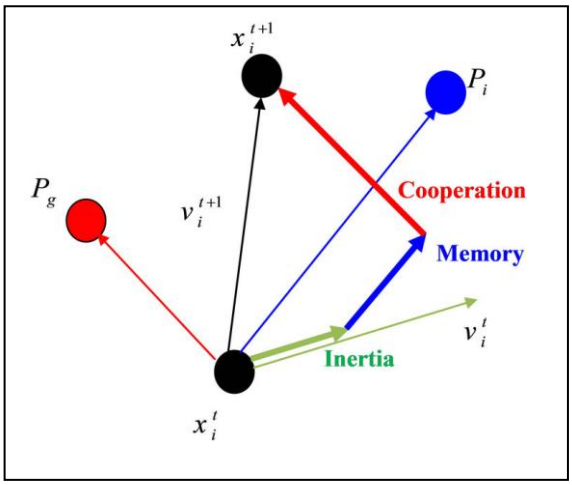

Atât p_i, cât și p_g sunt actualizate la fiecare iterație a algoritmului.

Acest model de PSO, numit „global”, menține o singură cea mai bună poziție pentru tot roiul. Deoarece toate particulele din roi se îndreaptă spre această poziție, dacă ea nu ar fi actualizată destul de des, la fiecare iterație sau câteva iterații, atunci tot roiul ar converge prematur.

Algoritmul are trei mari faze, pe care le vom descrie separat: faza de inițializare, faza iterațiilor și faza de terminare.

Inițializarea

Înainte de a „zbura”, particulele au nevoie de o inițializare a componentelor vectoriale descrise mai sus.

Fiecărei componente

- x_i^t ale vectorului de poziție i se va asigna o valoare aleatoare uniform distribuită în intervalul maxim din spațiul de căutare $[-x_{max}, +x_{max}]$,
- v_i^t ale vectorului de viteză, fie i se va asigna inițial valoarea 0, fie o valoare uniform aleatoare din intervalul $[-v_{max}, +v_{max}]$,
- cele specificate mai sus se traduc prin următoarele calcule

$$x_0^i = x_{\min} + rand\left(x_{\max} - x_{\min}\right)$$
$$v_0^i = \frac{x_{\min} + rand\left(x_{\max} - x_{\min}\right)}{\Delta t}$$

Cele două componente (poziție, viteză) pot fi văzute în figura următoare.

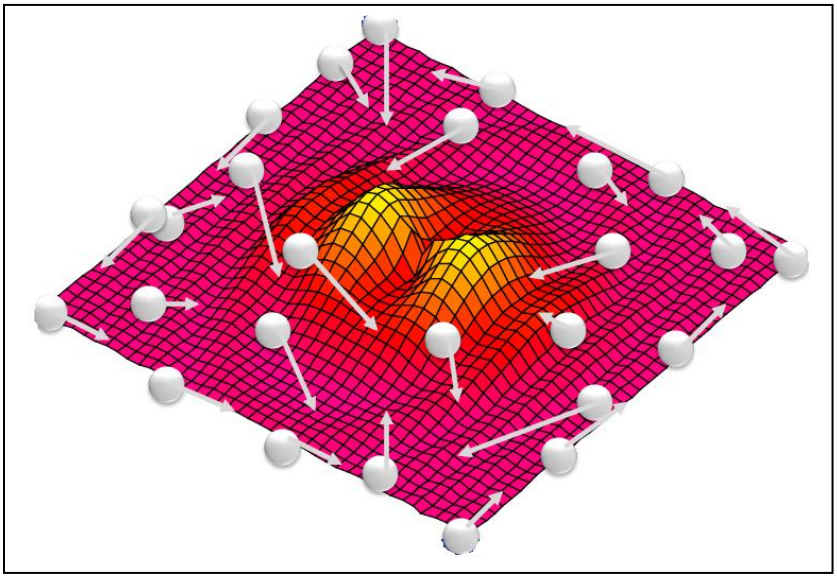

Faza iterațiilor

În faza iterațiilor se actualizează pentru fiecare particulă în parte vectorul de viteză, v_t^i, iar pe baza acestuia și vectorul de poziție, x_t^i.

Schimbarea vitezei pentru fiecare particulă în fiecare iterație presupune luarea în considerare:

- poziției curente a particulei
- a celei mai bune poziții anterioare pe care a avut-o particula
- a celei mai bune poziții anterioare a roiului

Tendința de deplasare a particulei, influența roiului sunt ponderate aleator. Ecuația (1) arată cum se schimbă viteza în fiecare iterație iar ecuația (2) arată cum viteza contribuie la schimbarea poziției particulei.

În ecuație:

- ***w*** este factorul de inerție,
- ***c1*** este coeficientul de încredere în decizia pe care o ia particula, iar
- ***c2*** este coeficientul de încredere în comportarea roiului,
- ***rand*** este un generator de numere aleatoare uniform distribuite în (0, 1).

Cea mai bună locație anterioară a particulei este memorată în $\boldsymbol{p_i}$ iar cea mai bună poziție curentă a roiului este memorată în $\boldsymbol{p_g}$.

Figura următoare arată cum fiecare din aceste componente se combină pentru a rezulta noua viteză și poziția care rezultă pentru o particulă la sfârșitul unei.

$$(1)\quad v_{k+1}^i = w \cdot v_k^i + c1 \cdot rand(\ ) \cdot \frac{\left(p^i - x_k^i\right)}{\Delta t} + c2 \cdot rand(\ ) \cdot \frac{\left(p_k^g - x_k^i\right)}{\Delta t}$$

$$(2)\quad x_{k+1}^i = x_k^i + v_{k+1}^i \cdot \Delta t$$

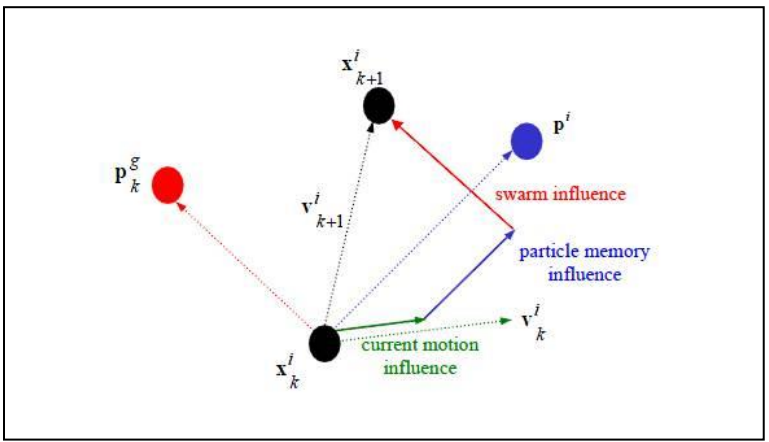

Pentru a căpăta proprietăți stohastice, algoritmul folosește, după cum se observă, doi vectori care au conținut uniform aleatoriu $rand \sim U(0,1)$, scalați de *coeficienții de accelerație* $c_1, c_2 \in [0,2]$.

- Coeficienții c_1, c_2 au rolul de a stabili mărimea maximă a pasului înspre
  - ***pi*** – cea mai bună poziție personală , respectiv
  - ***pg*** - cea mai bună poziție găsită de întregul roi.

- Coeficientul *w* are rolul de a balansa căutarea între
  - explorare globală (*w* mare) şi
  - explorare locală (*w* mic).

Ignorând viteza anterioară v_k^i, ecuația se împarte în două componente:

- ***componenta cognitivă personală***, $c1 \cdot rand \dfrac{\left(p^i - x_k^i\right)}{\Delta t}$

Această componentă ia în considerare doar experiențele personale ale particulei *i*, și influențează cât se va deplasa particula spre cea mai bună performanță a sa din trecut. Pentru actualizarea vitezei, Kennedy a folosit într-un experiment doar această componentă în ecuație, sub forma

$$v_{k+1}^i = w \cdot v_k^i + c1 \cdot rand \frac{\left(p^i - x_k^i\right)}{\Delta t},$$

omițând cea de-a doua componentă. Rezultatele obținute au fost mult inferioare soluției complete, deoarece particulele nu aveau nici o interacțiune.

- ***componenta socială de grup***, $c2 \cdot rand \dfrac{\left(p_k^g - x_k^i\right)}{\Delta t}$

Această componentă ia în considerare interacțiunile dintre particula ***i*** și roi. Influențează cât se va deplasa particula spre cea mai bună poziție găsită de roi.

În cadrul aceluiași experiment despre care am discutat mai sus, Kennedy a folosit pentru actualizarea vitezei doar componenta socială, sub forma

$$v_{k+1}^i = w \cdot v_k^i + c2 \cdot rand \frac{\left(p_k^g - x_k^i\right)}{\Delta t},$$

iar rezultatele au fost superioare primei încercări în care s-a folosit doar componenta cognitivă.

În prezent nu se știu prea multe despre cât de importante sunt cele două componente în parte, deși empiric s-a demonstrat că pe un set mai larg de probleme componenta socială ar fi mai importantă.

Cert este că, folosind ambele componente, rezultatele sunt satisfăcătoare în comparație cu alți algoritmi care încearcă să rezolve aceleași probleme.

Pe baza vectorului de viteză se calculează vectorul de poziție după formula:

$$x_{k+1}^{i} = x_{k}^{i} + v_{k+1}^{i} \cdot \Delta t$$

Urmează actualizarea celei mai bune poziții găsite de particula ***i*** până la momentul ***t***. După ce toate particulele au fost procesate, se poate calcula din nou cea mai bună poziție găsită de roi.

Faza de terminare

Algoritmul se rulează de un număr de ori stabilit dinainte sau până se atinge un nivel prestabilit de eroare. Desigur pot exista și alte criterii de oprire, acestea fiind date de natura problemei de rezolvat. În figura următoare se prezintă faza de iterație și ultima iterație în care s-a atins un optim.

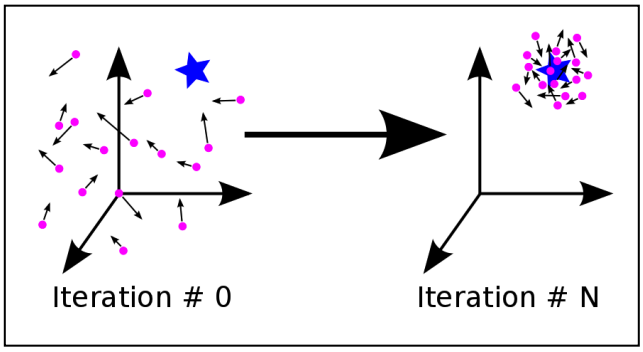

În continuare redăm o simplă variantă de pseudo-cod, care sintetizează cele discutate mai sus.

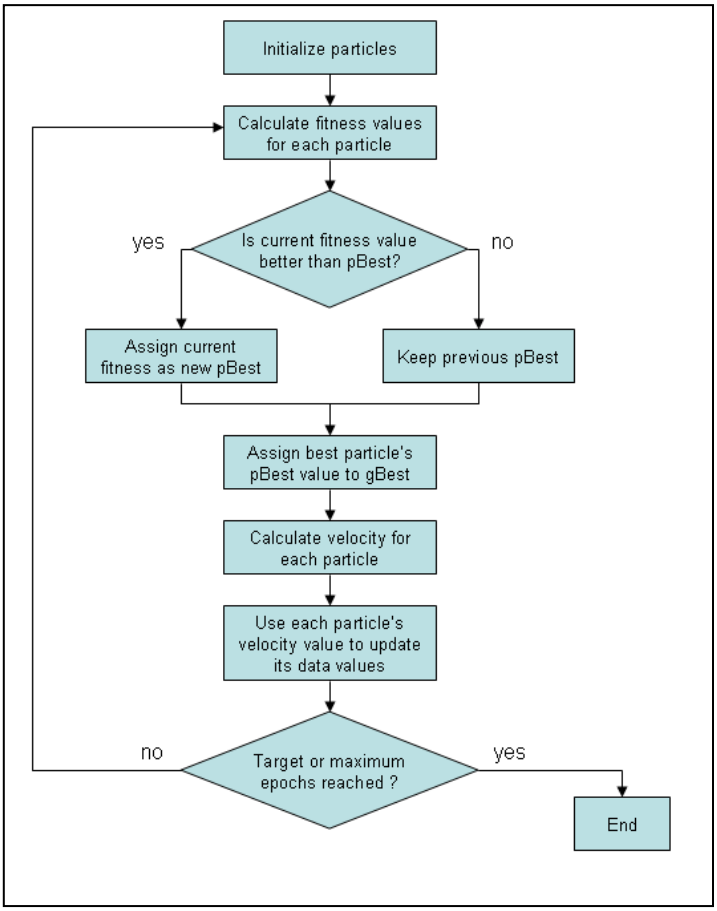

10.3 Exemplu

Optimizarea unui portofoliu utilizând Particle Swarm Optimization

Algoritmul PSO poate fi utilizat pentru optimizarea unui portofoliu în contextul unor tranzacții bursiere. În contextul optimizării portofoliului, fiecare particulă poate defini o posibilă alocare de capital între diverse 'bunuri' din contextul portofoliului. Funcția de fitness a acestui portofoliu poate fi determinată utilizând funcții financiare care calculează riscul unei investiții. Presupunând că se utilizează pentru funcția de fitness – Sharpe ratio - (Indice de performanță a unui portofoliu. A fost descrisa de Sharpe care corelează câștigul prognozat al unui portofoliu eficient cu rata dobânzii pentru titlul cu risc zero si câștigul prognozat al pieței. Este în prezent un standard de măsură a eficienței unui portofoliu)

$$E\left(R_p\right) = R_f + \frac{\left[E\left(R_M\right) - R_f\right]}{\sigma_M}\sigma_P$$

Unde:

- $E(R_p)$ câștigul prognozat al portofoliului;
- R_f câștigul prognozat al titlului cu risc zero;
- $E(R_M)$ câștigul prognozat al pieței (indice);
- σ_P abaterea standard a portofoliului;
- σ_M abaterea standard a pieței.

Considerăm următoare ilustrare a tehnicii PSO aplicată unui portofoliu constând din 3 bunuri

,

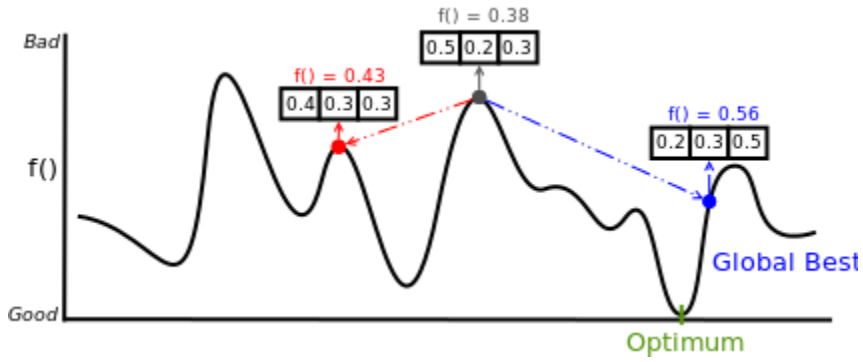

Particula gri este particula care a fost actualizată, Particula roșie este cea mai bună poziție a particulei gri (*pbest*) iar cea albastră cea mai bună poziție globală (gbest).

- Particula gri glisează în vectorul (0.5, 0.2, 0.3) care înseamnă că 50% din portofoliu este alocat pentru bunul 1, 20% pentru bunul 2 și 30% pentru bunul 3. Coeficientul Sharpe pentru această alocare de fonduri este de 0.38 care este mai mică decât cea mai bună poziție personală (particular roșie) și cea mai bună poziție global (particular albastră). Din această poziție particula gri este actualizată astfel încât aceasta se va apropria mai mult atât de valorile cele mai bune atât personale (pbest) cât ți globale (gbest). Rezultatul este mai bun decât cel din pasul anterior.

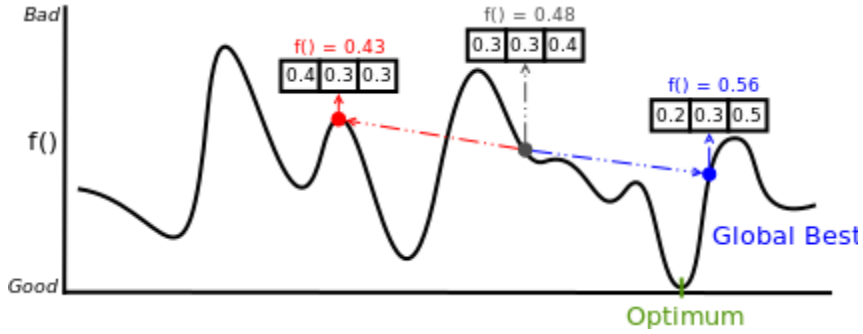

- Particula gri prezintă în acest pas valoarea (0.3, 0.3, 0.4) care are un coeficient Sharpe de 0.48. Deoarece această valoare este mai mare decât valoare pbest din pasul anterior poziția particulei va actualiza valoare pbest

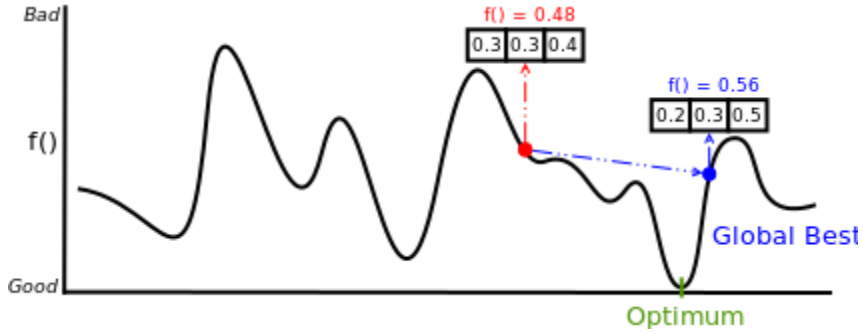

Adevărata provocare în procesul de optimizare cu (PSO) este legată de asigurarea respectării faptului că constrângerile de optimizare a portofoliului sunt satisfăcute. Cele mai frecvente constrângeri sunt

- în primul rând, legate de faptul că nu mai mult și nu mai puțin de 100% din capitalul disponibil se alocă între active (de exemplu, valoarea vectorului trebuie să fie 1,0). În al doilea rând, alocările negative de active nu sunt permise.
- Capitalul disponibil trebuie să fie alocat tuturor activelor din portofoliu. Aceasta din urmă fiind o constrângere cardinalitate. Două tehnici comune sunt utilizate pentru a se asigura că particulele satisfac constrângerile.
    - Pentru fiecare particulă care nu satisface constrângerile, se aplică un set de reguli pentru a modifica poziția particula lui astfel încât aceste restricții să fie îndeplinite.
    - Se penalizează prin intermediul funcției de fitness particulele care nu satisfac constrângeri

Anexa

Ackley Function

$$f(x) = 20 + e - 20e^{-\frac{1}{5}\sqrt{\frac{1}{n}\sum_{i=1}^{n} x_i^2}} - e^{\frac{1}{n}\sum_{i=1}^{n}\cos(2\pi x_i)}$$

Dimensions:	n
Domain:	$-32.768 \leq x_i \leq 32.768$
Global Optimum:	$f(x) = 0.0$ at $x = (0.0, 0.0, \ldots, 0.0)$
Operator:	AckleyEvaluator
Charts:	

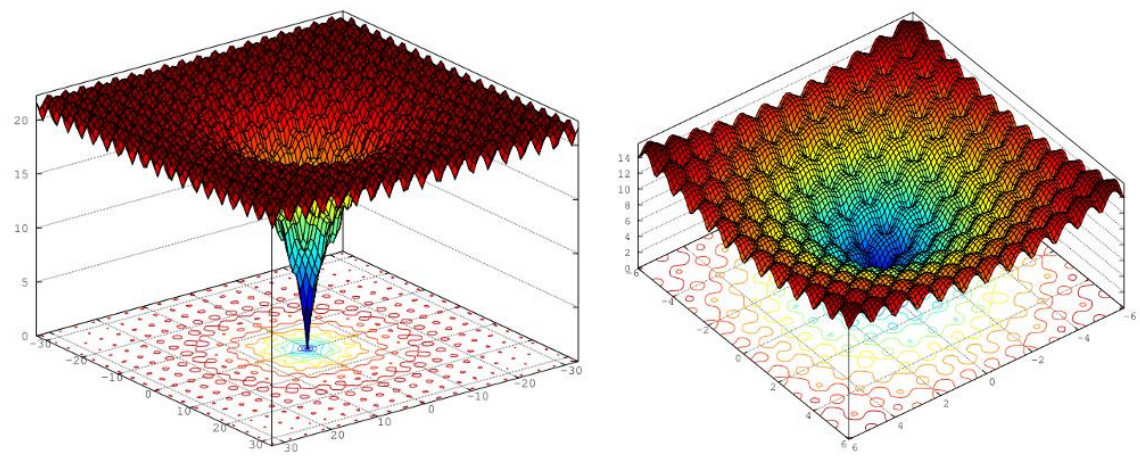

(a) [-32.768, 32.768] (b) [-6.0, 6.0]

Griewank Function

$$f(x) = 1 + \sum_{i=1}^{n} \frac{x_i^2}{4000} - \prod_{i=1}^{n} \cos(\frac{x_i}{\sqrt{i}})$$

Dimensions:	n
Domain:	$-600.0 \leq x_i \leq 600.0$
Global Optimum:	$f(x) = 0.0$ at $x = (0.0, 0.0, \ldots, 0.0)$
Operator:	GriewankEvaluator
Charts:	

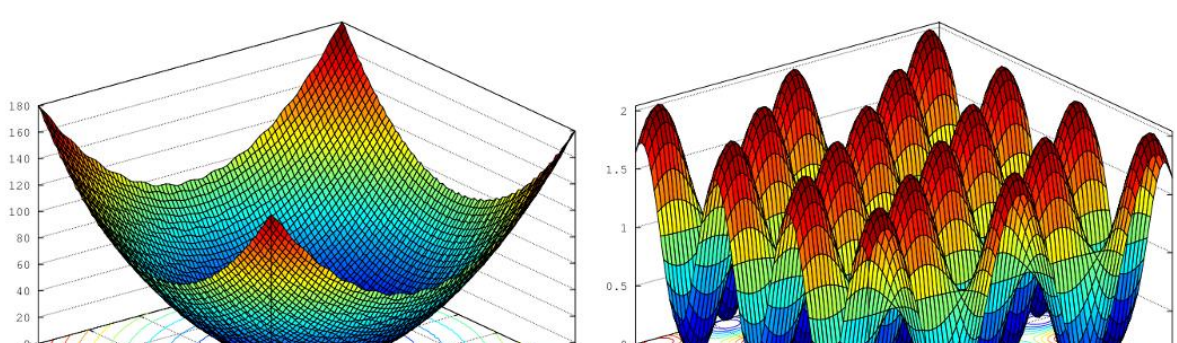

Rastrigin Function

$$f(x) = 10n + \sum_{i=1}^{n} [x_i^2 - 10\cos(2\pi x_i)]$$

Dimensions: n
Domain: $-5.12 \leq x_i \leq 5.12$
Global Optimum: $f(x) = 0.0$ at $x = (0.0, 0.0, \ldots, 0.0)$
Operator: RastriginEvaluator
Charts:

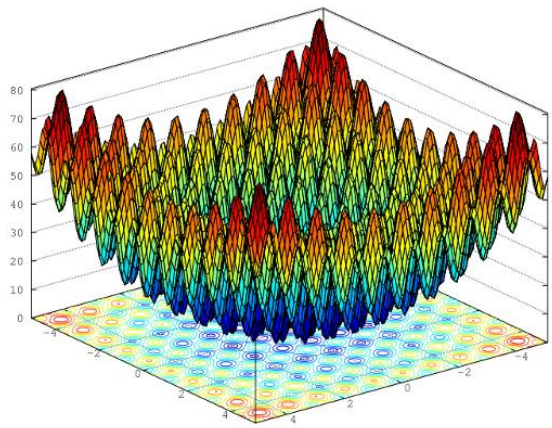

(a) [-5.12, 5.12]

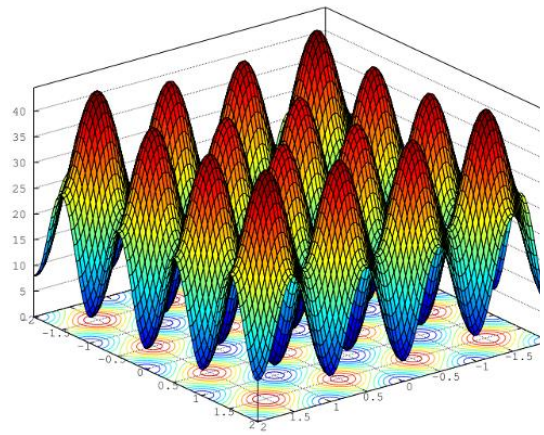

(b) [-2.0, 2.0]

Rosenbrock Function

$$f(x) = \sum_{i=1}^{n-1} [100(x_i^2 - x_{i+1})^2 + (x_i - 1)^2]$$
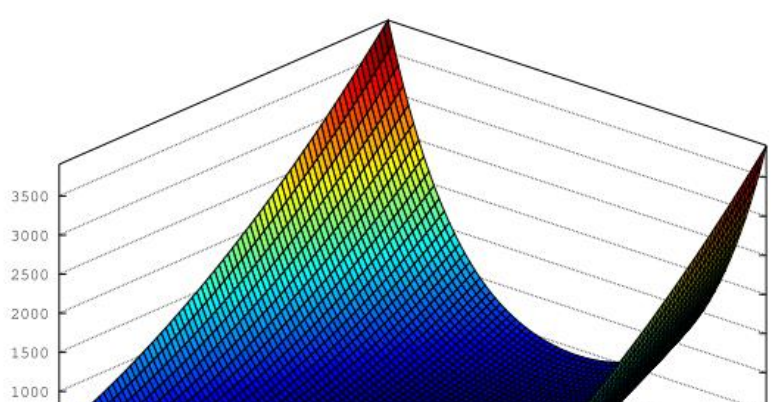
Dimensions: n
Domain: $-2.048 \leq x_i \leq 2.048$
Global Optimum: $f(x) = 0.0$ at $x = (1.0, 1.0, \ldots, 1.0)$
Operator: RosenbrockEvaluator
Charts: