PI_Curs_08

8.0

Absolut! Lecția **8. Image Captioning** introduce o nouă frontieră a inteligenței artificiale, conectând domeniile Viziunii Computerizate și Procesării Limbajului Natural (NLP). Deoarece sursa este concisă, Ghidul de Studiu se va concentra pe definirea clară a conceptelor și sarcinilor conexe.

Ghid de Studiu Complet: 8. Image Captioning (Adnotarea/Descrierea Imaginilor)

1. 🎯 SINTEZA LECȚIEI (THE BIG PICTURE)

Lecția 8, "Image Captioning," se concentrează pe sarcina de a **descrie conținutul unei imagini în limbaj natural**, adică de a genera automat *caption*-uri (descrieri) pentru o imagine,. Aceasta este o problemă fundamentală în inteligența artificială, deoarece **conectează viziunea computerizată și procesarea limbajului natural**,. *Image captioning* imită abilitatea remarcabilă a omului de a comprima cantități uriașe de informații vizuale în limbaj descriptiv,. Pe lângă sarcina de bază, acest capitol introduce și două sarcini conexe și mai complexe: **Visual Question Answering (VQA)** și **Visual Dialog**.

Care sunt cele 3 idei principale pe care trebuie neapărat să le rețin?

1. **Definiția Sarcinii:** *Image captioning* = descrierea conținutului vizual al unei imagini folosind limbaj natural,.
2. **Conectivitatea AI:** Sarcina este fundamentală deoarece face legătura între Viziunea Computerizată și NLP (Procesarea Limbajului Natural),.
3. **Sarcini Conexe:** *Image captioning* stă la baza sarcinilor mai complexe care necesită raționament: **VQA** (răspuns la întrebări despre o imagine) și **Visual Dialog** (dialog conversațional despre conținutul vizual),,.

---

2. 📖 REZUMAT DETALIAT (PE CAPITOLE/SECȚIUNI)

8. Image Captioning

Definirea Sarcinii de Bază

- **Image Captioning** reprezintă sarcina de a descrie conținutul unei imagini în limbaj natural,.

- Altfel spus, înseamnă generarea de *caption*-uri (descrieri) pentru o imagine, de unde și numele,.
- Este o problemă fundamentală în inteligența artificială, deoarece realizează o conexiune între **viziunea computerizată** și **procesarea limbajului natural**,.
- Această sarcină imită abilitatea umană remarcabilă de a **comprima cantități uriașe de informații vizuale în limbaj descriptiv**,.

Sarcini Conexe și Mai Complexe

1. **Visual Question Answering (VQA):**
   - Sarcina VQA (răspuns la întrebări vizuale deschise și în format liber) este definită astfel: având o imagine și o întrebare în limbaj natural despre acea imagine, sistemul trebuie să ofere un **răspuns precis în limbaj natural**,.
   - VQA oglindește scenarii din lumea reală, cum ar fi ajutorul oferit persoanelor cu deficiențe de vedere, unde atât întrebările, cât și răspunsurile sunt deschise (*open-ended*),.
   - Întrebările vizuale vizează selectiv diferite zone ale unei imagini, incluzând **detaliile de fundal și contextul implicit**,.
   - Un sistem care are succes în VQA necesită o **înțelegere mai detaliată a imaginii și un raționament complex** decât un sistem care produce doar *caption*-uri generice,.
   - Totuși, multe răspunsuri deschise la VQA conțin doar câteva cuvinte sau fac parte dintr-un set închis de răspunsuri ce pot fi oferite în format *multiple-choice*,.
2. **Visual Dialog:**
   - Sarcina de **Visual Dialog** necesită ca un agent să poarte un **dialog semnificativ** cu oamenii, în limbaj natural și conversațional, despre conținutul vizual al unei imagini,.
   - Mai exact, având o imagine, un istoric al dialogului și o întrebare despre imagine, agentul trebuie să:
     - **Fundamenteze** (*ground*) întrebarea în imagine,.
     - **In fereze** contextul din istoric,.
     - **Răspundă** la întrebare cu precizie,.
   - Visual Dialog este suficient de distinct de sarcinile specifice de tip *downstream* pentru a servi ca un **test general de inteligență a mașinilor**, fiind totodată bazat pe viziune suficient de mult pentru a permite evaluarea obiectivă a răspunsurilor individuale,.
   - Exemplu: Un dialog în care agentul răspunde la întrebări succesive despre o pisică care bea apă dintr-o cană, despre culoarea cănii, despre alte obiecte pe masă, ș.a.m.d.,.

---

3. 💡 EXPLICAȚII SUPLIMENTARE ȘI CLARIFICĂRI (IMPORTANT)

Termen Tehnic: Grounding the Question (Fundamentarea Întrebării)

- **Explicație Simplificată (Atingerea Realității):** În VQA și Visual Dialog, *grounding* înseamnă că sistemul nu doar înțelege lingvistic întrebarea ("Unde este pisica?"), ci reușește să o lege de **regiunea specifică a imaginii** la care se referă. Dacă pisica este detectată și localizată (sarcini din Capitolul 6), răspunsul devine fundamentat pe dovezi vizuale clare.
- *Asta se întâmplă deoarece:* Fără *grounding*, sistemul ar putea răspunde bazat pe cunoștințe generale sau contextul dialogului, dar nu ar demonstra că a **văzut** efectiv elementul respectiv în imaginea curentă.

Concept Dificil: Raționament Complex vs. *Caption* Generică (VQA)

- **Analogie (Elevul vs. Studentul):**
  - *Image Captioning* este ca un elev care învață să descrie o imagine: "O pisică bea apă." (Descriere generală).
  - *VQA* este ca un student care trebuie să raționeze: "Câte dungi sunt pe cana din care bea pisica?" Acest lucru necesită nu doar identificarea (pisică, cană), ci și **raționament fin și focalizare pe detalii** care nu ar fi incluse într-o descriere generală,.
- *Asta se întâmplă deoarece:* VQA solicită sisteme care pot **targeta selectiv** diferite zone ale unei imagini, inclusiv detalii de fundal și context implicit, ceea ce depășește producerea de *caption*-uri generice,.

---

4. 🔗 CONEXIUNI ȘI IMPLICAȚII

- **Conexiunea cu Viziunea Computerizată Anterioară (Capitolul 6 & 7):** Sarcini precum *Image Captioning* și VQA se bazează puternic pe capacitatea sistemului de a realiza Detecția Obiectelor (cutii de delimitare), Segmentarea Semantică (clasificare la nivel de pixel) și Segmentarea Instanțelor, deoarece aceste sarcini oferă **feature-urile vizuale semantice** necesare pentru a genera descrierea textului.
- **Relația Cauză-Efect (Inteligența Mașinilor):**
  - **CAUZĂ:** Necesitatea de a crea agenți AI care să poată interacționa fluid și inteligent cu oamenii, pe baza conținutului vizual.
  - **EFECT:** Dezvoltarea sarcinilor de **Visual Dialog**, care servesc ca un **test general de inteligență a mașinilor** (*general test of machine intelligence*),.

---

5. EXERCITII (Teorie și Analiză)

Exercițiul IA.1: Diferențiere Sarcini (VQA vs. Visual Dialog)

Deși ambele sarcini implică întrebări despre o imagine, explicați elementul distinctiv care face ca **Visual Dialog** să fie o sarcină mai complexă decât VQA, conform surselor.

Rezolvare IA.1:

Elementul distinctiv al **Visual Dialog** este necesitatea de a menține un **istoric al dialogului** și de a **infera contextul din acel istoric** pentru a răspunde cu precizie la întrebarea curentă,. VQA, deși implică întrebări deschise, se concentrează pe o singură întrebare (dată o imagine și o întrebare), în timp ce Visual Dialog necesită o interacțiune conversațională continuă,,,.

Exercițiul IA.2: Analiză Conceptuală (Compresia Informației)

Sursa afirmă că *Image Captioning* imită abilitatea umană de a "comprima cantități uriașe de informații vizuale în limbaj descriptiv",. Dați un exemplu simplu (nu din sursă) de o imagine care ar avea 1024×1024 pixeli (peste 1 milion de puncte de date vizuale) și o descriere care ar reprezenta compresia acestei informații.

Rezolvare IA.2:

- **Intrare Vizuală (Informație Extinsă):** O imagine 1024×1024 care prezintă o plajă vastă, marea albastră, o umbrelă roșie mică și o singură persoană citind pe șezlong. Peste 3 milioane de valori RGB stochează detaliile fiecărui val, fir de nisip și nuanță de culoare.
- **Ieșire Descriptivă (Informație Comprimată):** "O persoană citește sub o umbrelă roșie pe o plajă cu mare albastră." (Doar câteva zeci de caractere text comprimă milioane de puncte de date vizuale, concentrându-se pe elementele semantice cheie.)

Exercițiul IA.3: Aplicarea VQA (Selectivitatea Întrebărilor)

Pe baza definiției VQA, care implică întrebări care "vizează selectiv diferite zone ale unei imagini, incluzând detaliile de fundal și contextul implicit",, generați trei exemple de întrebări VQA pentru o imagine care arată un fotbalist (Messi) sărbătorind un gol pe un teren de fotbal, ilustrând această selectivitate.

Rezolvare IA.3:

1. **Selectivitate pe Detaliu/Obiect (Raționament Fin):** "Ce număr poartă pe tricou fotbalistul?"
2. **Selectivitate pe Fundal (Context):** "Ce culoare au scaunele din tribunele din spatele lui?"
3. **Selectivitate pe Context Implicit (Raționament Complex):** "Ce oră aproximativă a zilei sugerează umbra de pe gazon?"

8.1

Lecția **8.1 Show and Tell (NIC)** descrie modelul Neural Image Caption (NIC), o arhitectură inovatoare de rețea neuronală care realizează sarcina de descriere automată a imaginilor prin integrarea viziunii computerizate și a procesării limbajului natural (NLP). Modelul se inspiră din traducerea automată și utilizează o structură Encoder-Decoder, fiind antrenat *end-to-end*.

Ghid de Studiu Complet: 8.1 Show and Tell (Neural Image Caption - NIC)

1. 🎯 SINTEZA LECȚIEI (THE BIG PICTURE)

Modelul **Neural Image Caption (NIC)** reprezintă un model unic (*single joint model*) antrenat pentru a maximiza probabilitatea $p(S|I)$ de a produce o secvență țintă de cuvinte S care descrie adecvat imaginea de intrare I. Inspirația principală a NIC vine din **traducerea automată** bazată pe rețele recurente (RNN). Arhitectura adoptă structura Encoder-Decoder, dar înlocuiește Encoder-ul RNN folosit pentru limbaj cu un **CNN profund** care procesează imaginea. Modelul este antrenat *end-to-end* și folosește rețeaua **LSTM** pentru a genera propozițiile cuvânt cu cuvânt, condiționat de imaginea I și de cuvintele generate anterior.

Care sunt cele 5 idei principale pe care trebuie neapărat să le rețin?

1. **Arhitectura de Bază:** NIC utilizează un model Encoder-Decoder, unde **Encoder-ul este un CNN profund** (pentru viziune) și **Decoder-ul este o rețea LSTM** (pentru limbaj).
2. **Reprezentarea Imaginii:** CNN-ul transformă imaginea I într-un **vector cu lungime fixă**, care este folosit ca **stare ascunsă inițială** a LSTM la pasul $t = -1$.
3. **Modelarea Secvenței:** Generarea propoziției $S = S_0, \ldots, S_N$ este modelată ca un produs de probabilități condiționate $p(S|I) = \prod_{t=0}^{N} p(S_t|I, S_0, \ldots, S_{t-1})$.
4. **Parametrii:** Atât imaginea, cât și cuvintele sunt mapate în același spațiu folosind CNN și, respectiv, matricea de *word embedding* W_e. Dimensiunea *embeddings*-urilor și a memoriei LSTM este setată la **512**.
5. **Antrenament:** Ponderile CNN sunt inițializate cu ponderi **pre-antrenate pe ImageNet**, în timp ce restul ponderilor sunt inițializate aleatoriu.

---

2. 📖 REZUMAT DETALIAT (PE CAPITOLE/SECȚIUNI)

8.1 Show and Tell (NIC)

Obiectiv și Inspirație

- Neural Image Caption (NIC) reprezintă un model unic (*single joint model*) care ia o imagine I ca intrare.

- Obiectivul este maximizarea directă a probabilității $p(S|I)$ a descrierii corecte S dată imaginea I.
- Modelul este inspirat de **traducerea automată** bazată pe RNN-uri, unde un RNN encoder citește propoziția sursă și o transformă într-un vector, folosit ca stare ascunsă inițială a unui RNN decoder.

Arhitectura Encoder-Decoder (CNN și LSTM)

- NIC înlocuiește RNN encoder-ul cu un **CNN profund (*deep CNN*)**.
- CNN-urile produc o reprezentare bogată a imaginii de intrare, încorporând-o într-un **vector cu lungime fixă**.
- Acest vector este utilizat ca stare ascunsă inițială a unui **RNN decoder (LSTM)** care generează propoziția țintă.
- NIC este o rețea neuronală antrenabilă *end-to-end* pentru *image captioning*.
- Modelul combină sub-rețele pentru viziune și modele de limbaj care pot fi pre-antrenate pe corpusuri mari.

Modelarea Matematică a Secvenței

- Deoarece secvența $S = S_1, S_2, \ldots, S_N$ are o lungime nelimitată, probabilitatea comună $p(S|I)$ este modelată ca un produs de probabilități condiționate:

$$p(S|I) = {}_{t=0}^{N} p(S_t|I, S_0, \ldots, S_{t-1})$$

- Probabilitatea $p(S_t|I, S_0, \ldots, S_{t-1})$ este modelată folosind rețeaua **LSTM**.
- În versiunea desfășurată (*unrolled*), toate conexiunile recurente sunt transformate în conexiuni *feed-forward* (Figura 2).

Procesul Desfășurat și Maparea Spațiilor

- Imaginea I este introdusă **o singură dată la pasul** $t = -1$ pentru a informa LSTM despre conținutul ei.
  - S-a verificat empiric că alimentarea imaginii la fiecare pas de timp t duce la rezultate inferioare, rețeaua putând exploata zgomotul și supra-învăța mai ușor.
- **Mapare:** Atât imaginea (prin CNN), cât și cuvintele (prin matricea de *word embedding* W_e) sunt mapate în **același spațiu**.
- **Reprezentarea cuvântului:** Fiecare cuvânt S_t este un vector *one-hot* de dimensiune egală cu dimensiunea dicționarului.
- **Cuvinte Speciale:**
  - S_0: cuvânt special de start.
  - S_N: cuvânt special de stop, care semnalează că o propoziție completă a fost generată.
- **Ecuații de ieșire:**
  - Intrarea inițială a LSTM: $x_{-1} = CNN(I)$.

- Intrarea secvențială: $x_t = W_e S_t, \quad t \in 0, \ldots, N-1.$
- Starea următoare: $p_{t+1} = LSTM(x_t), \quad t \in 0, \ldots, N-1.$

Antrenament și Funcția de Pierdere

- **Funcția de pierdere** $L(I, S)$ este suma log-probabilității negative a cuvântului corect la fiecare pas:

$$L(I, S) = -\sum_{t=1}^{N} \log p_t(S_t)$$

- Această pierdere este minimizată în raport cu toți parametrii LSTM, stratul superior al CNN *image embedder* și *word embeddings* W_e.
- **Inițializarea Ponderilor:** Toate ponderile sunt inițializate aleatoriu, **cu excepția ponderilor CNN**, care au fost **pre-antrenate pe ImageNet**.
- **Dimensiunea Embeddings:** Dimensiunea pentru *embeddings* și dimensiunea memoriei LSTM au fost setate la **512**.

---

3. 💡 EXPLICAȚII SUPLIMENTARE ȘI CLARIFICĂRI (IMPORTANT)

Termen Tehnic: LSTM (Long Short-Term Memory)

- **Explicație Simplificată (Memoria Secvențială):** LSTM este un tip special de RNN, necesar deoarece propozițiile pot fi lungi. Dacă ar fi folosit un RNN simplu, acesta ar uita informațiile de la începutul propoziției până la sfârșit. LSTM are porți de control intern care îi permit să **rețină informațiile relevante** (imaginea I și cuvintele cheie) pe parcursul întregii secvențe de generare.

Concept Dificil: Maparea la Același Spațiu

- **Analogie (Dicționarul Comun):** CNN-ul transformă întreaga complexitate vizuală a imaginii (ex: "o pisică portocalie stă pe un covor roșu") într-un vector de 512 numere. Matricea W_e transformă cuvântul "pisică" tot într-un vector de 512 numere. Faptul că ambele sunt mapate la același spațiu de 512 dimensiuni permite sistemului să înțeleagă relația directă: vectorul care descrie imaginea este "vorbit" în același "limbaj numeric" în care sunt definite cuvintele.

Context Suplimentar: Rolul CNN Pre-antrenat

- *Asta se întâmplă deoarece:* Extracția de *feature*-uri vizuale este o problemă extrem de dificilă. Pre-antrenarea CNN-ului pe ImageNet (un set de date masiv pentru clasificare) asigură că partea de viziune a modelului (Encoder-ul) este deja extrem de eficientă în a

extrage **feature-uri vizuale bogate**, cum ar fi margini, texturi, și obiecte generice, înainte ca modelul să învețe cum să le combine în propoziții.

---

4. 🔗 CONEXIUNI ȘI IMPLICAȚII

- **Relația Cauză-Efect (Input-ul Imaginii la $t = -1$):**
  - **CAUZĂ:** Imaginea I este introdusă o singură dată la pasul $t = -1$.
  - **EFECT:** Rețeaua este forțată să învețe o reprezentare robustă, **evitând supra-învățarea** (*overfitting*) și exploatarea explicită a zgomotului din imagine.
- **Conexiunea cu NLP (Traducerea Automată):** NIC adaptează schema RNN Encoder-Decoder standard folosită în traducerea automată $p(T|S)$ pentru sarcina viziune-limbaj, înlocuind encoder-ul lingvistic cu un encoder vizual (CNN).

---

5. EXERCITII (Analiză Arhitecturală și Formule)

Exercițiul N.1: Analiză Arhitecturală (Fluxul de Informație)

Descrieți succesiunea logică a operațiilor de la intrarea imaginii I până la generarea primului cuvânt S_1 în modelul NIC, folosind referințe din ecuațiile procesului desfășurat.

Rezolvare N.1:

1. **Encoder (CNN):** Imaginea I este procesată de CNN pentru a produce vectorul cu lungime fixă, $x_{-1} = CNN(I)$. Acest vector este starea ascunsă inițială a LSTM.
2. **Start Word:** La pasul $t = 0$, LSTM primește vectorul de *embedding* al cuvântului special de start, S_0, care este mapat ca $x_0 = W_e S_0$.
3. **Decoder (LSTM):** LSTM-ul procesează x_0 și starea inițială (x_{-1}) pentru a genera probabilitățile de predicție pentru cuvântul următor ($p_1 = LSTM(x_0)$), care corespund primului cuvânt din propoziție, S_1.

Exercițiul N.2: Analiză Dimensională și Inițializare

1. Care este dimensiunea setată pentru *embeddings* și pentru memoria LSTM în modelul NIC?
2. Explicați de ce ponderile CNN sunt tratate diferit (pre-antrenate) față de ponderile LSTM și W_e (inițializate aleatoriu).

Rezolvare N.2:

1. **Dimensiunea Parametrilor:** Dimensiunea pentru *embeddings* și dimensiunea memoriei LSTM au fost setate la **512**.

2. **Inițializarea Ponderilor:** Ponderile CNN sunt pre-antrenate pe ImageNet pentru a asigura că modelul posedă deja o capacitate robustă de a extrage **feature-uri vizuale bogate** (cunoștințe vizuale generale). Ponderile LSTM și *word embeddings* (W_e) sunt inițializate aleatoriu deoarece acestea trebuie să învețe specific maparea viziune-limbaj și gramatica necesară pentru a descrie imaginile în contextul dat.

Exercițiul N.3: Calculul Funcției de Pierdere (Simulare)

Presupuneți că un model NIC generează o propoziție țintă S cu lungimea $N = 3$ (ignorând S_0 și S_N pentru simplitatea calculului). Funcția de pierdere se calculează pe cuvintele S_1, S_2, S_3.

Dacă probabilitățile logaritmice negative prezise de rețea pentru cuvintele corecte la fiecare pas sunt:

- $\log p_1(S_1) = -0.5$
- $\log p_2(S_2) = -0.7$
- $\log p_3(S_3) = -0.4$

Calculați pierderea totală $L(I, S)$ pentru această secvență.

Rezolvare N.3:

Funcția de pierdere este suma log-probabilității negative a cuvântului corect la fiecare pas:

$$L(I, S) = -\sum_{t=1}^{N} \log p_t(S_t)$$

$$\text{Pierderea} = [-(-0.5)] + [-(-0.7)] + [-(-0.4)]$$

$$\text{Pierderea} = 0.5 + 0.7 + 0.4$$

$$\mathbf{L(I, S) = 1.6}$$

8.2

Lecția **8.2 Long-term Recurrent Convolutional Networks (LRCNs)** prezintă o clasă de arhitecturi neuronale care extind principiul Encoder-Decoder (similar cu modelul NIC anterior) pentru a aborda sarcini complexe de viziune, cum ar fi adnotarea imaginilor și modelarea seriilor de timp vizuale (e.g., video).

Ghid de Studiu Complet: 8.2 Long-term Recurrent Convolutional Networks (LRCNs)

1. 🎯 SINTEZA LECȚIEI (THE BIG PICTURE)

Long-term Recurrent Convolutional Networks (LRCNs) reprezintă o clasă de arhitecturi versatile, proiectate pentru a îmbina forța rețelelor convoluționale (CNN) în recunoașterea vizuală cu capacitatea rețelelor recurente (RNN, în special LSTM) de a modela secvențe lungi și variabile. LRCN-urile sunt antrenabile *end-to-end* și sunt aplicabile la sarcini care necesită ieșiri de lungime variabilă, depășind predicțiile convenționale de tip unu-la-versus-toate. Arhitectura LRCN este un **analog multimodal** al modelelor de traducere automată bazate pe LSTM Encoder-Decoder. CNN-ul vizual codifică intrarea (imagine sau secvență video) într-un vector de stare profundă, iar LSTM-ul decodează acest vector într-un șir de limbaj natural. Succesul LRCN demonstrează că rețelele convoluționale cu unități recurente sunt aplicabile general la **modelarea seriilor de timp vizuale**.

Care sunt cele 5 idei principale pe care trebuie neapărat să le rețin?

1. **Arhitectură de Bază:** LRCN-urile combină straturi convoluționale (pentru recunoașterea vizuală) și recursivitate pe termen lung.
2. **Multimodal Analog:** Arhitectura urmează modelul Encoder-Decoder al traducerii automate, folosind un **CNN vizual** pentru codificare și un **LSTM** pentru decodare lingvistică.
3. **Aplicații:** Sunt utilizate pentru generarea de *caption*-uri de imagini, recunoașterea activității video specifice și descrierea video.
4. **Generalitate:** LRCN-urile demonstrează aplicabilitatea rețelelor convoluționale cu unități recurente la **modelarea vizuală a seriilor de timp**.
5. **Variante de Implementare:** Se pot utiliza stive de LSTM-uri (L straturi) și se poate explora **factorizarea modalităților**, unde straturile inferioare LSTM sunt condițional independente de intrarea vizuală.

---

2. 📖 REZUMAT DETALIAT (PE CAPITOLE/SECȚIUNI)

8.2 Long-term Recurrent Convolutional Networks (LRCNs)

Principii Fundamentale

- Modelele de *image captioning* trebuie să ofere **ieșiri de lungime variabilă** (descrieri de propoziții complete).
- LRCNs reprezintă o clasă de arhitecturi care combină straturi convoluționale și recursivitate pe termen lung, fiind **antrenabile *end-to-end***.
- LRCN-urile sunt aplicabile la modelarea vizuală a seriilor de timp.

Arhitectura și Fluxul de Date (Figura 3 și 4)

- **Intrare:** Intrarea vizuală x poate fi statică (o imagine) sau variabilă în timp (secvențe de imagini/video).

- **Feature Transformation ($\phi_V(x)$):** Intrarea vizuală trece printr-o transformare a *feature*-urilor (ϕ_V), realizată de un **CNN profund** (de obicei, modelul **VGG pre-antrenat pe ImageNet**).
- **Reprezentarea Ieșire:** CNN-ul produce o **reprezentare vectorială de lungime fixă** $\phi_V(x)$.
- **Sequence Learning Module:** Ieșirile ϕ_V sunt transmise unui modul recurent de învățare a secvențelor, format dintr-o **stivă de LSTM-uri**.

Modelarea Secvenței de Limbaj

- Problema *image captioning* este maparea unei imagini statice x la o secvență de ieșire $\langle y_1, y_2, \ldots, y_T \rangle$, care este un spațiu de etichete mult mai mare și mai bogat, constând din propoziții de orice lungime.
- **Intrarea la Pasul t:** La fiecare pas de timp t, *feature*-urile imaginii și cuvântul anterior sunt furnizate ca intrări pentru modelul de secvență.
- **Codificarea Cuvintelor:** Cuvintele de intrare sunt codificate ca **vectori *one-hot*** ($y \in \mathbb{R}^K$, unde K este numărul de cuvinte din vocabular).
- **Embedding Space:** Acești vectori *one-hot* sunt proiectați într-un spațiu de *embedding* de dimensiune d_e prin înmulțirea cu o matrice de parametri învățată $W_e \in \mathbb{R}^{d_e \times K}$. Matricea W_e acționează ca o "tabelă de căutare" (*lookup table*).
- **Token-uri Speciale:** Se folosește token-ul $\langle BOS \rangle$ (începutul secvenței) ca intrare la primul pas de timp ($t = 1$, luat ca y_0) și token-ul $\langle EOS \rangle$ (sfârșitul secvenței) pentru a indica încheierea unei descrieri de lungime variabilă.

Predicția Ieșirii

- Ieșirile finalului LSTM din stivă sunt intrările pentru un strat liniar de predicție, urmat de o funcție **softmax**.
- Softmax-ul produce o distribuție de probabilitate $P(y_t)$ peste cuvintele din vocabular (inclusiv $\langle EOS \rangle$) la pasul t.

Variante Arhitecturale (Figura 5)

Sunt explorate diferite adâncimi ale stivei LSTM (L) și efectul **factorizării modalităților**:

- **Unfactored (LRCN$_{2u}$):** Reprezentarea *feature*-urilor vizuale $\phi_V(x)$ este concatenată la cuvântul anterior *embedded* ($W_e y_{t-1}$) și alimentată către **primul LSTM din stivă**.
- **Factored (LRCN$_{2f}$):** Reprezentarea vizuală $\phi_V(x)$ este alimentată numai către LSTM-urile începând de la un strat $\ell \geq 2$. Acest lucru "orbește" straturile inferioare ($\ell = 1$ până la $\ell - 1$) de intrarea vizuală, forțând stările ascunse ale acestora să reprezinte **doar *caption*-ul parțial** (y_{1t-1}), fiind condițional independente de intrarea vizuală x.

Antrenare și Inferență

- **Antrenare:** La antrenare, cuvintele de intrare anterioare (y_{1t-1}) la pasul t sunt luate din ***caption***-ul ***ground truth***.
- **Inferență:** La inferență, cuvântul de intrare y_t este eșantionat din distribuția de probabilitate prezisă de model la pasul anterior, iar generarea continuă până când este prezis token-ul $\langle EOS \rangle$.

---

3. 💡 EXPLICAȚII SUPLIMENTARE ȘI CLARIFICĂRI (IMPORTANT)

Termen Tehnic: Multi-modal Analog

- **Explicație Simplificată (Schimbarea Limbii):** Modelele clasice de traducere automată (Encoder-Decoder) transformă o secvență dintr-o limbă (ex., engleză) în alta (ex., franceză). Ambele sunt secvențe text. LRCN este un **analog multimodal** deoarece tratează viziunea (imaginea/pixelii) ca pe o "limbă" de intrare și limbajul natural (textul) ca pe "limbă" de ieșire.

Concept Dificil: Factoring the Modalities (Factorizarea Modalităților)

- **Analogie (Divizarea Muncii):** Imaginați-vă o echipă de doi scriitori (straturi LSTM) care scriu o descriere:
  - **Scriitorul 1 (Stratul inferior):** Este responsabil cu logica propoziției (gramatică și vocabular), primind doar ultimul cuvânt scris. El *nu* se uită la imagine.
  - **Scriitorul 2 (Stratul superior):** Primește logica propoziției de la Scriitorul 1 *și* primește direct intrarea vizuală (imaginea). El este responsabil cu asigurarea faptului că propoziția corespunde imaginii.
- *Asta se întâmplă deoarece:* Prin "orbirea" straturilor inferioare de intrarea vizuală, factorizarea impune o **separare a responsabilităților**. Straturile inferioare se concentrează pe reprezentarea *caption*-ului parțial (modelul lingvistic), iar cele superioare fuzionează starea lingvistică cu *feature*-urile vizuale pentru a produce predicția următoare.

---

4. 🔗 CONEXIUNI ȘI IMPLICAȚII

- **Conexiunea cu Secțiunea 8.1 (NIC):** LRCN este o generalizare și rafinare a modelului NIC (care este, de fapt, o instanțiere specifică a LRCN). Ambele folosesc structura CNN Encoder / LSTM Decoder. Totuși, LRCN pune accentul pe aplicabilitatea sa la **modelarea seriilor de timp vizuale** (video), nu doar imagini statice.

- **Implicația Temporală:** Faptul că LRCN poate aplica convoluții cu unități recurente la **serii de timp vizuale** (Figura 3) arată o legătură directă cu recunoașterea temporală a evenimentelor, deschizând calea pentru sarcini precum descrierea automată a secvențelor video.
- **Curbă de Învățare (LSTM):** Sursa notează că RNN-urile de tip LSTM pot oferi o îmbunătățire semnificativă în sarcinile vizuale atunci când sunt disponibile **date de antrenare ample** pentru a învăța sau rafina reprezentarea.

---

5. EXERCITII (Calcul și Analiză)

Exercițiul L.1: Analiza Dimensională a Word Embedding

Se presupune un vocabular de $K = 10.000$ de cuvinte (plus token-urile speciale). Se utilizează o stivă LRCN cu *embedding* space $d_e = 512$.

1. Determinați dimensiunea vectorului *one-hot* de intrare y.
2. Determinați dimensiunea matricei de parametri învățată W_e care realizează proiecția vectorului *one-hot* în spațiul de *embedding*.
3. Care este semnificația operației $W_e y_t$?,

Rezolvare L.1:

1. **Dimensiunea Vectorului One-Hot (y):** Dimensiunea vectorului *one-hot* este egală cu numărul de cuvinte din vocabular, $K = \mathbf{10.000}$.
2. **Dimensiunea Matricei de Embedding (W_e):** W_e trebuie să mapeze un vector de 10.000 de dimensiuni la un vector de 512 dimensiuni. Prin urmare, dimensiunea matricei W_e este $\mathbf{512} \times \mathbf{10.000}$.
3. **Semnificația Operației $W_e y_t$:** Deoarece y_t este un vector *one-hot* (cu o singură componentă non-zero egală cu 1), operația $W_e y_t$ extrage coloana matricei W_e care corespunde indexului cuvântului actual. Această operație proiectează cuvântul în **spațiul de *embedding* de dimensiune d_e**.

Exercițiul L.2: Analiza Comparativă Factored vs. Unfactored

Se compară arhitecturile LRCN$_{2u}$ (Unfactored, $L = 2$) și LRCN$_{2f}$ (Factored, $L = 2$).

1. Descrieți unde anume în stiva LSTM este alimentată intrarea vizuală $\phi_V(x)$ în cazul **Unfactored**.
2. Care este scopul "factorizării" în cazul **Factored** și ce impune această arhitectură asupra stării ascunse (h_t) a stratului LSTM inferior?,

Rezolvare L.2:

1. **Fluxul Unfactored:** În cazul Unfactored, reprezentarea vizuală $\phi_V(x)$ este concatenată la *embedding*-ul cuvântului anterior ($W_e y_{t-1}$) și alimentată către **primul LSTM din stivă**.
2. **Scopul Factorizării:** Scopul factorizării este de a forța o **separare a responsabilităților** (separating the responsibilities) între straturile LSTM. Factorizarea impune ca starea ascunsă h_t a straturilor LSTM inferioare să reprezinte **doar *caption*-ul parțial** (y_{1t-1}), fiind astfel **condițional independentă** de intrarea vizuală x (dat fiind *caption*-ul parțial).

Exercițiul L.3: Inferența de Lungime Variabilă

Cum decide un model LRCN, în timpul fazei de **inferență** (generarea unei descrieri pentru o imagine nouă), când să se oprească din generarea cuvintelor, asigurând astfel o ieșire de lungime variabilă?,

Rezolvare L.3:

Modelul LRCN asigură o ieșire de lungime variabilă prin includerea token-ului special $\langle EOS \rangle$ **(end of sequence)** în vocabularul său. În timpul inferenței, generarea cuvintelor continuă pas cu pas, luând ca intrare predicția modelului din pasul anterior, până când modelul prezice token-ul $\langle EOS \rangle$. Softmax-ul de pe stratul liniar final include o distribuție de probabilitate peste acest token.

8.3

Suntem la lecția **8.3 Deep Visual-Semantic Alignments**, care explorează o abordare avansată pentru generarea de descrieri dense și detaliate ale regiunilor de imagine, concentrându-se pe problema dificilă a alinierii elementelor vizuale (obiecte) cu segmentele de cuvinte corespunzătoare (fraze) în absența etichetelor explicite de localizare.

Ghid de Studiu Complet: 8.3 Deep Visual-Semantic Alignments (Alinieri Vizual-Semantice Profunde)

1. 🎯 SINTEZA LECȚIEI (THE BIG PICTURE)

Obiectivul principal al acestei lucrări este de a face un pas către generarea de **descrieri dense ale regiunilor de imagine**. O provocare practică este că seturile de date de *caption*-uri de imagini sunt disponibile în cantități mari, dar aceste descrieri menționează adesea **mai multe entități ale căror locații în imagine sunt necunoscute**. Ideea centrală (core insight) este că aceste seturi de date mari, care conțin perechi imagine-propoziție, pot fi valorificate prin tratarea propozițiilor ca **etichete slabe (*weak labels*)**, în care segmentele de cuvinte contigue corespund unei locații particulare, dar necunoscute. Abordarea constă în inferarea acestor alinieri latente (de exemplu, cuvintele "Tabby cat is leaning" se referă la pisică) și utilizarea lor pentru a învăța un model generativ de descrieri. Modelul folosește o rețea **Region CNN (RCNN)** pentru a detecta regiunile imaginii și o **Rețea Recurentă**

Bidirecțională (BRNN) pentru a îmbogăți reprezentarea cuvintelor cu contextul propoziției, mapând ambele modalități într-un **spațiu de *embedding* multimodal comun**.

Care sunt cele 5 idei principale pe care trebuie neapărat să le rețin?

1. **Scopul Final:** Generarea de **descrieri ale regiunilor de imagine**.
2. **Etichete Slabe (Weak Labels):** Propozițiile descriptive sunt tratate ca etichete slabe, deoarece segmentele contigue de cuvinte corespund unei locații necunoscute în imagine.
3. **Componenta Vizuală (RCNN):** Obiectele și atributele din imagini sunt detectate folosind o rețea **RCNN**, iar primele **19 locații detectate** (plus imaginea întreagă) sunt folosite pentru a crea 20 de vectori vizuali v_i.
4. **Componenta Lingvistică (BRNN):** Pentru a capta contextul propoziției (care nu este considerat de maparea directă a cuvintelor), se folosește o **Rețea Recurentă Bidirecțională (BRNN)**. Reprezentarea finală s_t a cuvântului t este o funcție a cuvântului în sine și a contextului său înconjurător.
5. **Obiectivul de Aliniere:** Supervizarea are loc la nivelul perechilor imagine-propoziție, fiind formulată o funcție de scor *image-sentence* bazată pe scorurile individuale regiune-cuvânt (prin produs scalar $v_i^T s_t$).

---

2. 📖 REZUMAT DETALIAT (PE CAPITOLE/SECȚIUNI)

8.3 Deep Visual-Semantic Alignments – Provocări și Abordare

- **Provocarea Principală:** Crearea unui model suficient de bogat pentru a **raționa simultan despre conținutul imaginii și reprezentarea sa în limbajul natural**. Modelul trebuie să fie liber de șabloane (*hard-coded templates*) și să se bazeze exclusiv pe învățarea din datele de antrenament.
- **Intrare:** În timpul antrenamentului, intrarea este un set de imagini și descrierile corespunzătoare la nivel de propoziție.
- **Abordare (Două Etape):**
  1. Se introduce un model care **aliniază segmentele de propoziție la regiunile vizuale** prin intermediul unui *embedding* multimodal.
  2. Aceste corespondențe sunt tratate ca date de antrenament pentru un al doilea model **RNN multimodal** care învață să genereze segmentele.

Reprezentarea Vizuală (Encoder Vizual)

- **Detectarea Obiectelor:** Deoarece descrierile fac referiri frecvente la obiecte și atribute, obiectele sunt detectate în fiecare imagine cu o rețea **Region Convolutional Neural Network (RCNN)**.
- **Pre-antrenare:** CNN-ul este pre-antrenat pe ImageNet.

- **Vectorul Vizual (v):** Se folosesc **primele 19 locații detectate** plus imaginea întreagă, rezultând 20 de reprezentări. Reprezentările se bazează pe pixelii I_b din interiorul fiecărei cutii de delimitare (*bounding box*).
- **Calculul Vectorului Vizual:**

$$v = W_m[CNN_{\theta_c}(I_b)] + b_m$$

  - $CNN_{\theta_c}(I_b)$ transformă pixelii din cutia I_b în activări de **4096 de dimensiuni** ale stratului complet conectat imediat anterior clasificatorului.
  - Parametrii CNN θ_c conțin aproximativ **60 de milioane de parametri**.
  - Matricea W_m are dimensiuni $h \times 4096$, unde h este dimensiunea spațiului de *embedding* multimodal.
- **Ieșire:** Fiecare imagine este reprezentată ca un set de 20 de vectori h-dimensionali v_i, unde h variază între **1000 și 1600**.

Reprezentarea Lingvistică (Encoder Lingvistic)

- **Obiectiv:** De a reprezenta cuvintele în același spațiu de *embedding* h-dimensional ca și regiunile de imagine.
- **Problema Soluției Naive:** Proiectarea directă a fiecărui cuvânt individual nu consideră ordinea sau **contextul** cuvântului în propoziție.
- **Soluție (BRNN):** O **Rețea Recurentă Bidirecțională (BRNN)** este utilizată pentru a calcula reprezentările cuvintelor, luând o secvență de N cuvinte (codificate 1-din-k) și transformând fiecare cuvânt într-un vector h-dimensional.
- **Îmbogățirea Contextului:** Reprezentarea fiecărui cuvânt este îmbogățită de un context de mărime variabilă în jurul acelui cuvânt.
- **Formula BRNN (Pasul t):** BRNN folosește două fluxuri de procesare independente: unul de la stânga la dreapta (h_t^f) și unul de la dreapta la stânga (h_t^b).
  - Reprezentarea finală h-dimensională s_t pentru cuvântul t este o funcție a cuvântului la acea locație și a **contextului său înconjurător** în propoziție.

Scorul de Aliniere și Funcția de Pierdere

- **Similaritate Regiune-Cuvânt:** Produsul scalar $v_i^T s_t$ între regiunea i și cuvântul t este interpretat ca o **măsură de similaritate**. Această cantitate poate fi interpretată ca log-probabilitatea nenormalizată a cuvântului t care descrie orice *bounding box*.
- **Scorul Imagine-Propoziție (S_{kl}):** Scorul total S_{kl} între imaginea k și propoziția l este definit în forma simplificată ca fiind suma scorurilor maxime pentru fiecare cuvânt s_t:

$$S_{kl} = \sum_{t \in g_l} \max_{i \in g_k} v_i^\top s_t$$

  - Aici, fiecare cuvânt s_t se aliniază la **cea mai bună regiune unică de imagine**.
- **Funcția de Pierdere (Max-Margin):** Obiectivul de antrenament (pierderea $C(\theta)$) este de tip *max-margin* structurat, care încurajează perechile imagine-propoziție aliniate corect (

S_{kk}) să aibă un scor mai mare decât perechile nealiniate (S_{kl} sau S_{lk}) cu o marjă.

Inferarea Alinierilor Latente (MRF)

- **Problema Alinierii Naive:** O soluție naivă de a alinia fiecare cuvânt independent la regiunea cu cel mai mare scor este insuficientă, deoarece duce la cuvinte împrăștiate inconsecvent în regiuni diferite (ex: "tabby", "cat", "is" se duc în regiuni separate).
- **Soluția MRF:** Adevăratele alinieri sunt tratate ca **variabile latente** într-un **Markov Random Field (MRF)** cu structură de lanț de-a lungul propoziției.
- **Energia MRF:** $E(\mathbf{a})$ include potențiali unari ^{U} (scorul regiune-cuvânt) și potențiali binari ^{B} (care încurajează interacțiunile binare între cuvintele vecine să se alinieze la aceeași regiune).
  - Potențialul binar $^{B}(a_j, a_{j+1}) = \beta \mathbf{1}_{a_j = a_{j+1}}$.
- **Parametrul β:** Este un hiperparametru care controlează afinitatea față de frazele mai lungi.
  - $\beta = 0$: aliniază cuvintele individual (single-word alignments).
  - β mare: aliniază întreaga propoziție la o singură regiune cu scor maxim.
- **Minimizare:** Energia este minimizată pentru a găsi cele mai bune alinieri $\mathbf{a}$ folosind **programarea dinamică**.

---

3. 💡 EXPLICAȚII SUPLIMENTARE ȘI CLARIFICĂRI (IMPORTANT)

Termen Tehnic: Bidirectional Recurrent Neural Network (BRNN)

- **Explicație Simplificată (Cititul Invers):** Un RNN standard citește o propoziție doar de la stânga la dreapta, ca noi. O BRNN citește și de la **dreapta la stânga** (fluxul h^b) simultan cu citirea normală (h^f). Această dublă citire asigură că reprezentarea cuvântului (s_t) la poziția t include contextul **complet** (ce a venit înainte *și* ce urmează după), ceea ce este crucial pentru a înțelege semnificația exactă a cuvântului.

Concept Dificil: Max-Margin Structured Loss

- **Analogie (Competiția):** Pierderea *Max-Margin* este ca un sistem de notare unde perechea corectă (imaginea k și descrierea k) trebuie să câștige concursul de similaritate împotriva oricărei perechi greșite (imaginea k și descrierea l, sau imaginea l și descrierea k) cu o **marjă** fixă (în formulă, +1). Dacă scorul perechii greșite este prea mare, penalizarea (pierderea) se activează pentru a forța modelul să le distanțeze.

Context Suplimentar: MRF ca soluție la Alinierea Inconsecventă

- *Asta se întâmplă deoarece:* Deși scorul $v_i^T s_t$ poate fi mare pentru cuvântul "cat" în regiunea 1 și pentru cuvântul "is" în regiunea 5 (din cauza zgomotului), fraza "The cat is" este un segment contigu. MRF (prin potențialul binar ^{B} controlat de β) introduce o **penalizare** dacă cuvintele vecine din propoziție se aliniază la regiuni vizuale diferite. Acest lucru forțează modelul să grupeze cuvintele contigue în segmente vizuale coerente.

---

4. 🔗 CONEXIUNI ȘI IMPLICAȚII

- **Relația Cauză-Efect (Lipsa de Localizare):**
  - **CAUZĂ:** Propozițiile sunt tratate ca etichete slabe, locațiile vizuale ale obiectelor fiind necunoscute.
  - **EFECT:** Necesitatea de a utiliza **modele complexe de aliniere (MRF)** care inferă aceste corespondențe latente între fragmentele de propoziție și regiunile vizuale.
- **Conexiunea cu Detecția Obiectelor:** Această lucrare depinde de rezultatele Detecției Obiectelor (RCNN) pentru a furniza cele 19+1 locații de interes (vectorii v_i), arătând cum sarcinile de viziune de nivel scăzut sunt integrate în sarcinile de limbaj de nivel înalt.

---

5. EXERCITII (Calcul și Analiză Formulistică)

Exercițiul A.1: Analiză Dimensională Vizuală

Un model Deep Visual-Semantic Alignments folosește un spațiu de *embedding* multimodal $h = 1000$.

1. Care este dimensiunea vectorului de *feature*-uri obținut de CNN ($CNN_{\theta_c}(I_b)$) înainte de maparea în spațiul h-dimensional?
2. Care este dimensiunea matricei de mapare W_m?

Rezolvare A.1:

1. **Dimensiunea Feature-urilor CNN:** Vectorul *feature* este obținut din activările stratului complet conectat imediat anterior clasificatorului, având dimensiunea de **4096**.
2. **Dimensiunea Matricei W_m:** Matricea W_m mapează spațiul de 4096 la spațiul h-dimensional de 1000. Dimensiunile sale sunt $\mathbf{1000} \times \mathbf{4096}$.

Exercițiul A.2: Calculul Scorului Simplificat

Presupuneți o imagine k cu 3 regiuni vizuale (v_1, v_2, v_3) și o propoziție l cu 2 cuvinte (s_1, s_2). Vectorii sunt normalizați pentru simplitate.

Produsul scalar $v_i^T s_t$ este dat în următoarea matrice de scoruri:

$v_i^T s_t$	s_1 (Word A)	s_2 (Word B)
v_1	0.8	0.1
v_2	0.5	0.9
v_3	0.2	0.3

Calculați scorul total Imagine-Propoziție S_{kl} folosind formula simplificată: $S_{kl} = \sum_{t \in g_l} \max_{i \in g_k} v_i^\top s_t$.

Rezolvare A.2:

Scorul S_{kl} este suma scorurilor maxime pentru fiecare cuvânt:

1. **Pentru cuvântul s_1 (Word A):** $\max(0.8, 0.5, 0.2) = 0.8$
2. **Pentru cuvântul s_2 (Word B):** $\max(0.1, 0.9, 0.3) = 0.9$

$$S_{kl} = 0.8 + 0.9 = \mathbf{1.7}$$

Exercițiul A.3: Analiza Hiperparametrului MRF (β)

Explicați rolul hiperparametrului β în funcția de energie MRF $E(\mathbf{a})$. Ce se întâmplă cu alinierea segmentelor de cuvinte contigue atunci când:

1. $\beta = 0$
2. β este un număr mare?

Rezolvare A.3:

Parametrul β este un hiperparametru care controlează **afinitatea (*affinity*) către frazele mai lungi**.

1. **Când $\beta = 0$:** Potențialul binar ^{B} devine zero, eliminând interacțiunea dintre cuvintele vecine. Acest lucru duce la **alinieri la nivel de cuvânt individual** (*single-word alignments*), ignorând coerența frazei.
2. **Când β este mare:** Potențialul binar devine dominant, încurajând puternic cuvintele vecine să se alinieze la aceeași regiune. Acest lucru poate forța **întreaga propoziție să se alinieze la o singură regiune** cu scor maxim.

8.4

Suntem la lecția **8.4 Visual Question Answering (VQA)**, care detaliază arhitectura unui model de inteligență artificială cu două canale, special conceput pentru a răspunde la întrebări în limbaj natural despre conținutul unei imagini.

Ghid de Studiu Complet: 8.4 Visual Question Answering (VQA)

1. 🎯 SINTEZA LECȚIEI (THE BIG PICTURE)

Sarcina VQA (Visual Question Answering) presupune construirea unui model capabil să ofere un răspuns la o întrebare în limbaj natural bazată pe o imagine dată. Pentru a realiza acest lucru, este construit un model cu **două canale**: Canalul Imaginii (pentru viziune) și Canalul Întrebării (pentru limbaj). Reprezentările *embedding* obținute din aceste două canale sunt combinate și introduse într-un **Multi-Layer Perceptron (MLP)** care, în final, produce o distribuție Softmax peste un set K de răspunsuri posibile. Modelul este antrenat *end-to-end* cu o funcție de pierdere *cross-entropy*. Setul de date VQA utilizat conține aproximativ 0.25M imagini, 0.76M întrebări și 10M răspunsuri. Pentru simplificare, modelul alege cele $K = 1000$ **cele mai frecvente răspunsuri** ca ieșiri posibile, acoperind 82.67% din totalul răspunsurilor de antrenare și validare.

Care sunt cele 5 idei principale pe care trebuie neapărat să le rețin?

1. **Arhitectură Bicanal:** Modelul funcționează cu două canale separate (Viziune/Imagine și Limbaj/Întrebare) care furnizează *embeddings*.
2. **Ieșirea (Clasificarea):** Modelul oferă un răspuns final prin clasificare Softmax peste $K = 1000$ de răspunsuri posibile, cele mai frecvente.
3. **Canalul Imaginii:** Utilizează activările stratului ascuns final al rețelei VGG, în două variante: activări brute (4096-dimensional) sau activări normalizate l_2.
4. **Canalul Întrebării:** Utilizează rețele **LSTM** (cu 1 sau 2 straturi ascunse) pentru a obține *embedding*-uri de 1024-dimensionali sau 2048-dimensionali, bazate pe concatenarea stărilor celulare și a stărilor ascunse.
5. **Fuziunea și Clasificarea:** *Embeddings*-urile transformate sunt combinate (prin înmulțire element cu element) și introduse într-un **MLP** cu 2 straturi ascunse și 1000 de unități ascunse (cu *dropout* 0.5), urmat de Softmax.

---

2. 📖 REZUMAT DETALIAT (PE CAPITOLE/SECȚIUNI)

8.4 Visual Question Answering – Setul de Date și Obiectiv

- **Set de Date VQA:** Conține aproximativ **0.25M imagini**, **0.76M întrebări** și **10M răspunsuri**.
- **Ieșiri Posibile (K):** Cele $K = 1000$ **cele mai frecvente răspunsuri** sunt alese ca ieșiri posibile.
- Acest set de 1000 de răspunsuri acoperă **82.67%** din răspunsurile din seturile de antrenare și validare VQA.

- Obiectivul este de a performa VQA printr-un model cu două canale (viziune și limbaj) care culminează cu un Softmax peste K ieșiri posibile.

Canalul Imaginii (Image Channel)

Canalul Imaginii furnizează un *embedding* pentru imagine. Sunt utilizate două tipuri de *embeddings*:

1. **I:** Activările de la ultimul strat ascuns al rețelei VGG sunt folosite ca *embedding* al imaginii de **4096 de dimensiuni**.
2. **norm I:** Acestea sunt activările normalizate l_2 de la ultimul strat ascuns al rețelei VGG.

Canalul Întrebării (Question Channel)

Canalul Întrebării furnizează un *embedding* pentru întrebare. Sunt utilizate două tipuri de *embeddings*, ambele bazate pe LSTM:

1. **LSTM Q:**
   - Se folosește un LSTM cu **un singur strat ascuns** pentru a obține un *embedding* de **1024 de dimensiuni** pentru întrebare.
   - *Embedding*-ul este o **concatenare a stării celulare finale (*last cell state*) și a reprezentărilor stării ascunse finale (*last hidden state*)** de la stratul ascuns al LSTM.
   - Fiecare cuvânt al întrebării este codificat cu un *embedding* de **300 de dimensiuni** printr-un strat complet conectat și o neliniaritate *tanh*, înainte de a fi alimentat către LSTM.
   - Vocabularul de intrare pentru *embedding* constă din toate cuvintele din întrebări observate în setul de antrenare.
2. **deeper LSTM Q:**
   - Se folosește un LSTM cu **două straturi ascunse** pentru a obține inițial un *embedding* de **2048 de dimensiuni** pentru întrebare.
   - *Embedding*-ul de 2048 de dimensiuni este obținut prin concatenarea stării celulare finale și a stărilor ascunse finale din **ambele straturi ascunse** ale LSTM.
   - Calculul dimensionalității este: 2 (straturi ascunse) $\times$ 2 (stare celulară + stare ascunsă) $\times$ 512 (dimensionalitatea fiecărei stări celulare și ascunse) $= 2048$.
   - Acest *embedding* de 2048 de dimensiuni este apoi transformat în **1024 de dimensiuni** printr-un strat complet conectat și o neliniaritate *tanh*.
   - Cuvintele întrebării sunt codificate în același mod ca în LSTM Q.

Fuziunea și Clasificarea (MLP)

- **Transformarea Imaginii:** Pentru a se potrivi cu *embedding*-ul LSTM al întrebării (1024 de dimensiuni), *embedding*-ul imaginii este transformat inițial la **1024 de dimensiuni** printr-un strat complet conectat și o neliniaritate *tanh*.

- **Fuziunea:** *Embeddings*-urile transformate ale imaginii și LSTM sunt **fuzionate prin înmulțire element cu element** (*element-wise multiplication*), deoarece se află într-un spațiu comun.
- **Clasificatorul Final (MLP):** *Embedding*-ul combinat (imagine + întrebare) este transmis unui **MLP (Multi-Layer Perceptron)**.
  - MLP-ul este un clasificator de rețea neuronală complet conectată cu **2 straturi ascunse** și **1000 de unități ascunse**.
  - Se aplică *dropout* **0.5** în fiecare strat ascuns, urmat de neliniaritatea *tanh*.
  - Stratul final este un strat **Softmax** care produce o distribuție peste cele K răspunsuri.
- **Antrenament:** Întregul model este învățat *end-to-end* cu o **pierdere *cross-entropy***.
- **Ponderile VGG:** Parametrii rețelei VGG sunt **înghețați (*frozen*)** la cei învățați din clasificarea ImageNet și **nu sunt *fine-tuned*** în canalul imaginii.

---

3. 💡 EXPLICAȚII SUPLIMENTARE ȘI CLARIFICĂRI (IMPORTANT)

Termen Tehnic: Concatenarea Stării Celulare (Cell State) și Stării Ascunse (Hidden State)

- **Explicație Simplificată (Memoria Dublă a LSTM):** LSTM-ul are două tipuri de "memorie" la fiecare pas:
  1. **Starea Ascunsă (h):** Aceasta este ieșirea pe termen scurt, folosită pentru a calcula ieșirea la pasul curent.
  2. **Starea Celulară (c):** Aceasta este "autostrada" internă de informații pe termen lung.
- *Asta se întâmplă deoarece:* Prin concatenarea ambelor stări finale, modelul VQA se asigură că *embedding*-ul întrebării conține atât informațiile contextuale pe termen lung (din starea celulară), cât și cele pe termen scurt/ultima ieșire (din starea ascunsă), rezultând o reprezentare lingvistică mai completă.

Concept Dificil: Înmulțirea Element cu Element (Element-wise Multiplication) pentru Fuziune

- **Analogie (Filtru de Relevanță):** După ce *embedding*-ul imaginii și cel al întrebării sunt transformate în același spațiu (1024-dimensional), ele sunt fuzionate prin înmulțire element cu element. Aceasta nu este o simplă adunare sau concatenare. Înmulțirea element cu element acționează ca un **filtru**: dimensiunile din vectorul imaginii care sunt irelevante pentru întrebare vor fi atenuate (multiplicate cu o valoare mică din vectorul întrebării) și invers.
- *Asta se întâmplă deoarece:* Această metodă de fuziune forțează modelul să găsească **interacțiunile multimodale** cele mai relevante. De exemplu, dacă întrebarea este

despre culoare, doar dimensiunile din *embedding*-ul imaginii care codifică informații despre culoare vor rămâne puternice în vectorul combinat.

---

4. 🔗 CONEXIUNI ȘI IMPLICAȚII

- **Relația Cauză-Efect (Ponderile VGG Înghețate):**
  - **CAUZĂ:** Ponderile VGG sunt înghețate (*frozen*) la cele învățate din clasificarea ImageNet.
  - **EFECT:** Modelul nu trebuie să învețe *feature*-uri vizuale de la zero. El se bazează pe cunoștințele vizuale generale pre-existente ale VGG, permițând modelului să se concentreze doar pe învățarea **mapării multimodale** (imagine + întrebare $\rightarrow$ răspuns).
- **Conexiunea cu Secțiunea 8.1 (NIC):** Similar cu NIC, VQA utilizează un CNN (VGG) pre-antrenat pentru a genera un *embedding* vizual și un LSTM pentru a procesa informațiile textuale. Totuși, VQA folosește LSTM pentru *întrebare* (intrare) și nu pentru generarea *propoziției* (ieșire), fiind o sarcină de clasificare.

---

5. EXERCITII (Calcul și Analiză Arhitecturală)

Exercițiul V.1: Calculul Dimensionalității LSTM

Se consideră arhitectura **deeper LSTM Q** (LSTM cu două straturi ascunse).

1. Câți parametri de stare (stări celulare și stări ascunse) trebuie concatenați de la fiecare strat ascuns (din cele două) pentru a forma *embedding*-ul brut al întrebării?
2. Dacă dimensionalitatea fiecărei stări (celulară și ascunsă) este de 512, confirmați dimensionalitatea brută totală a *embedding*-ului înainte de transformarea finală.

Rezolvare V.1:

1. **Parametri per Strat Ascuns:** Fiecare strat ascuns contribuie cu 1 stare celulară și 1 stare ascunsă, adică un total de **2 stări** per strat.
2. **Dimensionalitatea Brută Totală:** Dimensionalitatea totală este calculată ca: 2 (straturi ascunse) $\times$ 2 (stare celulară + stare ascunsă) $\times$ 512 (dimensiunea stării) $= \mathbf{2048}$ de dimensiuni.

Exercițiul V.2: Analiza Stratului Final de Clasificare

1. Care este dimensionalitatea de intrare a MLP-ului final de clasificare?
2. Cum este transformat acest *embedding* final pentru a obține o distribuție de probabilitate peste K răspunsuri?

Rezolvare V.2:

1. **Dimensionalitatea de Intrare a MLP:** MLP-ul primește *embedding*-ul combinat (imagine + întrebare), care rezultă din înmulțirea element cu element a doi vectori de 1024 de dimensiuni. Prin urmare, dimensionalitatea de intrare a MLP-ului este de **1024 de dimensiuni**.
2. **Transformarea pentru Probabilitate:** *Embedding*-ul combinat trece prin 2 straturi ascunse (cu 1000 de unități și *tanh*) și în final, printr-un strat **Softmax**, care produce o distribuție de probabilitate peste cele K răspunsuri posibile.

Exercițiul V.3: Analiza Setului de Răspunsuri

Setul de date VQA conține aproximativ 10M răspunsuri.

1. Câte răspunsuri sunt excluse din setul de antrenare și validare dacă se folosesc doar $K = 1000$ cele mai frecvente răspunsuri, presupunând că cele $K = 1000$ acoperă 82.67% din totalul răspunsurilor de antrenare/validare?
2. Explicați de ce cercetătorii aleg să se limiteze la $K = 1000$ răspunsuri în loc să clasifice peste toate răspunsurile unice.

Rezolvare V.3:

1. **Răspunsuri Excluse (Procentual):** Procentul de răspunsuri excluse este 100. (Deși numărul exact de răspunsuri unice nu este dat, procentajul se referă la acoperirea totală a răspunsurilor din setul de antrenare și validare).
2. **Justificarea Limitei $K = 1000$:** Limitarea la $K = 1000$ cele mai frecvente răspunsuri simplifică sarcina de VQA dintr-o problemă de generare de text deschis (*open-ended generation*) într-o problemă de **clasificare** peste un set finit de ieșiri. Aceasta crește eficiența antrenamentului și reduce complexitatea modelului, acoperind totuși o majoritate semnificativă (82.67%) din datele de antrenare și validare.

8.5

Suntem la lecția **8.5 Visual Dialog**, care prezintă o arhitectură complexă de tip Encoder-Decoder menită să permită agenților AI să poarte un dialog conversațional, bazat pe o imagine și un istoric al discuției.

Ghid de Studiu Complet: 8.5 Visual Dialog

1. 🎯 SINTEZA LECȚIEI (THE BIG PICTURE)

Lecția 8.5 se concentrează pe sarcina **Visual Dialog (VisDial)**, o extensie complexă a VQA care necesită ca un agent să mențină un dialog coerent pe parcursul mai multor runde, bazat pe o imagine dată. Arhitectura de bază este de tip **Encoder-Decoder**, care facturează

procesul în două părți: (1) un Encoder ce convertește intrarea (imaginea I, istoricul H, și întrebarea curentă Q_t) într-un vector comun și (2) un Decoder ce convertește acest vector într-o ieșire (răspunsul A_t). Sunt introduse trei tipuri de Encoder-e (Late Fusion, Hierarchical Recurrent Encoder, Memory Network) și două tipuri de Decodere (Generative și Discriminative). Pentru evaluare, modelul primește o listă de 100 de răspunsuri candidate A_t și trebuie să le sorteze pe baza probabilității. Setul de date VisDial utilizat conține 10 perechi întrebare-răspuns pe circa 120.000 de imagini, totalizând 1.2M perechi întrebare-răspuns.

Care sunt cele 5 idei principale pe care trebuie neapărat să le rețin?

1. **Sarcina:** Purtarea unui dialog conversațional pe mai multe runde, bazat pe imagine (I) și pe istoricul dialogului (H).
2. **Arhitectura:** Se utilizează cadrul **Encoder-Decoder**.
3. **Encoder-i (3 Tipuri):** Late Fusion (LF), Hierarchical Recurrent Encoder (HRE) și Memory Network (MN).
4. **Decodere (2 Tipuri):** Generative (LSTM) și Discriminative (Softmax).
5. **Intrarea Modelului:** Imaginea I, istoricul dialogului *ground-truth* H (inclusiv *caption*-ul imaginii) și întrebarea curentă Q_t.

---

2. 📖 REZUMAT DETALIAT (PE CAPITOLE/SECȚIUNI)

8.5 Visual Dialog – Context și Set de Date

- A fost construit setul de date **visual dialog (VisDial)**, care conține **10 perechi întrebare-răspuns** pe aproximativ **120.000 de imagini**, totalizând **1.2M perechi întrebare-răspuns**.
- Au fost dezvoltate mai multe modele neuronale pentru răspuns la dialogul vizual.

Intrarea și Ieșirea Modelului

- **Intrarea Modelului:**
  - Imaginea I_t.
  - Istoricul dialogului *ground-truth* H, care include *caption*-ul imaginii (C) și perechile anterioare întrebare-răspuns $(Q_1, A_1), \ldots, (Q_{t-1}, A_{t-1})$).
  - Întrebarea curentă Q_t.
  - O listă de **100 de răspunsuri candidate** $A_t = A_t^{(1)}, \ldots, A_t^{(100)}$.
- **Obiectivul Ieșirii:** A returna o sortare a răspunsurilor candidate A_t.
- **Structură Generală:** Toate modelele urmează cadrul **Encoder-Decoder**.

Encodere (3 Tipuri)

Toți Encoder-ii convertesc intrările (I, H, Q_t) într-o reprezentare comună. În toate cazurile, imaginea I este reprezentată prin **activările normalizate** l_2 de la penultimul strat al rețelei

VGG-16.

1. **Late Fusion (LF) Encoder:**
   - Istoricul H este tratat ca un șir lung.
   - Q_t și H sunt codificate separat cu **două LSTM-uri diferite**.
   - Reprezentările individuale ale intrărilor (I, H, Q_t) sunt **concatenate**.
   - Concatenarea este urmată de un strat complet conectat și o neliniaritate *tanh* pentru a ajunge la un **vector de 512 de dimensiuni**, folosit pentru a decoda răspunsul.
2. **Hierarchical Recurrent Encoder (HRE):**
   - Captează natura ierarhică a problemei: fiecare întrebare Q_t este o secvență de cuvinte, iar dialogul în ansamblu este o secvență de perechi întrebare-răspuns (Q_t, A_t).
   - Reprezentarea imaginii (din VGG-16 CNN) este **fuzionată timpuriu (*early fused*) cu întrebarea** Q_t.
   - Fiecare pereche Q-A din istoricul dialogului (H) este codificată independent de un alt LSTM.
   - Un bloc recurent R_t (ce utilizează un LSTM) codifică întrebarea și imaginea.
   - Un **Dialog-RNN** se așează deasupra acestui bloc recurent.
   - Mecanismul de **"Attention-over-history"** permite blocului R_t să aleagă și să se concentreze pe istoricul relevant (H) din rundele anterioare, bazat pe întrebarea curentă.
3. **Memory Network (MN) Encoder:**
   - Imaginea este codificată cu un VGG-16 CNN, iar întrebarea Q_t cu un LSTM.
   - Reprezentările imaginii și întrebării sunt concatenate și transformate într-un **"query vector"** (vector de interogare).
   - Fiecare pereche Caption/QA din istoric este codificată independent ca un **"fact" (fapt)** într-o "bancă de memorie" folosind un alt LSTM.
   - Vectorul de interogare este folosit pentru a calcula **atenția peste cele t fapte** (istoric) prin **produs scalar (*inner product*)**.
   - Combinația convexă a vectorilor istorici ponderați de atenție trece printr-un strat complet conectat și este **adunată înapoi la vectorul de interogare** pentru a construi codificarea finală (MN encoding).

Decodere (2 Tipuri)

1. **Generative (LSTM) Decoder:**
   - Vectorul codificat (din Encoder) este setat ca **starea inițială** a modelului lingvistic LSTM RNN.
   - În timpul antrenării, log-likelihood-ul secvenței de răspuns *ground-truth* este maximizat, antrenat *end-to-end*.
   - Pentru evaluare, scorurile log-likelihood ale modelului sunt folosite pentru a clasa răspunsurile candidate.

- Decoderele generative sunt mai practice pentru aplicații realiste, dar pot avea performanțe inferioare și nu exploatează bias-urile în crearea opțiunilor.

2. **Discriminative (Softmax) Decoder:**
   - Calculează **similaritatea prin produs scalar (*dot product similarity*)** între codificarea de intrare (imagine, istoric, întrebare) și codificarea LSTM a fiecăreia dintre opțiunile de răspuns.
   - Aceste produse scalare sunt introduse într-un **Softmax** pentru a calcula probabilitatea posterioară peste opțiuni.
   - În timpul antrenării, log-likelihood-ul opțiunii corecte este maximizat.
   - În timpul evaluării, opțiunile sunt pur și simplu clasate pe baza probabilităților lor posterioare.

---

3. 💡 EXPLICAȚII SUPLIMENTARE ȘI CLARIFICĂRI (IMPORTANT)

Termen Tehnic: Atenția Peste Istoric (Attention-over-history)

- **Explicație Simplificată (Atenția Selectivă):** Într-un dialog lung, nu toate rundele anterioare de întrebări și răspunsuri sunt relevante pentru întrebarea curentă Q_t. Mecanismul de atenție (folosit în HRE și MN) acționează ca un **filtru inteligent**. El permite rețelei să acorde o **pondere mai mare** (să "se uite" mai mult) la acele părți din istoric (H) care sunt cele mai informative pentru a formula răspunsul corect la Q_t.

Concept Dificil: Decodere Generative vs. Discriminative

- **Analogie (Creativ vs. Selectiv):**
  - **Generativ (Creativ):** Decodorul LSTM generează răspunsul cuvânt cu cuvânt, de la zero. Este ca și cum ai scrie o teză (poate fi original, dar greu de antrenat bine).
  - **Discriminativ (Selectiv):** Decodorul Softmax nu generează text nou; în schimb, el **alege cel mai bun răspuns** dintr-o listă predefinită de 100 de opțiuni. Este ca și cum ai răspunde la un examen *multiple-choice* (mai ușor de evaluat și antrenat pentru clasare).

---

4. 🔗 CONEXIUNI ȘI IMPLICAȚII

- **Relația Cauză-Efect (Input-ul Istoricului H):**
  - **CAUZĂ:** Necesitatea de a purta un dialog coerent, în care răspunsurile depind de contextul anterior.
  - **EFECT:** Intrările modelului trebuie să includă explicit istoricul dialogului H (inclusiv *caption*-ul C și perechile Q-A anterioare), forțând Encoder-ul să învețe nu doar

viziunea și limbajul, ci și **raționamentul temporal**.

- **Conexiunea cu NIC/LRCN:** Toți Encoder-ii folosesc VGG-16 CNN pentru codificarea imaginii I, similar cu abordările din NIC și LRCN, evidențiind dependența continuă de **feature-urile vizuale pre-învățate**.

---

5. EXERCITII (Analiză Arhitecturală și Set de Date)

Exercițiul D5.1: Analiza Setului de Date VisDial

1. Calculați numărul mediu de perechi întrebare-răspuns furnizate per imagine în setul de date VisDial.
2. Determinați numărul total de imagini din setul de date VisDial.

Rezolvare D5.1:

1. **Numărul mediu de perechi Q-A per imagine:** Setul de date conține 10 perechi întrebare-răspuns pe circa 120k imagini.

$$\text{Media} = \mathbf{10} \text{ perechi -A per imagine.}$$

2. **Numărul total de imagini:** Numărul total de imagini este de $\mathbf{120.000}$ de imagini.

Exercițiul D5.2: Analiza Encoder-ului Late Fusion (LF)

Encoder-ul LF (Late Fusion) fuzionează cele trei reprezentări I, H, Q_t.

1. Care sunt componentele (sub-rețelele) utilizate pentru a codifica reprezentările lingvistice H și Q_t?
2. Care este dimensiunea finală a vectorului comun (joint representation) la care este transformată concatenarea, și care este scopul acestui vector?

Rezolvare D5.2:

1. **Componentele de Codificare Lingvistică:** Q_t și H sunt codificate separat folosind **două LSTM-uri diferite**.
2. **Dimensiunea Finală și Scopul:** Reprezentarea concatenată este transformată într-un **vector de 512 de dimensiuni** printr-un strat complet conectat și neliniaritate *tanh*. Acest vector este folosit ca intrare pentru **Decoder**.

Exercițiul D5.3: Analiza Decodării Discriminative

Explicați modul în care Decodorul Discriminativ (Softmax) determină probabilitatea unui răspuns candidat $A_t^{(i)}$ ca fiind cel corect.

Rezolvare D5.3:

Decodorul Discriminativ (Softmax) determină probabilitatea prin calcularea **similarității prin produs scalar (*dot product similarity*)** între:

1. Codificarea de intrare unificată (imagine, istoric, întrebare) de la Encoder.
2. Codificarea LSTM a opțiunii de răspuns candidate $A_t^{(i)}$. Aceste produse scalare servesc drept *logits* și sunt introduse într-un strat **Softmax** pentru a calcula probabilitatea posterioară peste cele 100 de opțiuni candidate.

8.6

Exercițiile vor acoperi integral subiectele specificate: *Image Captioning*, *Show and Tell (NIC)*, *Long-term Recurrent Convolutional Networks (LRCNs)*, *Deep Visual-Semantic Alignments*, *Visual Question Answering (VQA)* și *Visual Dialog*.

EXAMEN FINAL SIMULAT: VIZIUNE ȘI LIMBAJ (CAPITOLUL 8)

I. Întrebări de Analiză și Sinteză (Tip "Bacalaureat")

Subiectul I.1: Fundamentele Viziunii-Limbaj (Analiză Comparativă)

Explicați de ce sarcina **Image Captioning** este considerată o "problemă fundamentală în inteligența artificială". Comparați apoi *Image Captioning* cu sarcina **Visual Question Answering (VQA)**, evidențiind cerințele suplimentare pe care VQA le impune unui sistem (din punct de vedere al înțelegerii și raționamentului complex).

Rezolvare I.1 (Sinteză):

Sarcina *Image Captioning* reprezintă descrierea conținutului unei imagini în limbaj natural, generând *caption*-uri. Aceasta este o problemă fundamentală deoarece **conectează viziunea computerizată și procesarea limbajului natural (NLP)**. De asemenea, ea imită abilitatea remarcabilă a omului de a **comprima cantități uriașe de informații vizuale în limbaj descriptiv**.

VQA (Visual Question Answering) extinde această sarcină prin solicitarea unui **răspuns precis în limbaj natural** la o întrebare deschisă și în format liber, dată o imagine.

Cerințe Suplimentare VQA:

Un sistem care reușește la VQA necesită o **înțelegere mai detaliată a imaginii și un raționament complex** decât un sistem care produce doar *caption*-uri generice. Întrebările vizuale din VQA vizează **selectiv** diferite zone ale imaginii, inclusiv **detaliile de fundal și contextul implicit**.

Subiectul I.2: Arhitecturi Encoder-Decoder și Context (Deep Visual-Semantic Alignments & Visual Dialog)

Analizați modul în care arhitecturile avansate (precum cele din **Deep Visual-Semantic Alignments** și **Visual Dialog**) abordează problema contextului, fie că este vorba de contextul propoziției, fie de contextul conversațional:

1. **Contextul Propoziției (Deep Visual-Semantic Alignments):** Explicați de ce abordarea simplă de mapare a cuvintelor este insuficientă și cum este utilizată **Rețeaua Recurentă Bidirecțională (BRNN)** pentru a îmbogăți reprezentarea cuvântului.
2. **Contextul Conversațional (Visual Dialog):** Explicați elementul esențial pe care agentul trebuie să îl includă ca intrare pentru a asigura un dialog "semnificativ și conversațional" și cum este gestionat istoricul în Encoder-ele de tip **Memory Network (MN)**.

Rezolvare I.2 (Analiză):

1. **Contextul Propoziției:** Abordarea simplă de a proiecta fiecare cuvânt individual în spațiul de *embedding* nu consideră **ordinea** sau **contextul** cuvântului în propoziție. Pentru a rezolva această problemă, se folosește o **BRNN**, care transformă fiecare cuvânt într-un vector h-dimensional îmbogățit de un **context de mărime variabilă în jurul acelui cuvânt**. Reprezentarea finală s_t a cuvântului t devine o funcție a cuvântului și a contextului său înconjurător.
2. **Contextul Conversațional:** Sarcina *Visual Dialog* necesită ca agentul să poarte un dialog conversațional despre conținutul vizual. Pentru a face acest lucru, intrarea modelului trebuie să includă **istoricul dialogului *ground-truth* (H)** (care cuprinde *caption*-ul imaginii și perechile anterioare întrebare-răspuns) și întrebarea curentă Q_t. În Encoder-ul **Memory Network (MN)**, fiecare pereche *Caption/QA* din istoric este codificată independent ca un **"fact" (fapt)** într-o bancă de memorie. Un vector de interogare (obținut din imagine și întrebarea curentă) este apoi folosit pentru a calcula **atenția peste aceste fapte** (istoric) prin produs scalar (*inner product*). Aceasta permite modelului să se refere la faptele relevante stocate pentru a construi răspunsul.

II. Exerciții de Calcul și Analiză Arhitecturală

Exercițiul C.1 (Show and Tell / NIC - Calculul Pierderii):

Modelul NIC calculează probabilitatea secvenței $p(S|I)$ și minimizează pierderea $L(I, S)$.

1. Scrieți formula matematică pentru calculul probabilității secvenței $p(S|I)$ și explicați ce rol joacă termenul S_{t-1}.
2. Calculați pierderea totală $L(I, S)$ pentru o propoziție de lungime $N = 4$ (excluzând token-ul S_0). Dacă probabilitățile logaritmice negative prezise de rețea pentru cuvintele corecte la fiecare pas sunt: $S_1 = 0.2$, $S_2 = 0.5$, $S_3 = 0.3$, $S_4 = 0.6$.

Rezolvare C.1:

1. **Formula Probabilității Secvenței:**

$$p(S|I) = {}_{t=0}^{N} p(S_t|I, S_0, \ldots, S_{t-1})$$

   Termenul S_{t-1} (alături de $S_0, \ldots, S_{t-2}$) reprezintă **cuvintele precedente** (propoziția parțială generată până la acel pas) care condiționează predicția cuvântului curent S_t. LSTM-ul este antrenat să prezică fiecare cuvânt al propoziției după ce a văzut imaginea, precum și **toate cuvintele precedente**.
2. **Calculul Pierderii:** Pierderea este suma log-probabilității negative a cuvântului corect la fiecare pas.

$$L(I, S) = -\sum_{t=1}^{N} \log p_t(S_t)$$

   Notă: Deoarece valorile din exercițiu sunt deja date ca pierderi negative logaritmice (presupunem că $L_t = -\log p_t(S_t)$), le vom aduna direct:

$$L(I, S) = 0.2 + 0.5 + 0.3 + 0.6 = \mathbf{1.6}$$

Exercițiul C.2 (LRCNs - Analiză Arhitecturală):

Descrieți cele două moduri principale prin care **feature-urile vizuale** $\phi_V(x)$ ale imaginii x pot fi introduse într-o stivă de LSTM-uri (L straturi), așa cum este detaliat în LRCN. Care dintre aceste moduri este denumit **"factored"** și care este scopul său?

Rezolvare C.2:

1. **Modul 1 (Unfactored):** Reprezentarea *feature*-urilor vizuale $\phi_V(x)$ este concatenată cu cuvântul anterior *embedded* ($W_e y_{t-1}$) și alimentată către **primul LSTM al stivei**.
2. **Modul 2 (Factored):** Reprezentarea vizuală $\phi_V(x)$ este alimentată numai către LSTM-urile începând de la un strat $\ell \geq 2$. Acest mod este denumit **"factored"**.

Scopul Factorizării: Scopul este de a forța o **separare a responsabilităților** (separation of responsibilities). Prin "orbirea" (*blinding*) primelor $\ell - 1$ LSTM-uri de intrarea vizuală, acestea sunt forțate să reprezinte numai *caption*-ul parțial y_{1t-1}, fiind **condițional independente de intrarea vizuală** x.

Exercițiul C.3 (Deep Visual-Semantic Alignments - Alinierea Latentă):

În modelul Deep Visual-Semantic Alignments, inferarea alinierilor latente dintre segmentele de cuvinte contigue și regiunile vizuale este o problemă rezolvată cu un **Markov Random Field (MRF)** cu structură de lanț.

1. Scrieți funcția energetică $E(\mathbf{a})$ a MRF și identificați ce reprezintă potențialul binar ${}^{B}(a_j, a_{j+1})$.

2. Explicați cum influențează hiperparametrul β alinierea cuvintelor în MRF și ce se întâmplă când β este mare.

Rezolvare C.3:

1. **Funcția Energetică MRF:**

$$E(\mathbf{a}) = \sum_{j=1...N} {}^{U}(a_j) + \sum_{j=1...N-1} {}^{B}(a_j, a_{j+1})$$

   Potențialul binar ${}^{B}(a_j, a_{j+1}) = \beta \mathbf{1}_{a_j = a_{j+1}}$ reprezintă o **interacțiune binară între cuvintele vecine** care încurajează o aliniere la aceeași regiune.
2. **Influența Parametrului β:** Parametrul β este un hiperparametru care **controlează afinitatea față de frazele mai lungi**. Permite interpolarea între alinierea la nivel de cuvânt individual ($\beta = 0$) și alinierea întregii propoziții la o singură regiune cu scor maxim **când β este mare**.

Exercițiul C.4 (VQA - Dimensionalitatea Fuziunii):

Modelul VQA folosește arhitectura *deeper LSTM Q*.

1. Care este dimensionalitatea *embedding*-ului brut al întrebării obținut prin concatenarea stărilor celulare și a stărilor ascunse din cele două straturi LSTM?
2. După transformările necesare, care este dimensiunea *embedding*-ului comun la care sunt transformate atât imaginea, cât și întrebarea, înainte de fuziune, și ce metodă de fuziune este utilizată?

Rezolvare C.4:

1. **Dimensionalitatea Brută a Întrebării:** Dimensiunea fiecărei stări (celulară și ascunsă) este 512. Dimensionalitatea brută totală este: 2 (straturi ascunse) $\times$ 2 (stare celulară + stare ascunsă) $\times$ 512 $= \mathbf{2048}$ de dimensiuni.
2. **Dimensiunea Fuziunii și Metoda:** Atât *embedding*-ul imaginii, cât și cel al întrebării sunt transformate la **1024 de dimensiuni** pentru a se potrivi. Fuziunea acestor *embeddings* (fiind într-un spațiu comun) se realizează prin **înmulțirea element cu element (*element-wise multiplication*)**.

Exercițiul C.5 (Visual Dialog - Decodare):

Diferențiați rolul Decodorului Generativ (LSTM) de cel Discriminativ (Softmax) în arhitectura Visual Dialog. Subliniați care tip de Decodor este mai practic pentru aplicații realiste.

Rezolvare C.5:

Criteriu	Decodor Generativ (LSTM)	Decodor Discriminativ (Softmax)
Mecanism	Generează secvența de răspuns *ground-truth* cuvânt cu	Calculează similaritatea prin produs scalar (*dot product*) între codificarea

Criteriu	Decodor Generativ (LSTM)	Decodor Discriminativ (Softmax)
	cuvânt, pornind de la vectorul codificat setat ca stare inițială a LSTM.	de intrare și codificarea LSTM a fiecărei opțiuni de răspuns, urmată de Softmax.
Obiectiv	Maximizează *log-likelihood*-ul secvenței de răspuns *ground-truth*.	Maximizează *log-likelihood*-ul opțiunii corecte dintr-un set finit de candidați.
Practicabilitate	Decoderele generative sunt considerate **mai practice** pentru aplicații realiste, deoarece pot genera răspunsuri noi.	Decoderele discriminative tind să obțină performanțe mai bune în sarcinile de clasare și evaluare.