PI_Curs_09

9.0

Sunt la dispoziția dumneavoastră pentru a genera un Ghid de Studiu complet pentru lecția **9. Video Classification**, care introduce viziunea computerizată în domeniul temporal și al acțiunii.

Ghid de Studiu Complet: 9. Video Classification (Clasificarea Video)

1. 🎯 SINTEZA LECȚIEI (THE BIG PICTURE)

Lecția **Clasificarea Video** definește sarcina identificării acțiunilor în videoclipuri, spre deosebire de clasificarea imaginilor, unde doar cel mai important obiect trebuie identificat. Modelele de clasificare video au acces nu doar la informațiile despre aparența (*appearance*) prezente în imaginile statice, ci și la **evoluția temporală complexă** a acestora. Deși videoclipurile oferă un context temporal bogat, ele prezintă o provocare majoră: sunt **mari (big)**, ceea ce face antrenarea dificilă. Soluția practică este antrenarea pe **clipuri scurte (*short clips*)** cu rată mică de cadre (low fps) și rezoluție spațială mică.

Care sunt cele 3 idei principale pe care trebuie neapărat să le rețin?

1. **Obiectivul:** Clasificarea video identifică **acțiuni** (ex: *Running, Jumping*), în contrast cu clasificarea imaginilor care identifică **obiecte** (ex: *Dog, Cat*).
2. **Dimensiunea Datelor:** Videoclipurile sunt mari (e.g., un videoclip necomprimat de 1 minut în rezoluție HD necesită ~ 10 GB).
3. **Soluția de Antrenament:** Pentru a gestiona dimensiunea datelor, antrenarea se realizează pe **clipuri scurte (*short clips*)** cu fps și rezoluție spațială scăzute.

---

2. 📖 REZUMAT DETALIAT (PE CAPITOLE/SECȚIUNI)

9. Video Classification (Clasificarea Video)

- **Definiție:** Clasificarea video reprezintă sarcina de a **identifica acțiuni în videoclipuri**.
- **Contrast cu Clasificarea Imaginilor:** Clasificarea imaginilor se concentrează pe identificarea **celui mai important obiect** dintr-o imagine statică.
- **Informații Utilizate:** În clasificarea video, modelele au acces la:
  1. Informațiile despre aparență (*appearance*) prezente în imaginile statice.

2. **Evoluția temporală complexă** a aparenței.

Exemple de Sarcini (Vizualizare)

- **Imagini:** Recunoașterea **obiectelor** (ex: Dog, Cat, Fish, Truck).
- **Videoclipuri:** Recunoașterea **acțiunilor** (ex: Swimming, Running, Jumping, Eating, Standing).

Provocarea Dimensiunii Datelor (Video is Big)

- **Problema:** Principalul obstacol este că videoclipurile sunt **mari**.
- **Exemplu de Dimensiune (Necomprimat):**
  - Un videoclip necomprimat (3 bytes/pixel) în rezoluție **SD (640 $\times$ 480)** este de ~ 1.5 GB pe minut.
  - Un videoclip necomprimat în rezoluție **HD (1920 $\times$ 1080)** este de ~ 10 GB pe minut.

Soluția de Antrenament și Inferență

- **Soluția:** Soluția este de a antrena modelul pe **clipuri scurte (*short clips*)**, care au rată mică de cadre (low fps) și rezoluție spațială mică.
- **Exemplu de Clop Scurt:** Un clip poate fi definit prin $T = 16$ (număr de cadre), $H = 112$ (înălțime), $W = 112$ (lățime).
  - Acest clip reprezintă un videoclip de **3.2 secunde la 5 fps**.
  - Dimensiunea totală a unui astfel de clip este de doar **588 KB**.
- **Fluxul de Lucru (Figura 7/8):**
  - **Raw Video:** Videoclipul sursă este lung, cu rată mare de cadre (*high FPS*).
  - **Training:** Modelul este antrenat pentru a clasifica **clipuri scurte cu FPS mic**.
  - **Testing:** Modelul rulează pe **clipuri diferite** (*overlapping short clips*) din videoclipul brut, iar predicțiile sunt **mediate (*average predictions*)**.

---

3. 💡 EXPLICAȚII SUPLIMENTARE ȘI CLARIFICĂRI (IMPORTANT)

Termen Tehnic: Complex Temporal Evolution (Evoluție Temporală Complexă)

- **Explicație Simplificată (Schimbarea în Timp):** Clasificarea imaginilor știe ce este un "Dog" într-o singură poză (aparență). Clasificarea video trebuie să înțeleagă "Running". A vedea un câine ridicându-și laba la un moment dat nu este suficient. Trebuie să vadă secvența în care laba se mișcă, corpul se deplasează, și fundalul se schimbă pe o

durată de timp. Această mișcare continuă și coerentă este **evoluția temporală complexă**.

Concept Dificil: Compromisul Dimensiune/Antrenament

- **Analogie (Eșantionul de Sol):** Când un geolog studiază un munte (videoclipul lung), nu ia tot muntele, ci ia o carotă mică de sol.
  - Videoclipul HD de 10 GB/minut este muntele.
  - Clipul scurt de 588 KB este carota.
- *Asta se întâmplă deoarece:* Resursele de calcul (memoria GPU) nu pot gestiona volumele masive de date necomprimate, mai ales când antrenarea necesită mii de exemple. Antrenarea pe **clipuri scurte, cu rezoluție redusă (**112×112**)** și rată mică de cadre (5 fps) face ca antrenarea *end-to-end* să fie **fezabilă din punct de vedere computațional**.

---

4. 🔗 CONEXIUNI ȘI IMPLICAȚII

- **Relația Cauză-Efect (Metoda de Antrenament):**
  - **CAUZĂ:** Videoclipurile brute sunt prea lungi și prea mari pentru a fi procesate integral.
  - **EFECT:** Necesitatea de a utiliza o strategie de antrenament care implică **decimarea rezoluției temporale** (low fps) și **decimarea rezoluției spațiale** (low spatial resolution) pe clipuri scurte.
- **Implicația asupra Inferenței:** Faptul că modelul este antrenat pe clipuri scurte, impune o strategie specifică la testare: rularea modelului pe **clipuri diferite (overlapping short clips)** și apoi **media predicțiilor** pentru a obține un rezultat final robust.

---

5. EXERCITII (Calcul și Analiză)

Exercițiul V.1: Calculul Dimensiunii Datelor

Se utilizează un videoclip necomprimat (3 bytes/pixel) în rezoluție HD (1920×1080).

1. Dacă un videoclip de 1 minut necesită ~ 10 GB, calculați cât spațiu ar necesita un videoclip necomprimat de **2 minute și 30 de secunde** în aceeași rezoluție.
2. Dacă un antrenament standard folosește o rată de cadre de 30 fps, dar modelul este antrenat pe 5 fps, care este factorul de **decimare temporală** aplicat?

Rezolvare V.1:

1. **Calculul Dimensiunii:** Un minut = 10 GB. 2 minute și 30 de secunde = 2.5 minute.

$$\text{Dimensiune} = 2.5 \text{ minute} \times 10 \text{ B/minut} = \mathbf{25} \text{ B}$$

2. **Factorul de Decimare Temporală:**

$$\text{Factor} = \frac{\text{FPS standard}}{\text{FPS antrenament}} = \frac{30 \text{ fps}}{5 \text{ fps}} = \mathbf{6}$$

(Adică, se folosește doar 1 cadru din 6).

Exercițiul V.2: Analiză Arhitecturală (Timpul și Spațiul)

Clasificarea video trebuie să acceseze informațiile despre aparență *și* evoluția temporală complexă.

1. Care tip de informație (aparență sau evoluție temporală) este predominant capturat de rezoluția spațială mică ($H = 112, W = 112$)?
2. Cum este integrată evoluția temporală în clipurile de antrenament definite prin $T = 16$ cadre?

Rezolvare V.2:

1. **Informația Capturată de Rezoluția Spațială:** Rezoluția spațială (ex: 112×112) capturează informațiile despre **aparență** (forma și culoarea obiectelor), deși la o calitate redusă.
2. **Integrarea Evoluției Temporale:** Evoluția temporală este integrată prin secvența de $= \mathbf{16}$ cadre. Modelul trebuie să proceseze toate cele 16 cadre în ordine pentru a deduce **acțiunea** (mișcarea) care se desfășoară pe durata celor 3.2 secunde.

Exercițiul V.3: Analiza Strategiei de Testare

Explicați de ce, în faza de *Testing* a clasificării video, se rulează modelul pe **clipuri diferite (overlapping)**, iar predicțiile finale sunt **mediate (*average predictions*)**.

Rezolvare V.3:

Această strategie este adoptată pentru a îmbunătăți **robustetea și precizia** clasificării finale. Deoarece modelul este antrenat doar pe clipuri scurte, fiecare clip poate oferi o perspectivă incompletă sau zgomotoasă asupra acțiunii lungi.

- Rularea pe **clipuri diferite (overlapping)** asigură că acțiunea lungă din videoclipul brut este acoperită integral, chiar dacă unele clipuri individuale sunt ambigue.
- **Mediul Predicțiilor** (Average Predictions) reduce zgomotul și stabilizează clasificarea finală, bazând decizia pe consensul obținut din multiple eșantioane temporale.

9.1

Sunt onorat să vă fiu profesor și tutore în explorarea acestei lecții avansate despre clasificarea video la scară largă.

Ghid de Studiu Complet: 9.1 Large-scale video classification with CNNs

1. 🎯 SINTEZA LECȚIEI (THE BIG PICTURE)

Lecția 9.1 abordează problema extinderii succesului rețelelor convoluționale (CNN-uri) de la imaginile statice la clasificarea videoclipurilor la scară largă. Deoarece videoclipurile variază pe scară largă în **extinderea temporală** și nu pot fi ușor procesate de o arhitectură cu dimensiune fixă, provocarea centrală este modul de capturare a **feature-urilor spațio-temporale** (adică, mișcarea). Soluția adoptată este tratarea fiecărui videoclip ca o "pungă" (*bag*) de **clipuri scurte, de dimensiune fixă**. Pentru a integra informațiile temporale, sunt investigate trei categorii principale de modele de **fuziune** a informațiilor de-a lungul domeniului temporal: **Early Fusion, Late Fusion, și Slow Fusion**. Lecția introduce, de asemenea, o arhitectură cu **rezoluții multiple (*multiresolution*)** pentru a aborda eficiența computațională.

Care sunt cele 5 idei principale pe care trebuie neapărat să le rețin?

1. **Provocare și Soluție:** Videoclipurile variază în extinderea temporală. Ele sunt procesate ca o colecție de **clipuri scurte, de dimensiune fixă**.
2. **Extensia Spatio-Temporală:** Conectivitatea rețelei este extinsă în dimensiunea temporală pentru a învăța **feature-uri spațio-temporale** prin cadre contigue în timp.
3. **Early Fusion (Fuziune Timpurie):** Fuziunea se face **imediat la nivel de pixel** prin modificarea filtrelor primului strat convoluțional.
4. **Late Fusion (Fuziune Târzie):** Două rețele separate cu un singur cadru (*single-frame*) sunt plasate la o distanță temporală (de exemplu, **15 cadre**) și rezultatele lor sunt fuzionate târziu, în primul strat complet conectat.
5. **Arhitectura Multiresolution:** Utilizează două fluxuri separate, **Fovea Stream** (rezoluție înaltă, centru) și **Context Stream** (rezoluție joasă, cadru întreg), pentru a reduce dimensionalitatea totală a intrării la jumătate, menținând performanța.

---

2. 📖 REZUMAT DETALIAT (PE CAPITOLE/SECȚIUNI)

9.1 Clasificarea Video la Scară Mare cu CNN-uri

- Spre deosebire de imagini (care pot fi decupate și redimensionate la o dimensiune fixă), videoclipurile variază mult în extinderea temporală.
- Fiecare videoclip este tratat ca o "pungă" de **clipuri scurte, de dimensiune fixă**.

- Fiecare clip conține mai multe cadre contigue în timp, permițând extinderea conectivității rețelei în dimensiunea temporală pentru a învăța feature-uri spatio-temporale.

Modelul de Bază (Single Frame)

- O arhitectură de bază **Single Frame** este folosită pentru a înțelege contribuția aparenței statice la acuratețea clasificării.
- Această rețea acceptă intrări de $170 \times 170 \times 3$ **pixeli**.
- Notația arhitecturii complete este: $\mathbf{C(96, 11, 3) - N - P - C(256, 5, 1) - N - P - C(384, 3, 1) - C(384, 3, 1) - C(256, 3, 1}$.
  - $C(d, f, s)$: strat convoluțional cu d filtre de dimensiune spațială $f \times f$, aplicat cu *stride* s.
  - $FC(n)$: strat complet conectat cu n noduri.
  - P: strat de *pooling* spațial în regiuni non-suprapuse 2×2.
- Stratul final este conectat la un clasificator Softmax.

Categorii de Fuziune Temporală (Fusion Approaches)

1. **Early Fusion (Fuziunea Timpurie):**
   - Combină informația pe întregul interval de timp **imediat la nivel de pixel**.
   - Implementare: Filtrele primului strat convoluțional sunt modificate pentru a avea dimensiunea $11 \times 11 \times 3 \times T$ **pixeli**.
   - Extinderea temporală (T) utilizată este de $T = 10$ **cadre**, reprezentând aproximativ o treime de secundă.
   - Permite rețelei să detecteze precis **direcția și viteza mișcării locale**.
2. **Late Fusion (Fuziunea Târzie):**
   - Plasează **două rețele separate cu un singur cadru** (*single-frame networks*) la o distanță de **15 cadre** una de alta.
   - Aceste rețele partajează parametrii până la ultimul strat convoluțional.
   - Ieșirile celor două fluxuri sunt fuzionate **mai târziu** în procesare, în **primul strat complet conectat**.
   - Niciunul dintre cele două *single-frame tower* nu poate detecta mișcarea singur, dar stratul complet conectat poate calcula **caracteristici globale de mișcare** prin compararea ieșirilor.
3. **Slow Fusion (Fuziunea Lentă):**
   - Un mix echilibrat între cele două abordări, care fuzionează lent informația temporală pe parcursul întregii rețele.
   - Conectivitatea **tuturor straturilor convoluționale** este extinsă în timp, adăugând convoluții temporale pe lângă cele spațiale.
   - Exemplu utilizat: Primul strat folosește un filtru de extindere temporală $= \mathbf{4}$ pe un clip de intrare de **10 cadre** (prin convoluție validă cu *stride* 2) și produce **4 răspunsuri în timp**.

- Al doilea și al treilea strat repetă procesul cu filtre de extindere temporală $= \mathbf{2}$ și *stride* 2.
- Astfel, al treilea strat convoluțional are acces la informații de-a lungul **tuturor celor 10 cadre de intrare**.

CNN-uri Multirezoluție (Eficiență Computațională)

- Deoarece performanța la rulare (*runtime performance*) este critică, se caută abordări pentru a accelera modelele fără a sacrifica performanța.
- S-a observat că reducerea numărului de straturi sau neuroni scade performanța. De asemenea, reducerea rezoluției imaginilor îmbunătățește timpul de rulare, dar detaliile de înaltă frecvență sunt **critice pentru acuratețe**.
- **Fovea and Context Streams (Compromisul Multirezoluție):** Arhitectura propusă echilibrează performanța și eficiența folosind **două fluxuri separate** (Figura 2).
  - Intrarea este un clip video de 178×178 **cadre**.
  - **Context Stream:** Primește cadre eșantionate în jos (*downsampled*) la **jumătate din rezoluția spațială originală** (89×89 pixeli).
  - **Fovea Stream:** Primește **regiunea centrală** 89×89 la **rezoluția originală**.
  - Această abordare înjumătățește dimensionalitatea totală a intrării și exploatează *bias*-ul camerei (obiectul de interes este adesea în centru).
- **Convergența Fluxurilor:** Ambele fluxuri sunt procesate de rețele identice, dar stratul final de *pooling* este ajustat pentru a asigura că ambele se termină într-un strat de dimensiune $7 \times 7 \times 256$.
- Activările celor două fluxuri sunt apoi **concatenate** și introduse în primul strat complet conectat.

---

3. 💡 EXPLICAȚII SUPLIMENTARE ȘI CLARIFICĂRI (IMPORTANT)

Termen Tehnic: Spatio-Temporal Features (Feature-uri Spațio-Temporale)

- **Explicație Simplificată (Vederea 3D + Timp):** Feature-urile normale (ale imaginii) sunt doar spațiale (unde este un obiect). Feature-urile spațio-temporale adaugă a patra dimensiune: timpul. Ele descriu nu doar unde se află un obiect, ci și **cum se mișcă** în spațiu pe o anumită durată. Capturarea lor este esențială pentru a distinge între "Running" (acțiune) și "Standing" (aparență statică).

Concept Dificil: Early Fusion vs. Late Fusion

- **Analogie (Detectivul):**

- **Early Fusion:** Detectivul primește informațiile despre *toate* cadrele video (mișcarea) simultan, chiar la începutul analizei. Prin urmare, el poate detecta mișcarea locală foarte precis (viteza și direcția).
- **Late Fusion:** Detectivul trimite două rapoarte separate din două momente diferite (distanța de 15 cadre). Niciun raport nu știe de mișcare. Doar un manager (strat FC) compară cele două rapoarte la sfârșit și deduce că obiectul s-a deplasat (mișcare globală).

Context Suplimentar: Compromisul Multiresoluție

- *Asta se întâmplă deoarece:* Performanța la rulare este esențială. Deși rezoluția redusă a imaginii accelerează rețeaua, detaliul de înaltă frecvență este critic. Arhitectura **Fovea and Context** rezolvă asta prin **sacrificarea rezoluției pentru contextul larg** (Context Stream) și **prioritizarea rezoluției înalte pentru obiectul central** (Fovea Stream), reducând astfel la jumătate dimensionalitatea totală a intrării fără a sacrifica performanța semnificativ.

---

4. 🔗 CONEXIUNI ȘI IMPLICAȚII

- **Relația Cauză-Efect (Metoda Slow Fusion):**
  - **CAUZĂ:** Fuziunea informației prea devreme (EF) sau prea târziu (LF) nu este optimă.
  - **EFECT:** Slow Fusion a fost dezvoltată pentru a **fuziona lent informația temporală pe parcursul întregii rețele**, permițând straturilor superioare să acceseze progresiv mai multe informații globale atât în dimensiunile spațiale, cât și în cele temporale.
- **Conexiunea cu CNN-urile Statice:** Arhitectura de bază *Single Frame* utilizează o rețea de clasificare standard, similară AlexNet. Extinderile temporale (EF, LF, SF) sunt, în esență, modificări aduse arhitecturii CNN statice pentru a opera în dimensiunea 3D (spațiu + timp).

---

5. EXERCITII (Calcul și Analiză Arhitecturală)

Exercițiul C.5.1: Analiza Early Fusion (EF) și Timpul

1. Dacă un model **Early Fusion** utilizează un filtru de dimensiune $11 \times 11 \times 3 \times T$ și $T = 10$ cadre, la ce rată de cadre (FPS) ar fi fost capturat videoclipul inițial dacă extinderea temporală $T = 10$ reprezintă aproximativ o treime de secundă?
2. Care este dimensionalitatea totală a filtrului EF în spațiul 4D (Spațiu: 11×11; Canale: 3; Timp: 10)?

Rezolvare C.5.1:

1. **Calculul FPS:** Dacă 10 cadre reprezintă $1/3$ de secundă (conform sursei), atunci 1 secundă va conține $10 \times 3 = \mathbf{30}$ cadre (FPS).
2. **Dimensionalitatea Filtrului (Volum):**

$$11 \times 11 \times 3 \times 10 = 121 \times 30 = \mathbf{3630} \text{ ponderi/dimensiuni}$$

Exercițiul C.5.2: Analiza Multiresolution CNN (Dimensionalitate)

Se folosește arhitectura multirezoluție Fovea and Context. Intrările sunt clipuri de 178×178 cadre.

1. Care este rezoluția spațială a intrării pentru **Context Stream**?
2. Dacă ambele fluxuri termină în straturi de *pooling* de dimensiune $7 \times 7 \times 256$, iar activările sunt concatenate, care este dimensionalitatea intrării în primul strat complet conectat (FC)?

Rezolvare C.5.2:

1. **Rezoluția Context Stream:** Context Stream primește cadrele eșantionate în jos la **jumătate din rezoluția spațială originală**.

$$178/2 = 89 \text{ pixeli}$$

   Rezoluția este $\mathbf{89} \times \mathbf{89}$ pixeli.
2. **Dimensionalitatea Concatenată a Intrării FC:** Fiecare flux termină la $7 \times 7 \times 256$. Dimensionalitatea fiecărui flux este $7 \times 7 \times 256 = 49 \times 256 = 12544$. Prin concatenare, dimensionalitatea se dublează:

$$\text{Dimensiune Totală} = 12544 \times 2 = \mathbf{25088} \text{ dimensiuni}$$

Exercițiul C.5.3: Analiza Slow Fusion

Un model **Slow Fusion** lucrează cu un clip de intrare de **10 cadre**. Primul strat folosește un filtru temporal $T = 4$ și *stride* $s = 2$.

1. Câte răspunsuri temporale produce primul strat?
2. În acest model specific, care este primul strat convoluțional care are acces la informații de-a lungul tuturor celor 10 cadre de intrare?

Rezolvare C.5.3:

1. **Răspunsuri Temporale (Valid Convolution):** Pentru o convoluție validă, numărul de ieșiri este dat de (Lungime Intrare - Lungime Filtru) / Stride + 1.

$$(10 - 4)/2 + 1 = 6/2 + 1 = 3 + 1 = \mathbf{4} \text{ răspunsuri}$$

2. **Stratul cu Acces la Toate Cadrele:** Al doilea și al treilea strat repetă procesul, iar sursa indică faptul că **al treilea strat convoluțional** are acces la informații de-a lungul tuturor celor 10 cadre de intrare.

9.2

Sunt bucuros să vă ghidez prin lecția **9.2 Two-Stream CNNs**, o arhitectură fundamentală pentru recunoașterea acțiunilor video care separă informațiile spațiale de cele temporale.

Ghid de Studiu Complet: 9.2 Two-Stream CNNs (Rețele Convoluționale cu Două Fluxuri)

1. 🎯 SINTEZA LECȚIEI (THE BIG PICTURE)

Lecția 9.2 introduce arhitectura **Two-Stream CNNs** (Rețele Convoluționale cu Două Fluxuri) pentru clasificarea video. Această arhitectură se bazează pe premisa că un videoclip poate fi descompus în mod natural în componente **spațiale** (aparența cadrelor individuale, informații despre scene și obiecte) și **temporale** (mișcarea camerei și a obiectelor între cadre),,. Modelul propus divizează arhitectura de recunoaștere video în **două fluxuri separate**, fiecare implementat folosind un CNN profund (deep CNN),,. Fluxul Spațial procesează aparența statică, iar Fluxul Temporal exploatează mișcarea (fluxul optic) pentru a îmbunătăți semnificativ acuratețea,,. Punctele Softmax obținute de la fiecare flux sunt ulterior **fuzionate târziu (*late fusion*)** pentru a produce scorul final al clasei,,,,.

Care sunt cele 5 idei principale pe care trebuie neapărat să le rețin?

1. **Dezintegrarea Video:** Videoclipul este descompus în componente **spațiale** (aparență, obiecte) și **temporale** (mișcare),,.
2. **Arhitectura Bicanal:** Arhitectura folosește **două fluxuri CNN profunde** separate (Fluxul Spațial și Fluxul Temporal),,,,.
3. **Fluxul Spațial (Intrare și Scop):** Operează pe **cadre video individuale** (imagini statice) și se poate baza pe CNN-uri pre-antrenate pe ImageNet,,.
4. **Fluxul Temporal (Intrare și Scop):** Utilizează stivuirea câmpurilor vectoriale de deplasare a **fluxului optic (*optical flow*)** între cadre consecutive, descriind explicit mișcarea,,.
5. **Fuziunea:** Scorul final este obținut prin **fuziunea târzie (*late fusion*)** a scorurilor Softmax ale celor două fluxuri, folosind metode precum medierea (*averaging*) sau antrenarea unui **SVM liniar multiclasă**,,.

---

2. 📖 REZUMAT DETALIAT (PE CAPITOLE/SECȚIUNI)

9.2 Two-Stream CNNs

- Videoclipul poate fi descompus în componente spațiale și temporale,,.
- **Partea Spațială:** Se prezintă sub forma aparenței cadrului individual și conține informații despre scenele și obiectele din videoclip,,.
- **Partea Temporală:** Se prezintă sub forma mișcării pe cadre și transmite mișcarea observatorului (camerei) și a obiectelor,,.
- Arhitectura propusă de recunoaștere video este împărțită în două fluxuri,,.

Fluxul Spațial (Spatial stream ConvNet)

- Fluxul Spațial CNN operează pe **cadre video individuale**, realizând efectiv recunoașterea acțiunii din imagini statice,,,,.
- Aparența statică în sine este un indiciu util, deoarece unele acțiuni sunt puternic asociate cu anumite obiecte,,.
- Clasificarea acțiunilor din cadre statice (fluxul de recunoaștere spațială) este destul de competitivă pe cont propriu,,.
- Deoarece un CNN spațial este în esență o arhitectură de clasificare a imaginii, rețeaua poate fi **pre-antrenată** pe un set de date mare de clasificare a imaginilor, cum ar fi ImageNet,,.

Fluxul Temporal (Temporal stream ConvNet / Optical flow CNNs)

- Fluxul Temporal exploatează mișcarea și îmbunătățește semnificativ acuratețea,,.
- Spre deosebire de modelele CNN care folosesc cadre brute, intrarea pentru modelul fluxului optic este formată prin **stivuirea câmpurilor vectoriale de deplasare a fluxului optic** între mai multe cadre consecutive,,.
- Această intrare descrie **explicit mișcarea** între cadrele video, ceea ce ușurează recunoașterea, deoarece rețeaua nu trebuie să estimeze mișcarea implicit,,.

Stivuirea Fluxului Optic (Optical Flow Stacking)

- Fluxul optic dens poate fi văzut ca un set de **câmpuri vectoriale de deplasare** $\mathbf{d}_t$ între perechile de cadre consecutive t și $t+1$,,.
- Vectorul de deplasare $\mathbf{d}_t(u,v)$ la punctul (u,v) în cadrul t mută punctul la punctul corespunzător în cadrul $t+1$,,.
- Componentele orizontală (d_t^x) și verticală (d_t^y) ale vectorului $\mathbf{d}_t$ pot fi văzute ca **canale de imagine**, bine adaptate pentru recunoaștere folosind o rețea convoluțională,,,,.
- Pentru a reprezenta mișcarea pe o secvență de cadre, canalele de flux d^x, d^y ale L cadre consecutive sunt **stivuite** pentru a forma un total de $2L$ **canale de intrare**,,.
- Intrarea CNN $I_\tau \in \mathbb{R}^{W \times H \times 2L}$ pentru un cadru arbitrar τ este construită formal astfel:

$$I_\tau(u,v,2k-1) = d^x_{\tau+k-1}(u,v)$$

$$I_\tau(u, v, 2k) = d^y_{\tau+k-1}(u, v) \quad \text{pentru } u = 1...w, v = 1...h, k = 1...L$$

Unde canalele $c = 1..2L$ codifică mișcarea la acel punct (u, v) pe o secvență de L cadre,,.

Stivuirea Traiectoriilor (Trajectory Stacking)

- Aceasta este o reprezentare alternativă a mișcării care înlocuiește fluxul optic eșantionat în aceleași locații cu fluxul eșantionat de-a lungul **traiectoriilor de mișcare**,,.
- Spre deosebire de reprezentarea fluxului optic (unde canalele stochează vectorii de deplasare la locațiile (u, v)), volumul de intrare pentru stivuirea traiectoriilor stochează vectorii eșantionați la locațiile $\mathbf{p}_k$ de-a lungul traiectoriei,,.
- Punctul $\mathbf{p}_k$ de-a lungul traiectoriei este definit printr-o relație de recurență:

$$\mathbf{p}_1 = (u, v), \quad \mathbf{p}_k = \mathbf{p}_{k-1} + \mathbf{d}_{\tau+k-2}(\mathbf{p}_{k-1}), \quad k > 1$$

Fuziunea (Fusion)

- Fiecare flux este implementat folosind un CNN profund, ale cărui scoruri Softmax sunt combinate prin **fuziune târzie (*late fusion*)**,,.
- Sunt luate în considerare două metode de fuziune:
  1. **Medierea (*averaging*):** Medierea scorurilor Softmax,,.
  2. **Antrenarea unui SVM liniar:** Antrenarea unui SVM liniar multiclasă pe scorurile Softmax stivuite normalizate l_2 ca *feature*-uri,,.

---

3. 💡 EXPLICAȚII SUPLIMENTARE ȘI CLARIFICĂRI (IMPORTANT)

Termen Tehnic: Fluxul Optic (Optical Flow)

- **Explicație Simplificată (Săgețile Mișcării):** Fluxul optic nu este videoclipul în sine, ci o hartă matematică. Fiecare pixel dintr-un cadru este înlocuit cu o **săgeată** care arată exact unde s-a mutat acel pixel în cadrul următor. Aceste săgeți reprezintă vectorii de deplasare $\mathbf{d}$. Folosirea fluxului optic ca intrare separă explicit informația de mișcare de aparența statică, ușurând sarcina rețelei de a recunoaște acțiunea,,.

Concept Dificil: Fuziunea Târzie (Late Fusion)

- **Analogia (Judecătorul și Experții):** Fuziunea târzie este ca și cum ați avea doi experți care lucrează independent:
  - **Expertul Spațial:** Se uită la fotografii clare (cadre statice) și zice: "Cred că e vorba de o persoană cu o chitară."

    - **Expertul Temporal:** Se uită doar la săgețile de mișcare (fluxul optic) și zice: "Mișcarea sugerează că persoana cântă la chitară."
- **Decizia:** Un judecător (SVM-ul sau medierea) combină scorurile finale de la ambii experți. Ei nu lucrează împreună în timpul analizei, ci doar la sfârșit.

Context Suplimentar: Stivuirea Traiectoriilor vs. Stivuirea Fluxului Optic

- *Asta se întâmplă deoarece:* Stivuirea fluxului optic (1) eșantionează vectorii de deplasare $\mathbf{d}$ la **aceeași locație** (u, v) pe măsură ce timpul $(\tau, \tau+1, \ldots)$ trece,,,,. Stivuirea traiectoriilor (2) este mai inteligentă: ea urmează punctul pe măsură ce se mișcă, eșantionând vectorii $\mathbf{d}$ de-a lungul **traiectoriei reale** $\mathbf{p}_k$ a punctului,,,,.

---

4. 🔗 CONEXIUNI ȘI IMPLICAȚII

- **Relația Cauză-Efect (Pre-antrenarea Fluxului Spațial):**
    - **CAUZĂ:** Fluxul Spațial este o arhitectură de clasificare a imaginii.
    - **EFECT:** Poate fi **pre-antrenat** pe seturi de date mari, cum ar fi ImageNet, crescând eficiența antrenamentului,,.
- **Conexiunea cu Secțiunea 9.1 (Fuziunea):** Spre deosebire de Early Fusion sau Slow Fusion, care încearcă să integreze spațiul și timpul mai devreme în rețea, **Two-Stream CNNs** folosesc explicit **Fuziunea Târzie** la nivelul scorurilor de clasă,,.

---

5. EXERCITII (Calcul și Analiză Formulistică)

Exercițiul T.1: Calculul Numărului de Canale de Intrare (Fluxul Temporal)

Un model Two-Stream CNN dorește să reprezinte mișcarea pe o secvență de L cadre consecutive utilizând **stivuirea fluxului optic** (Optical flow stacking).

1. Dacă $L = 5$ (5 cadre consecutive sunt folosite), câte canale de intrare totale $2L$ va avea volumul de intrare I_τ pentru Fluxul Temporal?
2. Explicați fizic ce codifică fiecare pereche de canale $(2k-1, 2k)$ în volumul de intrare,,.

Rezolvare T.1:

1. **Numărul Total de Canale de Intrare ($2L$):** Pentru $L = 5$, numărul total de canale este $2 \times 5 = \mathbf{10}$ canale,,.
2. **Codificarea Canalelor:** Fiecare pereche de canale $(2k-1, 2k)$ codifică cele două componente ale vectorului de deplasare $\mathbf{d}$ (fluxul optic): d^x (componenta orizontală) și d^y

(componenta verticală) pentru o pereche de cadre,,.

Exercițiul T.2: Analiza Stivuirea Traiectoriilor (Formula de Recurență)

Stivuirea traiectoriilor utilizează o relație de recurență pentru a defini punctul $\mathbf{p}_k$ de-a lungul traiectoriei, care începe la (u, v).

Scrieți relația de recurență pentru $\mathbf{p}_k$ și explicați ce reprezintă $\mathbf{d}_{\tau+k-2}(\mathbf{p}_{k-1})$ în contextul acestei formule,,.

Rezolvare T.2:

Relația de recurență este:

$$\mathbf{p}_1 = (u, v), \quad \mathbf{p}_k = \mathbf{p}_{k-1} + \mathbf{d}_{\tau+k-2}(\mathbf{p}_{k-1}), \quad k > 1$$

Termenul $\mathbf{d}_{\tau+k-2}(\mathbf{p}_{k-1})$ reprezintă **vectorul de deplasare (fluxul optic)** calculat în cadrul $\tau + k - 2$, dar **eșantionat la locația anterioară** $\mathbf{p}_{k-1}$ (nu la o locație fixă (u, v)), pentru a urmări mișcarea reală a punctului de-a lungul traiectoriei,,.

Exercițiul T.3: Analiza Fuziunii Târzii (Late Fusion)

Modelul Two-Stream utilizează două metode de fuziune târzie a scorurilor Softmax: medierea și antrenarea unui SVM liniar. Explicați avantajul utilizării **SVM-ului liniar** ca metodă de fuziune comparativ cu simpla mediere a scorurilor,,.

Rezolvare T.3:

Avantajul utilizării unui **SVM liniar multiclasă** este că acesta tratează scorurile Softmax normalizate l_2 ale celor două fluxuri ca **feature-uri** și învață **ponderi optime** pentru a le combina,,. Spre deosebire de medierea simplă (care presupune ponderi egale), SVM-ul permite modelului să acorde o **importanță diferită** informațiilor spațiale și celor temporale, pe baza performanței lor pe datele de antrenament,,.

9.3

Absolut! Lecția **9.3 3D CNNs (C3D)** reprezintă o evoluție crucială în clasificarea video, extinzând operațiile de convoluție și *pooling* de la două dimensiuni (spațiu) la trei dimensiuni (spațiu-timp) pentru a capta eficient mișcarea.

Ghid de Studiu Complet: 9.3 3D CNNs (C3D)

1. 🎯 SINTEZA LECȚIEI (THE BIG PICTURE)

Lecția 9.3 introduce Rețelele Convoluționale 3D (3D CNNs sau C3D), care sunt fundamental diferite de CNN-urile 2D deoarece aplică operațiile de convoluție și *pooling* **spațio-**

temporal. În timp ce convoluțiile 2D se aplică doar în dimensiunile spațiale, cele 3D folosesc un **kernel 3D** pentru a procesa cubul format prin stivuirea mai multor cadre contigue, capturând astfel informația de mișcare,. Rețelele 3D CNN sunt considerate potrivite pentru învățarea *feature*-urilor spațio-temporale, deoarece **păstrează informațiile temporale** ale semnalelor de intrare, rezultând un volum de ieșire,. Prin experimente arhitecturale, s-a constatat că un kernel omogen de $3 \times 3 \times 3$ este cea mai bună alegere pentru rețelele C3D, performând consistent mai bine decât rețelele 2D CNN în clasificarea video,,.

Care sunt cele 5 idei principale pe care trebuie neapărat să le rețin?

1. **Diferența Esențială:** CNN-urile 3D realizează convoluții și *pooling* **spațio-temporal** (3D), în timp ce CNN-urile 2D le fac doar spațial (2D),.
2. **Scopul 3D:** Convoluțiile 3D sunt folosite pentru a capta **informația de mișcare** codificată în mai multe cadre contigue,.
3. **Kernel 3D:** Un kernel 3D este aplicat pe un **cub 3D** (stivuirea cadrelor contigue).
4. **C3D Proiectată:** Arhitectura propusă C3D utilizează 8 straturi convoluționale, 5 straturi de *pooling*, și 2 straturi complet conectate, folosind filtre omogene de $3 \times 3 \times 3$ **cu *stride*** $1 \times 1 \times 1$,.
5. **Păstrarea Temporală:** Doar convoluția 3D (și *pooling*-ul 3D) **păstrează informația temporală** a semnalului de intrare, rezultând un volum de ieșire, în timp ce 2D CNN-urile o pierd după fiecare operație,.

---

2. 📖 REZUMAT DETALIAT (PE CAPITOLE/SECȚIUNI)

9.3 3D CNNs (C3D) – Fundamente

- **2D CNNs:** Convoluția 2D se efectuează la straturile convoluționale pentru a extrage *feature*-uri din vecinătatea locală pe hărțile de *feature* din stratul anterior,. Convoluțiile sunt aplicate numai în **dimensiunile spațiale**,.
- **3D CNNs:** Când se aplică la probleme de analiză video, este de dorit să se capteze informația de mișcare codificată în mai multe cadre contigue,.
- Convoluțiile 3D pot fi utilizate în etapele de convoluție ale CNN-urilor pentru a calcula *feature*-uri din **ambele dimensiuni, spațiale și temporale**,.
- Convoluția 3D se realizează prin **convoluția unui kernel 3D** cu cubul format prin stivuirea mai multor cadre contigue,.
- Prin această construcție, hărțile de *feature* dintr-un strat de convoluție sunt conectate la mai multe cadre contigue din stratul anterior, **capturând astfel informația de mișcare**,.

Operațiile de Bază și Păstrarea Informației

- Spre deosebire de 2D CNNs, în 3D CNNs, operațiile de convoluție și *pooling* sunt efectuate **spațio-temporal**,.

- **2D CNNs pierd informațiile temporale** ale semnalului de intrare după fiecare operație de convoluție,.
- **Doar convoluția 3D păstrează informațiile temporale** ale semnalelor de intrare, rezultând un **volum de ieșire**,. Același fenomen este aplicabil și pentru *pooling*-ul 2D vs. 3D,.

Formula Convoluției 3D

Valoarea unei unități la poziția (x, y, z) în a j-a hartă de *feature* din stratul i, notată v_{ij}^{xyz}, este dată formal de:

$$v_{ij}^{xyz} = \phi \left(b_{ij} + \sum_{m} \sum_{p=0}^{P_i-1} \sum_{q=0}^{Q_i-1} \sum_{r=0}^{R_i-1} w_{ijm}^{pqr} V_{(i-1)m}^{(x+p)(y+q)(z+r)} \right)$$

- R_i este **dimensiunea kernelului 3D de-a lungul dimensiunii temporale**.
- w_{ijm}^{pqr} este valoarea la poziția (p, q, r) a kernelului conectat la a m-a hartă de *feature* din stratul anterior.
- P_i și Q_i sunt înălțimea și lățimea kernelului,.

Extragerea Multiplă de Feature-uri

- Un kernel convoluțional 3D poate extrage doar **un singur tip de *feature*** din cubul de cadre,.
- Pentru a crește numărul de hărți de *feature* (și a genera **tipuri multiple de *feature*-uri**) în straturile superioare, se pot aplica multiple convoluții 3D cu **kerneluri distincte** la aceeași locație din stratul anterior,,,.

Căutarea Arhitecturii Optime (C3D)

- Pe baza rezultatelor din 2D CNNs (care sugerează că câmpurile receptive mici de 3×3 dau cele mai bune rezultate), dimensiunea receptivă spațială a kernelului a fost fixată la 3×3, iar **adâncimea temporală** d a kernelului 3D a fost variată,.
- **Notații:** Un clip video are dimensiunea $c \times l \times h \times w$ (canale $\times$ lungime/cadre $\times$ înălțime $\times$ lățime),. Kernelul de convoluție/pooling 3D are dimensiunea $d \times k \times k$, unde d este adâncimea temporală, iar k este dimensiunea spațială,.
- **Tipuri de Arhitecturi Testate:**
  1. **Setare Omogenă (*Homogeneous*):** Toate straturile de convoluție au aceeași adâncime temporală d (ex: *depth-3* net),.
  2. **Adâncime Temporală Variabilă (*Varying*):** Adâncimea temporală a kernelului se schimbă de-a lungul straturilor (ex: 3-3-5-5-7 sau 7-5-5-3-3),.
- **Rezultate Cheie:**
  - Rețeaua $depth$-3 (kernel $3 \times 3 \times 3$ pe toate straturile) a performat cel mai bine dintre rețelele omogene,.

- Rețeaua $depth$-1 (echivalentă cu aplicarea convoluției 2D pe cadre separate) a performat **semnificativ mai slab**, din cauza lipsei de modelare a mișcării,,,.
- Aceste rezultate sugerează că $3 \times 3 \times 3$ este cea mai bună alegere de kernel,.

Setări Comune de Rețea (C3D)

- **Intrare:** Clipurile video sunt împărțite în clipuri non-suprapuse de **16 cadre**,.
- **Dimensiuni de Intrare:** $3\ (\text{canale}) \times 16\ (\text{cadre}) \times 128 \times 171\ (\text{rezoluție resize})$,.
- **Structură:** Rețeaua are 5 straturi convoluționale, 5 straturi de *pooling* (fiecare strat Conv urmat de Pooling), 2 straturi complet conectate (FC) și un strat Softmax,.
- **Ieșiri FC:** Cele două straturi complet conectate (fc6, fc7) au fiecare $\mathbf{2048}$ de ieșiri,. *Notă: Figura 8 menționează 4096,. Folosim 4096, conform descrierii arhitecturii finale.*

Arhitectura Finală C3D (Extinsă)

- **Structura Finală:** C3D propusă are **8 straturi convoluționale**, 5 straturi max-pooling, 2 straturi complet conectate, și Softmax,,,.
- **Filtre:** Toate filtrele de convoluție 3D sunt de $\mathbf{3} \times \mathbf{3} \times \mathbf{3}$ cu *stride* $\mathbf{1} \times \mathbf{1} \times \mathbf{1}$,,,.
- **Pooling:** Toate straturile *pooling* sunt max-pooling $2 \times 2 \times 2$ cu *stride* $2 \times 2 \times 2$, **cu excepția primului strat (*pool1*)**,.
- **Pooling 1:** Primul strat *pooling* (pool1) are un kernel size de $1 \times 2 \times 2$ și *stride* $1 \times 2 \times 2$, cu intenția de a **păstra informațiile temporale în faza incipientă**,.
- **Ieșiri FC:** Fiecare strat complet conectat (fc6, fc7) are $\mathbf{4096}$ de unități de ieșire,,,.

---

3. 💡 EXPLICAȚII SUPLIMENTARE ȘI CLARIFICĂRI (IMPORTANT)

Termen Tehnic: Păstrarea Informației Temporale (Preserving Temporal Information)

- **Explicație Simplificată (Volumul de Ieșire):** Când aplicăm o convoluție 2D pe un videoclip (văzut ca o stivă de imagini), ieșirea este tot o imagine (pierdem dimensiunea temporală). Când aplicăm o convoluție 3D, ieșirea este un **volum** (un cub),. Dacă intrăm cu un cub de 16 cadre, după convoluția 3D, tot un număr redus de cadre (sau o versiune comprimată a acestora) rămâne în ieșire. Acest lucru permite straturilor ulterioare să aibă în continuare acces la evoluția temporală.

Concept Dificil: Rolul Pool1 de $1 \times 2 \times 2$

- **Analogie (Încetinirea Compresiei):** În general, *pooling*-ul $2 \times 2 \times 2$ ar reduce rezoluția temporală la jumătate (de la 16 la 8 cadre). Dacă s-ar face asta prea devreme, rețeaua ar putea pierde detalii subtile de mișcare. Kernelul $1 \times 2 \times 2$ la *pool1* înseamnă că **se face *pooling* doar spațial (2×2)**, dar **nu se face *pooling* temporal (dimensiunea 1)**,.

- *Asta se întâmplă deoarece:* Evitarea *pooling*-ului temporal prea devreme ajută la **păstrarea informației temporale în faza incipientă** a rețelei, permițând convoluțiilor ulterioare să extragă *feature*-uri de mișcare mai bine,.

---

4. 🔗 CONEXIUNI ȘI IMPLICAȚII

- **Relația Cauză-Efect (Lipsa de Modelare a Mișcării):**
  - **CAUZĂ:** Rețeaua *depth-1* este echivalentă cu aplicarea convoluțiilor 2D pe cadre separate,.
  - **EFECT:** Performanța *depth-1* este **semnificativ mai slabă** decât alte rețele, deoarece **duce la lipsa modelării mișcării**,. Aceasta subliniază necesitatea absolută a modelării mișcării (prin convoluție 3D) în clasificarea video.
- **Conexiunea cu 2D CNNs:** Căutarea arhitecturii optime 3D a fost ghidată de succesul kernel-urilor mici (3×3) și al arhitecturilor profunde în 2D CNNs,,.

---

5. EXERCITII (Calcul și Analiză Arhitecturală)

Exercițiul C.6.1: Analiza Arhitecturală C3D (Pooling Temporal)

Arhitectura C3D utilizează 5 straturi de *pooling* max-pooling $2 \times 2 \times 2$ cu *stride* $2 \times 2 \times 2$, cu excepția *pool1* ($1 \times 2 \times 2$, *stride* $1 \times 2 \times 2$).

1. Dacă clipul inițial de intrare are $L = 16$ cadre, care este numărul de cadre (lungimea temporală) după aplicarea stratului **pool1**?
2. Dacă s-ar aplica *pooling* $2 \times 2 \times 2$ (reducere cu factor 2) la fiecare din cele 5 straturi de *pooling*, cu câte ar fi redus semnalul de intrare (16 cadre) la sfârșitul stratului *pool5*?

Rezolvare C.6.1:

1. **Cadre după pool1:** Deoarece kernelul temporal al *pool1* este $d = 1$ cu *stride* 1, nu există reducere temporală. Numărul de cadre rămâne **16**,.
2. **Reducerea la pool5 (Ipotetic):** Reducerea totală temporală ar fi $2^5 = 32$. Deoarece intrarea are doar 16 cadre, modelul ar reduce semnalul de intrare la $16/32 = \mathbf{0.5}$ cadre (sau, în termeni practici, semnalul temporal ar fi complet colapsat și s-ar pierde informațiile),.

Exercițiul C.6.2: Analiza Comparativă a Parametrilor (Teorie)

S-a notat că diferența în numărul de parametri între rețelele *depth-1* și *depth-7* este de doar 51K, ceea ce reprezintă mai puțin de 0.3% din totalul de 17.5 milioane de parametri al fiecărei rețele,.

1. Explicați de ce diferențele în numărul de parametri sunt "destul de minore" în comparație cu straturile complet conectate.
2. Ce concluzie majoră (în raport cu capacitatea de învățare) este trasă din această mică diferență de parametri?

Rezolvare C.6.2:

1. **Diferența Minoră:** Diferența în numărul de parametri este minoră deoarece majoritatea parametrilor (milioane) sunt concentrați în **straturile complet conectate (FC)**,. Numărul de parametri diferă doar la **straturile de convoluție** din cauza adâncimii temporale diferite (d),.
2. **Concluzia:** Aceasta indică faptul că **capacitățile de învățare ale rețelelor sunt comparabile**, iar diferențele de performanță nu sunt rezultatul direct al numărului de parametri, ci al capacității arhitecturale de a modela eficient mișcarea (spațio-temporalitate),.

Exercițiul C.6.3: Analiza Formulistică 2D vs. 3D

Comparați formal termenul kernel din formula convoluției 2D cu cel din formula convoluției 3D și explicați ce aduce nou convoluția 3D (C3D).

Formula 2D: $v_{ij}^{xy} = \phi\left(b_{ij} + \sum_m \sum_{p=0}^{P_i-1} \sum_{q=0}^{Q_i-1} w_{ijm}^{pq} V_{(i-1)m}^{(x+p)(y+q)}\right)$,

Formula 3D: $v_{ij}^{xyz} = \phi\left(b_{ij} + \sum_m \sum_{p=0}^{P_i-1} \sum_{q=0}^{Q_i-1} \sum_{r=0}^{R_i-1} w_{ijm}^{pqr} V_{(i-1)m}^{(x+p)(y+q)(z+r)}\right)$

Rezolvare C.6.3:

Convoluția 3D adaugă o a treia dimensiune de însumare și un al treilea indice la kernel:

1. **Însumare:** Formula 3D include un termen de însumare suplimentar $\sum_{r=0}^{R_i-1}$.
2. **Kernel:** Valoarea kernelului 3D este w_{ijm}^{pqr} (cu trei indici spațiali/temporali p, q, r), în timp ce kernelul 2D este w_{ijm}^{pq} (doar doi indici spațiali),,.
3. **Noua Dimensiune:** Convoluția 3D aduce nou introducerea dimensiunii temporale R_i (dimensiunea kernelului 3D de-a lungul dimensiunii temporale), permițând kernelului să extragă *feature*-uri atât din dimensiunile spațiale, cât și din cele **temporale**,.

9.4

Sunt onorat să vă prezint Ghidul de Studiu pentru lecția **9.4 Temporal Segment Networks (TSN)**, care oferă o soluție elegantă la problema modelării structurii temporale pe distanțe lungi în videoclipuri.

Ghid de Studiu Complet: 9.4 Temporal Segment Networks (TSN)

1. 🎯 SINTEZA LECȚIEI (THE BIG PICTURE)

Rețelele convoluționale cu două fluxuri (Two-Stream CNNs) în formele lor anterioare aveau un defect evident: inabilitatea de a modela **structura temporală pe distanțe lungi** (*long-range temporal structure*). Acest lucru se datora accesului lor limitat la contextul temporal, deoarece operau doar pe un singur cadru sau pe o stivă scurtă de cadre. Pentru a aborda această problemă, este propusă **Temporal Segment Network (TSN)**, un cadru la nivel de video (video-level framework) care modelează dinamica pe durata întregului videoclip. TSN realizează acest lucru prin operarea pe o **secvență de *snippets* scurte, eșantionate rar (*sparsely sampled*)** din întregul videoclip. Predicția finală este derivată dintr-un **consens** între predicțiile preliminare ale fiecărui *snippet*. Arhitectura utilizează rețele CNN cu flux spațial și temporal, adaptând structura BN-Inception (Batch Normalization-Inception) pentru a îmbunătăți echilibrul dintre acuratețe și eficiență.

Care sunt cele 5 idei principale pe care trebuie neapărat să le rețin?

1. **Problema Rezolvată:** Inabilitatea CNN-urilor cu două fluxuri de a modela **structura temporală pe distanțe lungi**.
2. **Mecanismul de Eșantionare:** Videoclipul este împărțit în K **segmente**, iar un *snippet* scurt (T_k) este **eșantionat aleatoriu** din fiecare segment (S_k).
3. **Consensul:** Fiecare *snippet* produce o predicție preliminară, iar predicția finală la nivel de video se obține printr-o **funcție de consens ($\mathcal{G}$)**.
4. **Optimizare:** Pierderea $\mathcal{L}$ este optimizată la nivel de video (pe baza consensului $\mathbf{G}$), nu pe predicțiile individuale ale *snippet*-urilor.
5. **Modalități de Intrare:** Pe lângă RGB și fluxul optic (optical flow), TSN explorează modalități suplimentare, precum **diferența RGB** (RGB difference) și **fluxul optic deformat** ($warped$ optical flow).

---

2. 📖 REZUMAT DETALIAT (PE CAPITOLE/SECȚIUNI)

9.4 Temporal Segment Networks (TSN)

Motivație și Obiectiv

- O problemă evidentă a rețelelor CNN cu două fluxuri este inabilitatea de a modela **structura temporală pe distanțe lungi**.
- Acest neajuns este atribuit accesului lor limitat la contextul temporal, deoarece operează doar pe un singur cadru (rețele spațiale) sau pe o singură stivă de cadre într-un *snippet* scurt (rețele temporale).
- Acțiunile complexe (ex: acțiunile sportive) cuprind multiple etape pe o durată relativ lungă. Ar fi o pierdere să nu se utilizeze aceste structuri temporale de lungă durată în antrenarea CNN.

- TSN propune un cadru la nivel de video pentru a modela dinamica pe durata întregului videoclip.

Cadrul Formal și Eșantionarea Segmentată

- Fiind dat un video V, acesta este împărțit în K **segmente** $S_1, S_2, \ldots, S_K$ de durată egală.
- TSN modelează o secvență de *snippets* $T_1, T_2, \ldots, T_K$, unde **fiecare *snippet* T_k este eșantionat aleatoriu din segmentul corespunzător** S_k.
- Fiecare *snippet* T_k este procesat de o funcție $\mathcal{F}(T_k\, \mathbf{W})$ (care reprezintă un CNN cu parametrii $\mathbf{W}$) și produce scoruri de clasă preliminare.
- **Consensul Segmental ($\mathcal{G}$):** O funcție de consens $\mathcal{G}$ combină ieșirile de la multiple *snippets* pentru a obține un consens al ipotezelor de clasă între ele.
- **Funcția de Predicție Finală ():** Bazată pe acest consens, funcția de predicție (care este Softmax-ul ales) prezice probabilitatea fiecărei clase de acțiune pentru întregul video.

$$\mathrm{TSN}(T_1, T_2, \ldots, T_K) = (\mathcal{G}(\mathcal{F}(T_1\, \mathbf{W}), \mathcal{F}(T_2\, \mathbf{W}), \ldots, \mathcal{F}(T_K\, \mathbf{W})))$$

Antrenament și Optimizare

- În timpul antrenamentului, **valorile pierderii predicțiilor la nivel de video** sunt optimizate, spre deosebire de pierderile predicțiilor la nivel de *snippet* folosite în CNN-urile cu două fluxuri.
- Pierderea finală $\mathcal{L}(\mathbf{y}, \mathbf{G})$ este formată prin combinarea consensului segmental $\mathbf{G}$ cu pierderea standard *categorical cross-entropy*.

$$\mathcal{L}(\mathbf{y}, \mathbf{G}) = -\sum_{i=1}^{C} y_i \left(\log G_i - \log \left(\sum_{j=1}^{C} \exp G_j \right) \right)$$

  - Unde C este numărul de clase de acțiune și y_i este eticheta *ground truth*.
- În practică, numărul de *snippets* K este stabilit la $K = 3$.
- **Funcția de Agregare (g):** Forma funcției de consens $\mathcal{G}$ a fost empiric evaluată, fiind testate funcții precum **media uniformă (*evenly averaging*)**, maximul (*maximum*) și media ponderată (*weighted averaging*).
- **Media uniformă (*evenly averaging*)** a avut cea mai bună performanță.
- Rețeaua TSN este diferențiabilă (sau are sub-gradienți), permițând optimizarea parametrilor $\mathbf{W}$ prin **algoritmi standard de *backpropagation***.
- Strategia de eșantionare temporală rară (*sparse temporal sampling*) **reduce drastic costul computațional** pentru evaluarea CNN-urilor pe cadre, comparativ cu lucrările anterioare care foloseau cadre eșantionate dens.

Arhitectura Rețelei și Modalități de Intrare

- **Arhitectura de Bază:** Arhitectura BN-Inception (Inception with Batch Normalization) este aleasă ca bloc de construcție, datorită echilibrului său bun între acuratețe și eficiență.

- **Fluxul Spațial (Spatial Stream):** Operează pe o singură imagine **RGB**.
- **Fluxul Temporal (Temporal Stream):** Procesează o stivă de câmpuri de **flux optic consecutive** ca intrare.
- **Modalități Suplimentare de Intrare:** Sunt propuse două modalități extra pentru a îmbunătăți puterea de discriminare:
  1. **Diferența RGB (RGB difference):** Descrie schimbarea de aparență între două cadre consecutive, corespunzătoare regiunii proeminente de mișcare.
  2. **Fluxul Optic Deformat ($warped$ optical flow):** Este obținut prin estimarea matricei de homografie și apoi **compensarea mișcării camerei**. Acest lucru suprimă mișcarea de fundal și face ca mișcarea să se concentreze pe actor.

---

3. 💡 EXPLICAȚII SUPLIMENTARE ȘI CLARIFICĂRI (IMPORTANT)

Termen Tehnic: Eșantionare Temporală Rară (Sparse Temporal Sampling)

- **Explicație Simplificată (Fotografia La Intervale):** În loc să analizeze fiecare cadru (sau un grup compact de cadre) dintr-un videoclip lung, TSN ia doar câteva "instantanee" (*snippets*) răspândite uniform pe parcursul întregii durate a videoclipului. De exemplu, dintr-un videoclip de 30 de secunde, ia un *snippet* de la secunda 5, unul de la secunda 15 și unul de la secunda 25 (pentru $K = 3$).
- *Asta se întâmplă deoarece:* Această metodă **păstrează contextul pe distanțe lungi** (știe ce s-a întâmplat la început, mijloc și sfârșit) fără a necesita costul computațional imens al procesării fiecărui cadru.

Concept Dificil: Fluxul Optic Deformat ($Warped$ Optical Flow)

- **Analogia (Stabilizatorul de Cameră):** Fluxul optic normal include mișcarea camerei (dacă utilizatorul mișcă camera). Dacă încercați să clasificați acțiunea "Săritură în înălțime", mișcarea laterală a camerei poate domina semnalul de mișcare. Fluxul optic deformat este ca un **stabilizator digital**. Prin compensarea mișcării de fundal, el **izolează mișcarea actorului**.

Context Suplimentar: Rolul Consensului

- TSN folosește consensul $\mathcal{G}$ deoarece fiecare *snippet* eșantionat aleatoriu T_k oferă doar o **predicție preliminară** pentru acțiune. Prin medierea predicțiilor celor $K = 3$ *snippets* (unul din început, unul din mijloc, unul din sfârșit), modelul obține o clasificare mai robustă și mai reprezentativă pentru acțiunea totală a videoclipului.

---

4. 🔗 CONEXIUNI ȘI IMPLICAȚII

- **Relația Cauză-Efect (Utilizarea Consensului):**
  - **CAUZĂ:** Dorința de a modela dinamica pe durata **întregului videoclip**.
  - **EFECT:** Necesitatea de a utiliza o funcție de consens $\mathcal{G}$ și de a optimiza pierderea la **nivel de video**.
- **Conexiunea cu Secțiunea 9.2 (Two-Stream):** TSN este construit pe arhitectura **Two-Stream CNNs** (Fluxul Spațial + Fluxul Temporal), dar depășește limitarea acesteia privind contextul temporal scurt.

---

5. EXERCITII (Calcul și Analiză Formulistică)

Exercițiul T4.1: Analiza Eșantionării Temporale

Un videoclip are o durată de 30 de secunde. Modelul TSN este setat să utilizeze $K = 3$ *snippets* eșantionate rar.

1. Calculați durata segmentului S_k (în secunde) dacă videoclipul este împărțit în $K = 3$ segmente de durată egală.
2. Explicați impactul eșantionării rare asupra costului computațional.

Rezolvare T4.1:

1. **Durata Segmentului:**

$$\text{Durata segmentului} = \frac{\text{Durata totală}}{\text{Numărul de segmente } K} = \frac{30 \text{ secunde}}{3} = \mathbf{10} \text{ secunde}$$

2. **Impactul Costului Computațional:** Fixând K pentru toate videoclipurile, strategia de eșantionare temporală rară asigură că *snippets*-urile eșantionate conțin doar o mică porțiune din totalul cadrelor. Acest lucru **reduce drastic costul computațional** pentru evaluarea CNN-urilor pe cadre, comparativ cu lucrările anterioare care foloseau eșantionare densă.

Exercițiul T4.2: Analiza Funcției de Pierdere (Cross-Entropy)

Funcția de pierdere $\mathcal{L}(\mathbf{y}, \mathbf{G})$ combină consensul segmental $\mathbf{G}$ cu pierderea *categorical cross-entropy*.

1. În formula pierderii, ce reprezintă $\sum_{i=1}^{C} y_i(\ldots)$?
2. Dacă s-a constatat că media uniformă (*evenly averaging*) a avut cea mai bună performanță pentru funcția de agregare g, explicați cum ar fi obținut scorul clasei G_i pentru un număr K de *snippets*.

Rezolvare T4.2:

1. **Semnificația Termenului $\sum_{i=1}^{C} y_i(\ldots)$:** Acest termen reprezintă o sumă pe toate cele C clase de acțiune. Deoarece $\mathbf{y}$ este vectorul de etichete *ground truth*, iar în clasificarea *categorical* doar o singură clasă y_k este 1 (restul 0), suma selectează **doar termenul de pierdere corespunzător clasei corecte (k)**.
2. **Calculul Scorului Clasei G_i prin Mediere Uniformă:** Scorul clasei G_i este inferat din scorurile aceleiași clase i obținute de la toate *snippets*-urile, folosind o funcție de agregare g. Dacă se folosește media uniformă, G_i este pur și simplu media aritmetică a scorurilor clasei i de la fiecare *snippet* $k = 1$ la K.

Exercițiul T4.3: Analiza Modalităților Suplimentare

1. Explicați diferența dintre modalitatea de intrare **Diferența RGB** (RGB difference) și intrarea Fluxului Optic standard, din perspectiva informației capturate.
2. De ce este necesar Fluxul Optic Deformat ($warped$ optical flow) în videoclipurile realiste?

Rezolvare T4.3:

1. **Diferența RGB vs. Flux Optic:** O singură imagine RGB codifică aparența statică. **Diferența RGB** între două cadre consecutive descrie **schimbarea de aparență** care corespunde regiunii proeminente de mișcare. Fluxul Optic standard, în schimb, capturează câmpurile vectoriale de deplasare, care reprezintă mișcarea pixelilor.
2. **Necesitatea Fluxului Optic Deformat:** În videoclipurile realiste, câmpurile de flux optic pot să nu se concentreze pe acțiunea umană din cauza **mișcării camerei** (camera motion). Fluxul optic deformat compensează mișcarea camerei prin estimarea matricei de homografie, suprimând mișcarea de fundal și făcând ca mișcarea să se concentreze pe actor.

9.5

Suntem la lecția **9.5 Two-Stream Inflated 3D CNNs (I3D)**, care aduce o contribuție tehnică majoră, rezolvând o problemă fundamentală a rețelelor 3D CNN anterioare: lipsa antrenării prealabile pe ImageNet și superficialitatea arhitecturilor.

Ghid de Studiu Complet: 9.5 Two-Stream Inflated 3D CNNs (I3D)

1. 🎯 SINTEZA LECȚIEI (THE BIG PICTURE)

Lecția 9.5 introduce **Two-Stream Inflated 3D CNNs (I3D)** ca o contribuție tehnică principală. Această arhitectură combină beneficiile rețelelor 3D (capacitatea de a învăța reprezentări spațio-temporale) cu puterea de inițializare oferită de rețelele de clasificare a imaginilor pre-antrenate pe ImageNet. Problema rețelelor 3D anterioare (precum C3D) era că erau superficiale (shallow, sub 8 straturi) din cauza dimensionalității mari a parametrilor și a lipsei

de date video etichetate. Soluția inovatoare propusă este **inflația trivială** a arhitecturilor 2D de succes (Inception, VGG, ResNet) în extractori de *feature*-uri spațio-temporale 3D. De asemenea, se păstrează configurația cu **două fluxuri (Two-Stream)**, demonstrând că includerea unui flux optic (optical flow) îmbunătățește considerabil performanța, chiar și pentru rețelele 3D care pot învăța tipare temporale din fluxul RGB.

Care sunt cele 5 idei principale pe care trebuie neapărat să le rețin?

1. **Contribuția I3D:** I3D este o metodă de **inflație** a arhitecturilor 2D de clasificare a imaginilor (ex: Inception-V1) în rețele 3D.
2. **Inițializare Valoroasă:** Inflația permite reutilizarea ponderilor pre-antrenate pe **ImageNet** (proces numit *bootstrapping* sau *boring-video fixed point*).
3. **Configurația Two-Stream:** Chiar dacă 3D CNN-urile pot învăța mișcarea din RGB, configurația cu două fluxuri (RGB și Flux Optic) este în continuare **utilă** și îmbunătățește performanța.
4. **Arhitecturi Evaluate:** Lucrarea compară și studiază un subset de modele, inclusiv CNN+LSTM, rețele Two-Stream (cu două tipuri de fuziune), și 3D CNN (C3D).
5. **Diferența C3D Modificată:** O variantă a C3D implementată în lucrare folosește **Batch Normalization** și un *stride* temporal de 2 în primul strat de *pooling* (față de 1 la C3D originală), pentru a reduce amprenta memoriei și a permite *batch*-uri mai mari.

---

2. 📖 REZUMAT DETALIAT (PE CAPITOLE/SECȚIUNI)

9.5 Two-Stream Inflated 3D CNNs (I3D)

Diferențe Majore în Arhitecturile Video Anterioare

Diferențele principale între arhitecturile video anterioare includ:

- Dacă operatorii convoluționali și de *pooling* folosesc **kerneluri 2D (bazate pe imagini) sau 3D (bazate pe video)**.
- Dacă intrarea în rețea este doar **video RGB** sau include și **flux optic pre-calculat**.
- Cum este propagată informația între cadre în cazul 2D CNN-urilor (folosind **straturi recurente temporal, cum ar fi LSTM-urile**, sau **agregarea *feature*-urilor în timp**).

Lucrarea compară un subset de modele, inclusiv CNN-uri cu LSTM deasupra, rețele Two-Stream (cu două tipuri de fuziune) și 3D CNN (C3D).

Provocări 3D CNNs Anterioare (C3D)

- Din cauza **dimensionalității mari a parametrizării lor** și a lipsei de date video etichetate, 3D CNN-urile anterioare erau relativ **superficiale** (până la 8 straturi).
- Modelele 3D CNN păreau să excludă beneficiile pre-antrenării pe ImageNet, fiind antrenate de la zero (*from scratch*).

- Deși rezultatele 3D CNN-urilor arătau promisiuni, ele nu erau competitive cu *state-of-the-art*.

Ideea Centrală: Inflating 2D CNNs into 3D (I3D)

- Contribuția tehnică principală este introducerea **Two-Stream Inflated 3D CNNs (I3D)**.
- Se observă că rețelele de clasificare a imaginilor de mare succes (Inception, VGG-16, ResNet) pot fi **trivial umflate (*trivially inflated*)** în extractoare de *feature*-uri spațio-temporale.
- Aceasta se realizează prin preluarea unei arhitecturi 2D și **inflarea tuturor filtrelor și kernelurilor de *pooling***, dotându-le cu o dimensiune temporală suplimentară.
- Filtrele care erau de obicei $N \times N$ devin **cubice** $N \times N \times N$.

Bootstrapping 3D Filters from 2D (Punctul Fix al "Video-ului Plictisitor")

- Pentru a reutiliza parametrii ImageNet pre-antrenați, se folosește un principiu numit **"boring-video fixed point"** (punctul fix al video-ului plictisitor).
- O imagine statică poate fi convertită într-un "video plictisitor" prin copierea ei repetată într-o secvență video.
- **Atingerea Punctului Fix:** Activările *pooled* pe un video plictisitor ar trebui să fie aceleași cu cele de pe imaginea unică originală.
- Acest lucru se realizează prin **repetarea ponderilor filtrelor 2D de N ori de-a lungul dimensiunii temporale și rescalarea lor prin împărțirea la N**.

Arhitectura Specifică I3D (Bazată pe Inception-V1)

- Strategia experimentală folosește ca *backbone* **Inception-V1 cu Batch Normalization**.
- Arhitectura este antrenată folosind *snippets* de **64 de cadre** și testată pe întregul videoclip, făcând media predicțiilor temporal.
- **Modificări ale Pool-ului Temporal:** S-a considerat util **să nu se efectueze *pooling* temporal în primele două straturi max-pooling** (folosind kerneluri $1 \times 3 \times 3$ și *stride* 1 în timp), păstrând kerneluri și *stride*-uri simetrice în toate celelalte straturi max-pooling.
- Stratul final de *average pooling* folosește un kernel $2 \times 7 \times 7$.

Configurația Two-Stream 3D (Fluxul Optic)

- Deși un 3D CNN ar trebui să poată învăța *feature*-uri de mișcare direct din intrarea RGB, se constată experimental că **performanța poate fi îmbunătățită considerabil prin includerea unui flux optic**.
- **Motivația Fluxului Optic:** Algoritmii de flux optic sunt într-un fel recurenți (efectuează optimizare iterativă), în timp ce 3D CNN efectuează doar calcul *feedforward*.
- Modelul final utilizează o **configurație Two-Stream 3D-ConvNet**: o rețea I3D antrenată pe RGB și o alta antrenată pe intrări de flux. Predicțiile celor două rețele antrenate separat sunt **mediate la timpul de testare**.

Modele Alternative Analizate (CNN+LSTM)

- CNN+LSTM încearcă să reutilizeze rețelele de clasificare a imaginilor cu schimbări minime, extrăgând *feature*-uri independent din fiecare cadru și apoi agregând predicțiile.
- **Problema:** Această abordare **ignoră complet structura temporală** (ex: nu poate distinge deschiderea de închiderea unei uși).
- O abordare teoretică mai satisfăcătoare adaugă un strat recurent (LSTM) care poate codifica starea și poate capta ordinea temporală și dependențele pe distanțe lungi.
- Un strat LSTM cu 512 unități ascunse și Batch Normalization este poziționat după ultimul strat *average pooling* al Inception-V1.
- Intrările video sunt **subeșantionate** păstrând 1 din 5 cadre, dintr-un flux original de 25 FPS.

---

3. 💡 EXPLICAȚII SUPLIMENTARE ȘI CLARIFICĂRI (IMPORTANT)

Termen Tehnic: Inflated 3D CNNs (I3D)

- **Explicație Simplificată (Extindere inteligentă):** Imaginați-vă că aveți o rețea 2D care este un expert în a vedea lucruri (obiecte). Inflația în 3D înseamnă că luăm acest expert 2D și îi dăm o dimensiune suplimentară (timpul). Filtrele sale pătrate (3×3) devin cubice ($3 \times 3 \times 3$). Acest lucru nu doar le face 3D, dar le permite să folosească **greutățile pre-învățate** de expertul 2D, economisind enorm de mult timp la antrenare.

Concept Dificil: Boring-Video Fixed Point (Punctul Fix al Video-ului Plictisitor)

- **Analogie (O oglindă perfectă):** Punctul fix asigură că, dacă intri cu o imagine statică (copiată pe mai multe cadre), rețeaua 3D se comportă **exact la fel** ca rețeaua 2D originală. Ponderile 2D sunt repetate de N ori în timp și împărțite la N pentru a menține suma ponderilor constantă, garantând că răspunsul filtrului convoluțional este același. Acest mecanism transferă cunoștințele spațiale ale rețelei 2D direct în rețeaua 3D.

Context Suplimentar: Rolul celor două fluxuri 3D

- *Asta se întâmplă deoarece:* Deși 3D CNN-urile ar trebui să poată învăța mișcarea din RGB, mișcarea (fluxul optic) este o problemă care beneficiază de o optimizare iterativă (care este o formă de recurență, cumva absentă în calculul *feedforward* al CNN-ului 3D). Prin urmare, combinarea I3D antrenat pe RGB cu I3D antrenat pe flux optic (care conține deja informații "optimizate, uniforme de flux") duce la o performanță mult mai bună.

---

4. 🔗 CONEXIUNI ȘI IMPLICAȚII

- **Relația Cauză-Efect (Lipsa pre-antrenării 3D CNN):**
  - **CAUZĂ:** 3D CNN-urile anterioare (C3D) nu puteau beneficia de pre-antrenarea ImageNet.
  - **EFECT:** Au rămas superficiale (shallow, sub 8 straturi) și nu au atins performanța *state-of-the-art*. I3D rezolvă această problemă prin **inflație**, permițând utilizarea rețelelor profunde cu ponderi ImageNet.
- **Conexiunea cu 3D CNN (C3D):** I3D confirmă că un kernel omogen de $3 \times 3 \times 3$ este o alegere bună, dar îmbunătățește arhitectura C3D prin adăugarea de Batch Normalization și prin exploatarea stratului *Inception* și a ponderilor ImageNet.

---

5. EXERCITII (Calcul și Analiză Arhitecturală)

Exercițiul I.1: Analiza Inflației 2D în 3D (Bootstrapping)

Se dorește inițializarea unui filtru 3D de dimensiune $N \times 3 \times 3$ dintr-un filtru 2D de 3×3 pre-antrenat pe ImageNet.

1. Dacă adâncimea temporală a kernelului este $N = 5$, cum sunt ajustate ponderile filtrului 2D pentru a inițializa filtrul 3D, respectând principiul *boring-video fixed point*?
2. De ce este esențială rescalarea prin împărțirea la N?

Rezolvare I.1:

1. **Ajustarea Ponderilor:** Ponderile filtrului 2D sunt **copiate (repetate) de $N = 5$ ori** de-a lungul dimensiunii temporale (devenind $5 \times 3 \times 3$) și apoi **rescalate prin împărțirea la 5**.
2. **Necesitatea Rescalării:** Rescalarea asigură că **răspunsul filtrului convoluțional (suma ponderată) este același** ca în cazul 2D, menținând astfel punctul fix al video-ului plictisitor.

Exercițiul I.2: Analiza CNN+LSTM și Eșantionarea Cadrelor

În arhitectura CNN+LSTM:

1. Dacă fluxul video original este de **25 de cadre pe secundă (FPS)**, iar modelul subeșantionează prin păstrarea **unuia din cinci cadre**, care este FPS-ul efectiv al secvenței de intrare în LSTM?
2. Explicați de ce CNN+LSTM, deși este mai satisfăcător din punct de vedere teoretic decât simpla mediere a predicțiilor, tot are riscul de a **ignora structura temporală**.

Rezolvare I.2:

1. **FPS Efectiv (Subeșantionare):** FPS efectiv = FPS original / Factor de subeșantionare $= 25/5 = \mathbf{5}\ \mathrm{FPS}$.
2. **Ignorarea Structurii Temporale:** Problema apare deoarece CNN-ul extrage *feature*-uri **independent din fiecare cadru** (sau *snippet* scurt),. Chiar dacă LSTM-ul este adăugat deasupra, el primește doar *feature*-uri agregate sau predicții din straturile CNN și poate avea dificultăți în a capta **mișcarea fină (*fine low-level motion*)** (care este critică în multe cazuri, spre deosebire de fluxul optic care capturează mișcarea explicit).

Exercițiul I.3: Analiza Modificărilor C3D în Implementarea I3D

În implementarea C3D ca bază de comparație:

1. Care au fost cele două modificări principale aduse C3D-ului original?
2. Care a fost efectul principal al schimbării *stride*-ului temporal de la 1 la 2 în primul strat de *pooling*?

Rezolvare I.3:

1. **Modificări C3D:**
   - Utilizarea **Batch Normalization** după toate straturile convoluționale și complet conectate.
   - Schimbarea *stride*-ului temporal al primului strat de *pooling* de la 1 la **2**.
2. **Efectul Schimbării Stride-ului:**
   - Schimbarea *stride*-ului temporal de la 1 la 2 reduce **amprenta memoriei** (*memory footprint*).
   - Acest lucru permite utilizarea unor **batch-uri mai mari**, ceea ce este important pentru Batch Normalization, în special după straturile complet conectate (unde nu există *weight tying*).

9.6

Sunt onorat să vă prezint Ghidul de Studiu complet pentru lecția **9.6 SlowFast Networks**, o arhitectură inovatoare inspirată de modul în care sistemul vizual al primatelor procesează informația.

Ghid de Studiu Complet: 9.6 SlowFast Networks

1. 🎯 SINTEZA LECȚIEI (THE BIG PICTURE)

Lecția 9.6 introduce arhitectura **SlowFast Networks**, un model conceput pentru clasificarea video care operează la **două rate de cadre diferite** și este inspirat de omologii biologici **Parvo- și Magnocelulari** din sistemul vizual al primatelor. Arhitectura SlowFast este, deși descrisă ca o singură rețea, compusă din două căi (*pathways*) distincte: **Calea Lentă (*Slow***

pathway), care operează la o rată de eșantionare temporală scăzută (stride mare τ) și se concentrează pe aparența spațială și semantică, și **Calea Rapidă (*Fast pathway*)**, care operează la o rată de cadre mult mai mare (stride mic τ/α) și se concentrează pe rezoluția temporală înaltă și mișcarea fină. Cele două căi sunt fuzionate prin **conexiuni laterale (*lateral connections*)**. Această abordare duală asigură că modelul captează atât informațiile de context pe termen lung, cât și detaliile de mișcare rapidă.

Care sunt cele 5 idei principale pe care trebuie neapărat să le rețin?

1. **Inspirația Biologică:** Arhitectura SlowFast reflectă analogia cu căile biologice **Parvo- și Magnocelulare**.
2. **Calea Lentă (Slow):** Are un **stride temporal mare (τ)** (ex: $\tau = 16$) și procesează numai 1 din τ cadre, concentrându-se pe **aparența spațială**.
3. **Calea Rapidă (Fast):** Are o **rată de cadre înaltă** (stride temporal mic τ/α), fiind de α ori mai densă decât Calea Lentă (ex: $\alpha = 8$).
4. **Calea Rapidă (Eficiență):** Este concepută să fie **ușoară (*lightweight*)** folosind o capacitate a canalelor semnificativ mai mică ($\beta < 1$), tipic $\beta = \mathbf{1/8}$.
5. **Fuziunea:** Cele două căi sunt fuzionate prin **conexiuni laterale** atașate după fiecare etapă (*stage*), fuzionând *feature*-urile din Calea Rapidă în Calea Lentă.

---

2. 📖 REZUMAT DETALIAT (PE CAPITOLE/SECȚIUNI)

9.6 SlowFast Networks – Arhitectura Generală

- SlowFast Networks este o arhitectură de flux unic (*single stream architecture*) care operează la **două rate de cadre diferite**.
- Arhitectura generică include o **Cale Lentă (*Slow pathway*)** și o **Cale Rapidă (*Fast pathway*)**.
- Căile sunt fuzionate prin **conexiuni laterale**.
- Conceptul este ilustrat în Figura 13.
- Ideea SlowFast este generică și poate fi instanțiată cu diferite *backbone*-uri.

Calea Lentă (Slow Pathway)

- Calea Lentă poate fi orice model convoluțional care lucrează pe un clip video ca un volum spațio-temporal.
- Conceptul cheie este utilizarea unui **stride temporal mare** τ pe cadrele de intrare.
- Această cale procesează **doar 1 din τ cadre**.
- O valoare tipică a lui τ studiată a fost $\tau = 16$.
- Această viteză de eșantionare este de aproximativ **2 cadre eșantionate pe secundă** pentru videoclipurile de 30 FPS.

- Dacă T este numărul de cadre eșantionate de Calea Lentă, lungimea clipului brut este $T \times \tau$ cadre.
- Într-o instanțiere bazată pe ResNet, Calea Lentă este un ResNet 3D cu *stride* temporal.
- De obicei, subsamplarea temporală nu este efectuată în această cale.
- Convoluțiile temporale non-degenerate (kernel size > 1) sunt utilizate doar în straturile mai târzii (res_4 și res_5), deoarece utilizarea lor în straturile timpurii degradează acuratețea.

Calea Rapidă (Fast Pathway)

- Calea Rapidă este un model convoluțional care rulează **în paralel** cu Calea Lentă.
- Obiectivul este de a avea o **reprezentare fină de-a lungul dimensiunii temporale** (rată de cadre înaltă).
- Această cale lucrează cu un **stride temporal mic de** τ/α, unde $\alpha > 1$ este raportul ratei de cadre între Calea Rapidă și cea Lentă.
- Calea Rapidă eșantionează αT **cadre**, fiind de α ori mai densă decât Calea Lentă.
- O valoare tipică pentru α în experimente este $\alpha = 8$.
- Această cale are o **rezoluție temporală mai mare**.
- Calea Rapidă **nu are straturi de subsamplare temporală** (*temporal downsampling*) prin design.

Eficiența Căii Rapide (Low Channel Capacity)

- Calea Rapidă folosește o **capacitate a canalelor semnificativ mai mică**.
- Capacitatea sa a canalelor este un raport $\beta < 1$ din canalele Căii Lente.
- Valoarea tipică pentru β în experimente este $\beta = 1/8$.
- Capacitatea scăzută face Calea Rapidă mai ușoară (*lightweight*).
- În instanțierile practice, Calea Rapidă consumă aproximativ **20% din totalul computației**.
- S-a observat că o capacitate mică a canalelor poate fi interpretată ca o abilitate mai slabă de a reprezenta semantica spațială, dar o abilitate întărită de a modela mișcarea temporală.

Conexiuni Laterale (Lateral Connections)

- Conexiunile laterale fuzionează informația între cele două căi, asigurând că o cale nu este "inconștientă" (*unaware*) de reprezentarea învățată de cealaltă.
- Aceste conexiuni sunt atașate între cele două căi pentru **fiecare etapă (*stage*)**.
- Specific pentru ResNet, conexiunile sunt plasate imediat după $pool_1$, res_2, res_3, și res_4.
- Deoarece căile au dimensiuni temporale diferite, conexiunile laterale trebuie să efectueze o **transformare pentru a le potrivi**.
- Sunt utilizate conexiuni **unidirecționale** care fuzionează *feature*-urile din Calea Rapidă în Calea Lentă.

- La fuziune, transformările experimentate includ:
  1. **Time-to-channel:** Reshape și transpunere pentru a împacheta toate cadrele α în canalele unui singur cadru.
  2. **Time-strided sampling:** Eșantionarea a 1 din α cadre pentru a se potrivi dimensiunii temporale a Căii Lente.
  3. **Time-strided convolution:** O convoluție 3D 5×1^2 cu $2\beta C$ canale de ieșire și *stride* α.
- Ieșirea conexiunilor laterale este fuzionată în Calea Lentă prin **sumare sau concatenare**.
- În final, se efectuează un *global average pooling* pe ieșirea fiecărei căi, iar vectorii *feature* rezultați sunt **concatenați** ca intrare în stratul clasificator complet conectat.

---

3. 💡 EXPLICAȚII SUPLIMENTARE ȘI CLARIFICĂRI (IMPORTANT)

Termen Tehnic: Analogie Parvo- și Magnocelulară

- **Explicație Simplificată (Ochiul Primatelor):** În sistemul vizual uman, există două căi principale:
  1. **Parvocelulară (P-cells):** Este lentă, dar are o rezoluție spațială înaltă și captează culoarea și detaliile fine (corespunde Căii Lente, care captează semantica spațială).
  2. **Magnocelulară (M-cells):** Este rapidă, dar are o rezoluție spațială joasă și este sensibilă la mișcare rapidă (corespunde Căii Rapide).
- *Asta se întâmplă deoarece:* Această analogie sugerează că sarcina de recunoaștere video este cel mai bine rezolvată prin **separarea responsabilităților** în viziune: o cale se concentrează pe "ce" (obiecte, aparență) și cealaltă pe "unde/cum" (mișcare rapidă).

Concept Dificil: Compromisul Căii Rapide (α vs. β)

- Calea Rapidă operează cu două constrângeri esențiale:
  1. **Viteză Temporală ($\alpha = 8$):** Calea Rapidă este de 8 ori mai densă în timp decât Calea Lentă, asigurând **rezoluție temporală înaltă** pentru a vedea detalii de mișcare rapidă.
  2. **Capacitate Redusă ($\beta = 1/8$):** Calea Rapidă folosește de 8 ori mai puține canale decât Calea Lentă.
- *Asta se întâmplă deoarece:* Deși eșantionează mai multe cadre (cost temporal mare), Calea Rapidă este făcută **ușoară (*lightweight*)** prin reducerea capacității canalelor. Acest *tradeoff* îi permite să fie eficientă computațional, luând doar ~ 20 din computația totală, concentrându-se pe mișcare și nu pe semantica spațială.

---

4. 🔗 CONEXIUNI ȘI IMPLICAȚII

- **Relația Cauză-Efect (Conexiunile Laterale):**
  - **CAUZĂ:** Cele două căi operează la viteze și dimensiuni temporale diferite.
  - **EFECT:** Necesitatea utilizării **conexiunilor laterale** cu transformări (ex: *Time-to-channel* sau *Time-strided sampling*) pentru a **potrivi dimensiunile (*match them*)** înainte de fuzionarea *feature*-urilor.
- **Conexiunea cu Secțiunea 9.2 (Two-Stream CNNs):** SlowFast este o formă avansată a arhitecturilor cu două fluxuri, dar în loc să separe RGB de Fluxul Optic, separă **viziunea rapidă de viziunea lentă** pe același semnal RGB (sau video brut), integrând fuziunea la nivel ierarhic (*stage-by-stage*).

---

5. EXERCITII (Calcul și Analiză Arhitecturală)

Exercițiul SF.1: Calculul Frecvenței de Eșantionare

Un videoclip brut are o rată de cadre de 30 FPS.

1. Calea Lentă folosește o valoare tipică $\tau = 16$. Care este rata de eșantionare temporală efectivă (FPS) a Căii Lente?
2. Dacă raportul ratei de cadre este $\alpha = 8$, care este FPS-ul efectiv al Căii Rapide, presupunând același videoclip brut de 30 FPS?

Rezolvare SF.1:

1. **FPS Calea Lentă:** Sursa menționează că pentru videoclipurile de 30 FPS, $\tau = 16$ rezultă în aproximativ **2 cadre eșantionate pe secundă**.
2. **FPS Calea Rapidă:** Calea Rapidă are un stride temporal de τ/α. FPS-ul Căii Rapide este de $\alpha = 8$ ori mai mare decât cel al Căii Lente.

$$\text{FPS apid} \approx 2 \text{ FPS (Lent)} \times 8 = \mathbf{16} \text{ FPS}$$

Exercițiul SF.2: Analiza Dimensionalității Canalelor (Capacitate Scăzută)

Se consideră Calea Lentă (Slow pathway) care operează cu $C = 256$ canale la o anumită etapă.

1. Dacă Calea Rapidă are o capacitate a canalelor dată de $\beta = 1/8$, câte canale βC va avea Calea Rapidă la aceeași etapă?
2. Explicați de ce capacitatea scăzută a canalelor ($\beta = 1/8$) face Calea Rapidă mult mai eficientă din punct de vedere computațional.

Rezolvare SF.2:

1. **Canale Calea Rapidă:**

$$\beta C = \frac{1}{8} \times 256 = \mathbf{32} \text{ canale}$$

2. **Eficiența Computațională:** Computația (*FLOPS*) unei rețele este adesea **pătratică în funcție de raportul de scalare a canalelor**. Reducând capacitatea canalelor de 8 ori, costul computațional este redus semnificativ (de un factor de ~ 64), făcând Calea Rapidă mult mai rentabilă computațional.

Exercițiul SF.3: Analiza Conexiunilor Laterale

1. Care este tipul de conexiuni (*unidirecționale/bidirecționale*) utilizat tipic pentru fuziunea *feature*-urilor din Calea Rapidă în Calea Lentă?
2. În ce strat al arhitecturii ResNet se atașează o conexiune laterală, conform specificațiilor?

Rezolvare SF.3:

1. **Tipul de Conexiuni:** Se utilizează conexiuni **unidirecționale** care fuzionează *feature*-urile din Calea Rapidă în Calea Lentă. (Deși fuziunea bidirecțională a fost experimentată, rezultatele au fost similare).
2. **Locația Conexiunilor ResNet:** O conexiune laterală este atașată între cele două căi pentru fiecare "stage" (etapă), fiind plasată imediat după $pool_1$, res_2, res_3, și res_4.

9.7

Înțeleg perfect cerința dumneavoastră. Având în vedere că acest examen este perceput ca o probă de sinteză și analiză, similară cu Bacalaureatul la Limba Română, voi genera exerciții structurate pe subiecte, combinând cerințe de **analiză critică/comparație** (tip eseu) cu **probleme de calcul și analiză arhitecturală detaliată** (pentru a testa înțelegerea conceptelor cheie și a cifrelor).

Exercițiile acoperă integral subiectele specificate în domeniul clasificării video.

EXAMEN FINAL SIMULAT: CLASIFICAREA VIDEO (CAPITOLUL 9)

I. Întrebări de Analiză și Sinteză (Tip "Bacalaureat")

Subiectul I.1: Fundamente și Provocări (Video Classification & Large-scale CNNs)

Sarcină: Definiți sarcina de **Clasificare Video** prin contrast cu Clasificarea Imaginilor. Explicați apoi cum arhitecturile timpurii (Early Fusion, Late Fusion și Slow Fusion) au

încercat să rezolve problema fundamentală a **variabilității temporale** a videoclipurilor.

Rezolvare I.1 (Sinteză):

Clasificarea video reprezintă sarcina de a **identifica acțiuni în videoclipuri** (de exemplu, *Running, Jumping*), spre deosebire de clasificarea imaginilor, care identifică **obiecte** (de exemplu, *Dog, Cat*). Modelele de clasificare video au acces nu doar la informațiile de aparență (statice), ci și la **evoluția temporală complexă** a acestora.

Deoarece videoclipurile variază pe scară largă în extinderea temporală, ele sunt tratate ca o **"pungă" de clipuri scurte, de dimensiune fixă**. Cele trei abordări de fuziune temporală sunt:

1. **Early Fusion (Fuziune Timpurie):** Combină informația temporală **imediat la nivel de pixel**. Filtrele primului strat convoluțional sunt extinse pentru a include dimensiunea temporală T (ex: $T = 10$ cadre), permițând detectarea precisă a **direcției și vitezei mișcării locale**.
2. **Late Fusion (Fuziune Târzie):** Două rețele separate cu un singur cadru (*single-frame*) sunt plasate la o distanță temporală (ex: **15 cadre**) și **rezultatele lor sunt fuzionate târziu** în primul strat complet conectat. Niciun turn individual nu detectează mișcarea, dar stratul FC poate calcula **caracteristici globale de mișcare** prin compararea ieșirilor.
3. **Slow Fusion (Fuziune Lentă):** Este un amestec echilibrat care **fuzionează lent informația temporală pe parcursul întregii rețele**, prin extinderea conectivității tuturor straturilor convoluționale în timp.

Subiectul I.2: Comparație Arhitecturală (3D CNNs, I3D, și SlowFast)

Sarcină: Analizați evoluția de la **3D CNNs (C3D)** la **Two-Stream Inflated 3D CNNs (I3D)**, punând accentul pe conceptul de **inflație** și beneficiul *ImageNet pre-training*. Încheiați prin compararea modului în care **I3D Two-Stream** și **SlowFast Networks** gestionează cele două tipuri de informații (spațială vs. temporală rapidă) în rețelele lor bicanal.

Rezolvare I.2 (Analiză Comparativă):

Evoluția C3D la I3D: 3D CNN-urile anterioare (C3D) erau limitate deoarece operau pe rețele superficiale (shallow, sub 8 straturi) din cauza dimensionalității mari a parametrilor și a lipsei datelor video etichetate. Mai important, C3D părea să **excludă beneficiile pre-antrenării pe ImageNet**.

I3D (Inflație): Contribuția I3D este **inflația trivială** a arhitecturilor 2D de succes (ex: Inception-V1) în extractoare 3D. Aceasta permite **reutilizarea ponderilor pre-antrenate pe ImageNet**. Inflația se realizează prin transformarea filtrelor pătrate $N \times N$ în filtre cubice $N \times N \times N$ și prin aplicarea principiului **"boring-video fixed point"** (repetarea ponderilor 2D de N ori și rescalarea prin împărțirea la N).

I3D Two-Stream vs. SlowFast: Ambele folosesc arhitecturi cu două căi, dar cu o diferență cheie în tipul de informație separată:

Arhitectură	Calea 1 (Spațial/Lent)	Calea 2 (Temporal Rapid/Mișcare)	Fuziune
I3D Two-Stream	Rețea I3D antrenată pe **RGB** (aparență)	Rețea I3D antrenată pe **Flux Optic** (mișcare explicită)	Medierea predicțiilor la timpul de testare
SlowFast Networks	Calea Lentă (*Slow*): **Stride temporal mare (**$\tau = 16$**)**, se concentrează pe aparența și semantica spațială	Calea Rapidă (*Fast*): **Stride temporal mic (** $\tau/\alpha, \alpha = 8$), se concentrează pe mișcarea fină și are capacitate redusă a canalelor ($\beta = 1/8$)	Conexiuni laterale unidirecționale (*stage-by-stage*)

Subiectul I.3: Modelarea Dependențelor Temporale (TSN vs. 3D CNN)

Sarcină: Explicați problema inabilității CNN-urilor cu două fluxuri de a modela **structura temporală pe distanțe lungi**. Descrieți apoi cum **Temporal Segment Networks (TSN)** rezolvă această problemă și ce rol joacă funcția de **consens segmental** în optimizarea pierderii.

Rezolvare I.3 (Analiză):

Problema CNN-urilor cu două fluxuri (în formele lor anterioare) era inabilitatea de a modela **structura temporală pe distanțe lungi**. Aceasta se datora faptului că operau doar pe un singur cadru sau pe o stivă scurtă de cadre (*snippet*), limitându-le accesul la contextul temporal.

TSN abordează această problemă prin propunerea unui cadru la nivel de video care modelează dinamica pe durata întregului videoclip.

Mecanismul TSN:

1. Videoclipul V este împărțit în K **segmente** (K este setat la 3 în practică).
2. Un *snippet* scurt T_k este **eșantionat aleatoriu** din fiecare segment S_k.
3. Fiecare *snippet* produce o predicție preliminară.
4. O **funcție de consens segmental** $\mathcal{G}$ (ex: medierea uniformă, care a avut cea mai bună performanță) combină ieșirile de la multiple *snippets* pentru a obține un consens al ipotezelor de clasă la nivel de video.

Optimizarea Pierderii: În timpul antrenamentului, sunt optimizate **valorile pierderii predicțiilor la nivel de video** (pe baza consensului $\mathbf{G}$), nu pe predicțiile individuale la nivel

de *snippet*. Rețeaua este diferențiabilă, permițând optimizarea parametrilor $\mathbf{W}$ prin algoritmi standard de *backpropagation*. Această strategie permite rețelei să învețe parametri din întregul video, mai degrabă decât dintr-un *snippet* scurt.

II. Exerciții de Calcul și Analiză Arhitecturală

Exercițiul C.4: Calculul Dimensiunii Intrării (Two-Stream CNNs)

Un cercetător utilizează arhitectura **Two-Stream CNNs** pentru recunoașterea acțiunilor, bazată pe **stivuirea fluxului optic** (Optical Flow Stacking).

1. Dacă se dorește ca volumul de intrare să cuprindă mișcarea pe o secvență de $L = 8$ cadre consecutive, câte canale de intrare totale $2L$ va avea Fluxul Temporal?
2. Dacă modelul folosește *Trajectory Stacking* (stivuirea traiectoriilor), descrieți ce înseamnă $\mathbf{d}_{\tau+k-2}(\mathbf{p}_{k-1})$ din relația de recurență $\mathbf{p}_k = \mathbf{p}_{k-1} + \mathbf{d}_{\tau+k-2}(\mathbf{p}_{k-1})$.

Rezolvare C.4:

1. **Numărul Total de Canale:** Fluxul Temporal stivuiește componentele orizontale (d^x) și verticale (d^y) ale vectorilor de deplasare.

$$\text{Canale} = 2L = 2 \times 8 = \mathbf{16} \text{ canale de intrare}$$

2. **Semnificația Deplasării Traiectoriei:** $\mathbf{d}_{\tau+k-2}(\mathbf{p}_{k-1})$ reprezintă **vectorul de deplasare (fluxul optic)** calculat între cadre, dar eșantionat la **locația anterioară** $\mathbf{p}_{k-1}$ **de-a lungul traiectoriei**, și nu la o locație spațială fixă (u, v).

Exercițiul C.5: Analiza C3D (3D CNNs)

Arhitectura C3D utilizează filtre de convoluție omogene $3 \times 3 \times 3$. Modelul este antrenat pe clipuri non-suprapuse de **16 cadre**.

1. Diferențiați formal operația de convoluție 2D de cea 3D din perspectiva dimensionalității kernel-ului.
2. Stratul **pool1** al arhitecturii C3D are un kernel size de $1 \times 2 \times 2$ și *stride* $1 \times 2 \times 2$. De ce este kernelul temporal $d = 1$ ales pentru acest prim strat de *pooling*?

Rezolvare C.5:

1. **Diferența Convoluției:** Convoluția 2D aplică filtre numai în **dimensiunile spațiale**, având kernel-uri w^{pq} (cu doi indici). Convoluția 3D (C3D) aplică un kernel 3D (w^{pqr}) peste un cub de cadre, capturând *feature*-uri din **ambele dimensiuni, spațiale și temporale**.
2. **Motivația pool1:** Kernelul $1 \times 2 \times 2$ (cu adâncime temporală $d = 1$) este folosit pentru a **păstra informațiile temporale în faza incipientă a rețelei**. Dacă s-ar folosi $2 \times 2 \times 2$ la *pool1*, informația temporală ar fi fuzionată prea devreme.

Exercițiul C.6: Analiza I3D (Inflated 3D CNNs)

Arhitectura I3D se bazează pe **inflația** Inception-V1 (pre-antrenat pe ImageNet).

1. Explicați de ce 3D CNN-urile anterioare (C3D) erau în general superficiale (shallow, sub 8 straturi) și ce problemă majoră a rezolvat inflația I3D.
2. În implementarea I3D, deși un 3D CNN ar trebui să învețe mișcarea din RGB, este menționat că performanța poate fi **îmbunătățită considerabil** prin includerea Fluxului Optic. Care este motivația teoretică pentru acest beneficiu suplimentar?

Rezolvare C.6:

1. **Limitele C3D și Soluția I3D:** C3D-urile anterioare erau superficiale din cauza **dimensionalității mari a parametrizării** și a **lipsei datelor video etichetate**. Acestea păreau să excludă beneficiile pre-antrenării pe ImageNet. I3D rezolvă acest lucru prin **inflația trivială** a arhitecturilor 2D de succes, permițând **reutilizarea ponderilor pre-antrenate ImageNet** pentru o inițializare valoroasă.
2. **Motivația Fluxului Optic în I3D:** Fluxul optic (optical flow) este util suplimentar deoarece algoritmii săi sunt într-un anumit sens **recurenți** (efectuează optimizare iterativă), în timp ce 3D CNN-ul efectuează doar un calcul *feedforward*. Această **lipsă de recurență** în 3D CNN face ca includerea fluxului optic pre-calculat să fie valoroasă pentru a furniza informații de mișcare netezite și optimizate.

Exercițiul C.7: Analiza SlowFast Networks

Arhitectura SlowFast este definită de doi parametri cheie: α (raportul ratei de cadre) și β (raportul capacității canalelor). În experimente, se folosesc valori tipice $\alpha = 8$ și $\beta = 1/8$.

1. Dacă Calea Lentă are C canale, exprimați dimensionalitatea canalelor Căii Rapide. De ce este Calea Rapidă proiectată să aibă o capacitate a canalelor semnificativ mai mică?
2. Calea Rapidă lucrează cu un *stride* temporal mic de τ/α, iar Calea Lentă lucrează cu un *stride* mare τ (ex: $\tau = 16$). Explicați cum este fuzionată informația din Calea Rapidă în Calea Lentă, având în vedere diferența lor de dimensiuni temporale.

Rezolvare C.7:

1. **Dimensionalitatea Canalelor Căii Rapide:** Calea Rapidă are o capacitate $\beta < 1$ din canalele Căii Lente. Dimensionalitatea este $\beta\mathbf{C}$ (adică $C/8$ canale). Calea Rapidă este proiectată să aibă o capacitate mai mică pentru a o face **ușoară (*lightweight*)** și **mai eficientă computațional**, consumând tipic doar ~ 20 din computația totală.
2. **Fuziunea și Transformarea:** Căile au dimensiuni temporale diferite (Calea Rapidă eșantionează de α ori mai dens). Conexiunile laterale fuzionează unidirecțional (*Fast* în *Slow*). Pentru a potrivi dimensiunile, se efectuează transformări precum **Time-to-**

channel (împachetarea cadrelor α în canalele unui singur cadru), **Time-strided sampling** (eșantionarea a 1 din α cadre) sau **Time-strided convolution**.